



UNIVERSIDAD ESAN
FACULTAD DE INGENIERÍA
INGENIERÍA DE TECNOLOGÍAS DE INFORMACIÓN Y SISTEMAS

Optimización de Cobertura de Redes Inalámbricas mediante Inteligencia Artificial Generativa
para la Predicción de Ubicaciones de Puntos de Acceso (APs) Indoor en Diferentes Planos

Tesis I que presenta:

Jeferson Joseph Sandoval Díaz

Profesor: Marks Calderón

Lima, julio de 2024

OPTIMIZACIÓN DE COBERTURA DE REDES INALÁMBRICAS MEDIANTE
INTELIGENCIA ARTIFICIAL GENERATIVA PARA LA PREDICCIÓN DE
UBICACIONES DE PUNTOS DE ACCESO (APS) INDOOR EN DIFERENTES PLANOS

Agradecimiento y Dedicatoria

Thx

Índice general

Resumen	1
Introducción	3
Capítulo I: Planteamiento del Problema	4
1.1 Descripción de la Realidad Problemática	4
1.2 Formulación del Problema	6
1.2.1 Problema General	6
1.2.2 Problemas Específicos	6
1.3 Objetivos de la Investigación	7
1.3.1 Objetivo General	7
1.3.2 Objetivos Específicos	7
1.4 Hipótesis	7
1.4.1 Hipótesis General	7
1.4.2 Hipótesis Específicas	8
1.5 Justificación de la Investigación	8
1.5.1 Teórica	8
1.5.2 Práctica	9
1.5.3 Metodológica	9
1.6 Delimitación del Estudio	10
1.6.1 Espacial	10
1.6.2 Temporal	10
1.6.3 Conceptual	10
Capítulo II: Marco Teórico	11
2.1 Antecedentes de la investigación	11
2.1.1 «Modelo de optimización para la ubicación de Access Point en redes WLAN»	11
2.1.2 «An Optimization for Access Point Placement in Indoor Communication» .	12
2.1.3 «Location Prediction of Rogue Access Point Based on Deep Neural Network Approach»	14
2.1.4 «House-GAN++: Generative Adversarial Layout Refinement Network towards Intelligent Computational Agent for Professional Architects» .	14
2.1.5 «Precise WiFi Indoor Positioning using Deep Learning Algorithms» .	16
2.1.6 «NSGA-II based optimal Wi-Fi access point placement for indoor positioning: A BIM-based RSS prediction»	17

2.1.7	«3D coverage location modeling of Wi-Fi access point placement in indoor environment»	19
2.1.8	<i>Generating Mass Housing Plans Through Gans - A Case in Toki, Turkey</i>	20
2.1.9	«Building-GAN: Graph-Conditioned Architectural Volumetric Design Generation»	21
2.1.10	«Intelligent Home 3D: Automatic 3D-House Design from Linguistic Descriptions Only»	23
2.1.11	«Research on Wireless Network Coverage for Transformation and Upgrading of Exhibition Management with Artificial Intelligence Technology»	24
2.2	Bases Teóricas	27
2.2.1	Inteligencia Artificial	27
2.2.2	Aprendizaje Automático	27
2.2.3	Aprendizaje Profundo	30
2.2.4	Aprendizaje Profundo Multimodal	31
2.2.5	Inteligencia Artificial Generativa	31
2.2.6	Modelos de Predicción	35
2.2.7	Análisis de Datos Espaciales	35
2.2.8	Procesamiento del Lenguaje Natural	37
2.2.9	Redes Generativas Antagónicas	40
2.2.10	Generación de Imágenes	43
2.3	Marco Conceptual	45
2.3.1	Redes Inalámbricas	45
2.3.2	Calidad de Servicio (QoS)	46
2.3.3	Diferentes parámetros que deben enviarse para las comunicaciones de extremo a extremo a través de redes inalámbricas	47
2.3.4	Access Points	48
Capítulo III:	Metodología de la Investigación	51
3.1	Diseño de la investigación	51
3.1.1	Tipo de investigación	51
3.1.2	Enfoque de la investigación	51
3.1.3	Población	51
3.1.4	Muestra	51
3.1.5	Operacionalización de Variables	52
3.2	Técnicas de recolección de datos	53
3.3	Técnicas para el procesamiento y análisis de la información	54
3.3.1	Metodología de implementación de la solución	54
3.3.2	Metodología para la medición de resultados	71

3.4 Cronograma de actividades y presupuesto	75
Referencias	78
Anexos	82
A Árbol de Problemas	83
B Árbol de Objetivos	84
C Matriz de Consistencia	85
D Comparación de metodologías de antecedentes	89

Índice de Figuras

Figura 1.	Quejas de Clientes en el foro de Cisco	5
Figura 2.	Problemas de uso de Access Points	6
Figura 3.	Diagrama de cobertura y ubicación de AP	12
Figura 4.	Un mapa de calor que describe la intensidad de la señal recibida antes y después. a Área de cobertura de la señal para los puntos de acceso de la izquierda, b Área de cobertura de la señal para los puntos de acceso de la derecha, c Área de cobertura de la señal para los puntos de acceso de la izquierda, d Área de cobertura de la señal para los puntos de acceso de la derecha.	13
Figura 5.	Precisión de la predicción en función del número de subzonas para la predicción de la ubicación de 1 a 4 RAP.	15
Figura 6.	La arquitectura se basa en un GAN relacional. Se puede especificar una máscara de segmentación 2D adicional para cada habitación/puerta como condición de entrada, lo que permite un refinamiento iterativo del diseño.	16
Figura 7.	Evaluación del realismo. Se muestra un diseño generado para cada diagrama de burbujas de entrada	17
Figura 8.	Los MAE del modelo híbrido de posicionamiento	18
Figura 9.	Los resultados de la evaluación de la convergencia del NSGA-II	19
Figura 10.	Colocación óptima de AP capacitados con demandas ponderadas ($p = 117$)	20
Figura 11.	HouseGAN con LIFULL HOMES Datasets, imágenes generadas por los autores	22
Figura 12.	Para cada gráfico de programa, se generan diseños volumétricos mediante nuestro modelo y mediante House-GAN	23
Figura 13.	Comparación de nuestros planos de casas en 3D generados con sus contrapartes reales (hechas por humanos)	24
Figura 14.	Estructura de HHO	25
Figura 15.	Comparaciones entre los métodos	26
Figura 16.	El algoritmo de K medias	29
Figura 17.	Características del Aprendizaje por Refuerzo	30
Figura 18.	Relación entre IA, ML y DL	31
Figura 19.	Modelo de aprendizaje profundo	32
Figura 20.	Modelo que combina imágenes y texto	32
Figura 21.	Un modelo multimodal para las señales de la vista	33
Figura 22.	Modelos de difusión	34
Figura 23.	Autocodificadores variacionales	35
Figura 24.	Ánalysis Exploratorio de Datos Espaciales (ESDA)	36

Figura 25.	El modelo gaussiano isotrópico; el modelo gaussiano anisotrópico ajustado; la predicción de Kriging Simple Residual; y la varianza de Kriging Simple Residual.	37
Figura 26.	Regresión Logística	38
Figura 27.	Arquitectura de un modelo CNN	39
Figura 28.	Modelo Seq2seq	40
Figura 29.	Red Generativa Antagónica de Imágenes	41
Figura 30.	Red Generativa Antagónica de Imágenes	42
Figura 31.	Imágenes de Ruido Gaussiano	42
Figura 32.	Arquitectura de Red Generativa Antagónica con Capas Convolucionales (DCGAN)	44
Figura 33.	Clasificación de redes inalámbricas con su alcance de señal	46
Figura 34.	Access Points	49
Figura 35.	Funcionamiento de un AP	50
Figura 36.	Plano interior	53
Figura 37.	Metodología de la Investigación	55
Figura 38.	Representación de las imágenes de los planos interiores	59
Figura 39.	Red Neuronal Convolucional (CNN) para la extracción de características .	61
Figura 40.	Generador del GAN	62
Figura 41.	Discriminador del GAN	63
Figura 42.	Pseudocódigo para la implementación	64
Figura 43.	Pseudocódigo para el Entrenamiento Supervisado	66
Figura 44.	Pseudocódigo para la Optimización de Cobertura	67
Figura 45.	Matriz de Confusión	71
Figura 46.	Cronograma de actividades	76

Índice de Tablas

Tabla 1.	Matriz de Variables Principales.	52
Tabla 2.	Actividades de la fase de Adquisición de Datos.	56
Tabla 3.	Actividades de la fase de Preprocesamiento de Datos.	57
Tabla 3.	Actividades de la fase de Preprocesamiento de Datos.	58
Tabla 4.	Actividades de la fase de Desarrollo del Modelo de IA.	60
Tabla 5.	Actividades de la fase de Entrenamiento del Modelo.	65
Tabla 6.	Actividades de la fase de Evaluación del Modelo.	68
Tabla 7.	Actividades de la fase de Despliegue.	70
Tabla 8.	Presupuesto	77

Índice de Ecuaciones

Ecuación 1	Fórmula para la exactitud	72
Ecuación 2	Fórmula para la precisión	72
Ecuación 3	Fórmula para el área bajo la curva ROC	73
Ecuación 4	Fórmula para calcular la sensibilidad	73
Ecuación 5	Fórmula para calcular el puntaje F1	74

Resumen

Palabras claves:

Abstract

Keywords:

Introducción

1

2

El primer capítulo aborda el tema de la investigación y su contexto. Además, se discuten los objetivos del estudio, sus hipótesis, justificación y delimitación.

En el segundo capítulo, varios enfoques y puntos de vista examinan los antecedentes principales del problema de la insuficiente cobertura de red inalámbrica. Además, se proporciona la base teórica que aborda los conceptos técnicos aplicados, desde los principios de la IA hasta las técnicas utilizadas en su desarrollo. El marco conceptual del capítulo concluye con una explicación de términos relacionados con la cobertura y el funcionamiento de las redes inalámbricas.

El tercer capítulo detalla el enfoque, población, muestra, diseño, tipo y operacionalización de las variables estudiadas. Luego se explican los criterios de selección, la ejecución de fases y actividades y los entregables comprometidos. Posteriormente, se presenta el método para evaluar los resultados de aplicación. Por último, se concluye con predicciones y cobertura detalladas de Aps Indoor.

El cuarto capítulo describe el desarrollo de la solución, incluyendo todos los modelos construidos, así como lo planteado en el capítulo anterior.

Los resultados de los experimentos se analizan y discuten en el quinto capítulo, que incluye los valores de las métricas y el tiempo de ejecución de la predicción utilizada. Además, se analiza el desempeño del modelo propuesto en comparación con la línea base.

Los principales hallazgos de la investigación se discuten en el sexto capítulo, así como las posibles mejoras, las fortalezas y las investigaciones futuras.

Las referencias utilizadas y los anexos de la investigación proporcionan información adicional sobre cada afirmación mencionada.

Capítulo I: Planteamiento del Problema

1.1 Descripción de la Realidad Problemática

En la actualidad, la capacidad de conectarse a Internet se ha vuelto fundamental para la comunicación entre individuos, empresas e instituciones educativas, y se ha convertido en una herramienta esencial para las actividades relacionadas. Sin embargo, muchas empresas carecen de una cobertura Wi-Fi completa que permita el acceso a Internet, lo que crea una serie de problemas para el envío de trabajos, la realización de consultas y otras actividades en las que la red sería de gran ayuda.

Lograr encontrar la ubicación idónea de Aps Indoor para lograr la cobertura total de un lugar es un proceso iterativo que consume mucho tiempo, que requiere múltiples rondas de refinamientos. Un especialista de TI esboza un diseño, evalúa, ajusta y repite los ciclos hasta estar satisfecho con un diseño dentro de un presupuesto de tiempo dado. Desafortunadamente, diseñar un plano de cobertura de red efectivo solo es posible mediante especialistas de TI o Redes, donde gran parte de empresas hacen su propio diseño personalizado menos efectivo debido al costo. La generación automática de planos de cobertura de red con las ubicaciones de Aps Indoor tendrá un tremendo impacto en las industrias de bienes raíces/construcción, redes y TI de billones de dólares.

En los últimos años, ha habido un aumento en la demanda de redes inalámbricas entre los usuarios, gracias a los beneficios que ofrecen en términos de movilidad y costos de implementación más bajos. Dentro de las redes inalámbricas, se encuentran las WLAN (Redes de Área Local Inalámbricas), las cuales son comúnmente utilizadas en entornos cotidianos como hogares, oficinas y instituciones educativas, entre otros lugares. Estas redes suelen estar compuestas principalmente por dispositivos concentradores conocidos como Puntos de Acceso (AP), los cuales permiten a los usuarios conectarse de forma inalámbrica a la red, cumpliendo una función similar a la de un Switch en una red cableada. Sin embargo, a pesar de la capacidad de los AP para establecer conexiones inalámbricas, la distancia efectiva entre el usuario y el AP es limitada (generalmente inferior a 100 metros), debido a la potencia de la señal de transmisión y a posibles obstáculos en el entorno que puedan afectar la señal. Debido a la creciente necesidad de conectividad inalámbrica por parte de los usuarios, la cantidad de Puntos de Acceso en uso está en constante aumento.

Una investigación de ABI Research, una empresa que asesora a los fabricantes de semiconductores inalámbricos, predice que para 2026 se alcanzará un despliegue total de Wi-Fi 6. El desarrollo de esta capacidad está avanzando rápidamente, ya que un número cada vez mayor de dispositivos convencionales están habilitados para usar la banda de 6 GHz. Esto debe tenerse en cuenta debido al rápido avance tecnológico y los efectos que esto tendrá. Zignani (2020)

En un artículo del diario El País, se destaca un problema creciente relacionado con la conectividad Wi-Fi en los hogares. A medida que más dispositivos se conectan a las redes inalámbricas, la infraestructura existente se ve sometida a una presión cada vez mayor. Además, muchos hogares y empresas aún utilizan enrutadores y puntos de acceso antiguos que no pueden manejar la cantidad de dispositivos conectados, sumando la falta de actualización de la infraestructura contribuye al problema. El País (2023)

En el ámbito de las redes inalámbricas, especialmente en entornos corporativos y de alta demanda, como los clientes de Cisco, las quejas sobre la conectividad y el rendimiento de las WLAN (Wireless Local Area Network) son una constante preocupación. A medida que aumenta la dependencia de estas redes para la comunicación, colaboración y operaciones empresariales, también lo hacen los desafíos técnicos y las expectativas de los usuarios. Uno de los problemas recurrentes es la cobertura inalámbrica insuficiente, que se manifiesta en áreas muertas donde la señal es débil o inexistente. Esto puede deberse a la ubicación subóptima de los puntos de acceso (AP) o a interferencias externas que obstaculizan la propagación de la señal. Los clientes de Cisco a menudo expresan su frustración por tener que moverse dentro de un espacio para obtener una señal sólida, lo que afecta negativamente la productividad y la experiencia del usuario. Cisco (2022)

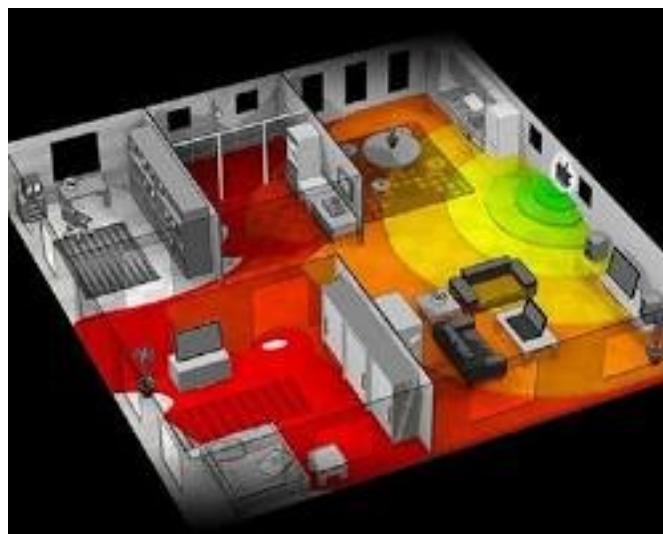


Figura 1. Quejas de Clientes en el foro de Cisco

Fuente: Cisco (2022). *Cobertura de red ineficiente*

Además de este problema, en muchos casos los usuarios optan por adquirir un nuevo punto de acceso para mejorar el medio ambiente, pero esto puede tener consecuencias negativas. La compatibilidad entre los dispositivos instalados no siempre está garantizada y también puede haber incompatibilidades a nivel de switch y VPN. Identificar y resolver estos problemas de una manera que tenga o tenga menos impacto en las operaciones requiere un sólido

conocimiento técnico en el campo de las tecnologías de la información (TI), ya sea dentro del negocio o mediante el uso de servicios tecnológicos especializados. El procesamiento lento genera, entre otras desventajas, la necesidad de retrabajo, demoras en la emisión de informes y documentos y costos adicionales relacionados con las horas extras. NapIT (2017)

A lo anterior, podemos sumar que los errores de configuración en switches, enrutadores y puntos de acceso también pueden tener un impacto negativo en la red inalámbrica, provocando, por ejemplo, ralentizaciones y caídas de conexiones. Por lo tanto, reconfigurar estos dispositivos puede ayudar a abordar los desafíos de la red. Una solución eficaz a esta situación es realizar un análisis detallado del entorno y las estructuras existentes. Con esta evaluación, resulta más fácil determinar la ubicación adecuada para conectar los elementos, evaluar los requisitos de los nuevos componentes y garantizar que sigan funcionando de manera óptima. NapIT (2017)

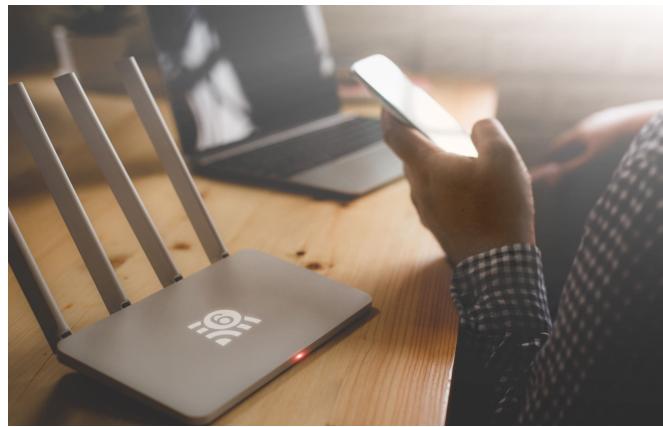


Figura 2. Problemas de uso de Access Points

Fuente: NapIT (2017). *Problema con el funcionamiento ideal del Access Point*

1.2 Formulación del Problema

Se creó un "árbol de problemas" para formular los problemas de la investigación actual. (Anexo 1: A)

1.2.1 Problema General

PG: ¿Es posible predecir las ubicaciones de Puntos de Acceso (APs) Indoor en Diferentes Planos mediante Inteligencia Artificial Generativa?

1.2.2 Problemas Específicos

- PE1: ¿Cómo se puede modelar de manera efectiva la distribución espacial de usuarios y obstáculos en un entorno interior para predecir la cobertura inalámbrica?

- PE2: ¿Qué enfoques de inteligencia artificial generativa son más adecuados para generar ubicaciones óptimas de APs en entornos interiores?
- PE3: ¿Cómo puedo encontrar una base de datos eficiente y robusta que almacene información detallada y precisa sobre la infraestructura de edificios y características de entornos indoor?
- PE4: ¿Cuáles son las métricas y metodologías de evaluación más adecuadas para medir la eficiencia y efectividad de las predicciones de ubicaciones óptimas de puntos de acceso (APs) generadas por modelos de inteligencia artificial generativa en entornos indoor?

1.3 Objetivos de la Investigación

Se creó un "árbol de objetivos" para establecer los objetivos de esta investigación. (Anexo 2: B)

1.3.1 Objetivo General

OG: Desarrollar técnicas de inteligencia artificial generativa para predecir las ubicaciones óptimas de puntos de acceso (APs) en diferentes planos de un entorno interior, con el fin de optimizar la cobertura de redes inalámbricas y mejorar la conectividad y calidad del servicio para los usuarios finales.

1.3.2 Objetivos Específicos

- OE1: Desarrollar un algoritmo que pueda simular con precisión la cobertura de redes inalámbricas en interiores
- OE2: Implementar un modelo generativo capaz de proponer automáticamente ubicaciones eficientes para los Aps
- OE3: Encontrar una base de datos eficiente y robusta que almacene información detallada sobre la infraestructura de los edificios y características de los entornos indoor.
- OE4: Desarrollar un conjunto de métricas y un marco de evaluación para medir la eficiencia y efectividad de las predicciones generadas por los modelos de inteligencia artificial generativa en la optimización de la cobertura de redes inalámbricas indoor.

1.4 Hipótesis

1.4.1 Hipótesis General

HG: La aplicación de técnicas de inteligencia artificial generativa para la predicción de la ubicación de puntos de acceso (Aps) en planes distribuidos en zonas interiores supone

una mejora significativa en la cobertura y calidad del servicio de los recursos sin datos.

1.4.2 Hipótesis Específicas

- HE1: Los algoritmos de inteligencia artificial generativa, como las GAN, se pueden utilizar para predecir con precisión la ubicación óptima de los puntos de acceso (AP) en un entorno interior.
- HE2: La combinación de datos de sensores de señales inalámbricos con datos como planos arquitectónicos mejoran la precisión y predicción de la ubicación de AP mediante inteligencia artificial generativa.
- HE3: Una base de datos bien gestionada y enriquecida con datos contextuales permitirá validar las predicciones de los modelos de IA de manera más fiable, comparando las ubicaciones sugeridas con las condiciones reales y mejorando la precisión de futuras predicciones.
- HE4: La implementación de un marco de evaluación estandarizado permitirá comparar de manera objetiva diferentes enfoques y modelos de IA, facilitando la selección de los más efectivos para optimizar la cobertura de redes inalámbricas en distintos entornos indoor.

En el Anexo 3 se observa como la Matriz de Consistencia alinea los problemas, objetivos e hipótesis mencionados anteriormente. Además, después de revisar los objetivos que se plantearon en los antecedentes, donde el detalle y referencia podemos verlo en el Anexo 5, con una lluvia de ideas se crearon los objetivos específicos .

1.5 Justificación de la Investigación

1.5.1 Teórica

Los estudios teóricos sobre la optimización de la cobertura de redes inalámbricas mediante inteligencia artificial generativa se justifican por la necesidad de desarrollar soluciones eficaces, según Nauata et al. (2021), para entornos interiores donde se requieren muchas conexiones. La aplicación de algoritmos generativos brinda la oportunidad de mejorar la precisión del posicionamiento de los puntos de acceso (AP), reducir los costos operativos y garantizar una experiencia de usuario satisfactoria al minimizar las áreas de sombra y mantener una conexión estable. Estos avances son críticos en un contexto donde la conectividad inalámbrica es esencial para la productividad y disponibilidad de servicios digitales en planos complejos.

El objetivo del estudio no es sólo mejorar la cobertura y calidad del servicio de la red inalámbrica, sino también optimizar los recursos y el gasto relacionado en infraestructura

nacional. Se espera que mapear las capacidades de la IA generativa mejore significativamente el rendimiento de la red inalámbrica, la satisfacción del usuario y la adaptabilidad en espacios donde la conectividad confiable es esencial para la vida cotidiana y los negocios, como lo menciona el antecedente de Alathari (2023).

1.5.2 Práctica

La investigación práctica sobre la optimización de la cobertura inalámbrica mediante inteligencia artificial generativa es crucial para garantizar la viabilidad y eficacia de las soluciones propuestas en entornos reales. Se pueden utilizar pruebas y experimentos prácticos para evaluar el uso de algoritmos generativos para predecir la ubicación de puntos de acceso (AP) en diferentes planos. Estos estudios proporcionan datos empíricos sobre mejoras en la cobertura, la eficiencia de los recursos y la calidad del servicio, proporcionando una base sólida para la adopción y expansión de estas tecnologías en el campo inalámbrico.

También participa en el desarrollo de herramientas y métodos aplicables a la industria de las telecomunicaciones y la gestión de redes. Trabajando con casos reales y diferentes entornos, es posible identificar desafíos específicos, optimizar algoritmos y proponer mejores prácticas para diseñar y optimizar redes inalámbricas en entornos interiores. Estos resultados son útiles para los investigadores de telecomunicaciones, pero también tienen implicaciones directas para mejorar la conectividad y la experiencia del usuario en diversos sectores, como empresas, instituciones educativas y espacios públicos.

1.5.3 Metodológica

La aplicación del modelo de inteligencia artificial generativa propuesto en este estudio ayuda a optimizar la cobertura de redes inalámbricas en ambientes interiores. Este modelo utiliza técnicas avanzadas de inteligencia artificial generativa, como las redes generativas adversarias (GAN) para predecir con precisión los puntos de acceso (AP) óptimos en diferentes niveles. La combinación de sensores de señal inalámbricos y una estructura de datos estructurados mejora significativamente la calidad del servicio y reduce los costos operativos asociados con la instalación y mantenimiento de la infraestructura de red.

Es por ello que este estudio puede proporcionar soluciones de datos efectivas, mejorar la conectividad inalámbrica en entornos interiores complejos. Al confirmar la aplicación de algoritmos generativos en el mundo real, este estudio proporciona una base sólida para la adopción y expansión de estas técnicas en la industria de las telecomunicaciones. Esto beneficia tanto a los usuarios finales, que garantizan una experiencia de usuario superior, como a las empresas, reduciendo costes y optimizando la eficiencia de las infraestructuras de redes inalámbricas.

1.6 Delimitación del Estudio

1.6.1 Espacial

Esta investigación se centra en optimizar la cobertura de la red inalámbrica en entornos interiores específicos como entornos comerciales, institucionales o residenciales. La investigación se lleva a cabo en áreas edificadas o construidas donde la conectividad inalámbrica es esencial para el funcionamiento eficiente de dispositivos y servicios.

1.6.2 Temporal

El estudio cubre los últimos cinco años desde el año en curso 2024. Esto permite el uso de información actualizada y relevante para entrenar modelos creativos de IA y evaluar su efectividad para predecir la ubicación de puntos de acceso en diferentes niveles en un ambiente interior.

1.6.3 Conceptual

Esta investigación se orientará en técnicas de inteligencia artificial generativa, como las redes generativas adversarias (GAN) para optimizar la cobertura de la red inalámbrica. Se utilizan datos de sensores de señales inalámbricas, datos de construcción (por ejemplo, planos arquitectónicos) y técnicas de procesamiento de datos para mejorar la precisión de la predicción de la ubicación de la estación base y mejorar así la calidad del servicio de las redes inalámbricas en entornos interiores.

Capítulo II: Marco Teórico

2.1 Antecedentes de la investigación

2.1.1 «Modelo de optimización para la ubicación de Access Point en redes WLAN»

Martha Contreras y Vesga (2021) publicaron el modelo de optimización «Modelo de optimización para la ubicación de Access Point en redes WLAN» para el departamento de Investigación e Innovación en Ingenierías de la Universidad Simón Bolívar.

Debido a su movilidad y bajo costo, la demanda de redes inalámbricas, particularmente WLAN, ha aumentado significativamente. Para que estas redes inalámbricas funcionen en hogares, oficinas y escuelas, los puntos de acceso (AP) son necesarios. La ubicación y densidad de los AP tienen un impacto en la cobertura y la calidad de la señal. Para mejorar la eficiencia y la cobertura de la red, este artículo propone un modelo de optimización para la ubicación de AP en interiores que utiliza el modelo de propagación Log-Normal Shadowing Path Loss.

El desarrollo del modelo de optimización incluyó una serie de pasos importantes: se utilizó el modelo de propagación Log-Normal Shadowing Path Loss para estimar el radio de cobertura y la probabilidad de corte de la señal utilizando dimensiones del escenario, frecuencia y condiciones ambientales; se implementó un pseudocódigo para calcular el radio de cobertura y la probabilidad de corte de la señal para las bandas de 2,4 GHz y 5 GHz; y se diseñó una técnica específica para determinar la ubicación óptima de los AP dentro de una construcción, considerando la probabilidad de corte, la sensibilidad de recepción y otros parámetros técnicos.

Los resultados del modelo sugerido demostraron una mejora significativa en la identificación de las áreas de cobertura y la probabilidad de corte. En particular, se descubrió que la banda de 2.4 GHz cubre un mayor área de cobertura en comparación con la banda de 5 GHz, pero también se observó que tiene una mayor probabilidad de interferencia. La técnica permitió el cálculo de los radios de cobertura apropiados y la mejora de la ubicación geográfica de los AP, lo que permitió maximizar la cobertura y reducir las zonas de silencio. Las tablas y los gráficos que muestran la relación entre la distancia y la potencia de la señal describieron los parámetros específicos para cada banda de frecuencia y tipo de entorno.

El modelo de optimización para la ubicación de puntos de acceso en redes WLAN en ambientes interiores demostró ser efectivo para aumentar la cobertura y reducir la probabilidad de corte de señal como se ilustra en la Figura 3. Los algoritmos y metodologías creados ofrecen una herramienta útil para diseñar y desplegar redes WLAN de manera eficiente. Este modelo debería ser utilizado en futuras investigaciones y aplicaciones prácticas para mejorar la calidad y el rendimiento de las redes inalámbricas, especialmente en entornos con alta densidad de

usuarios y dispositivos.

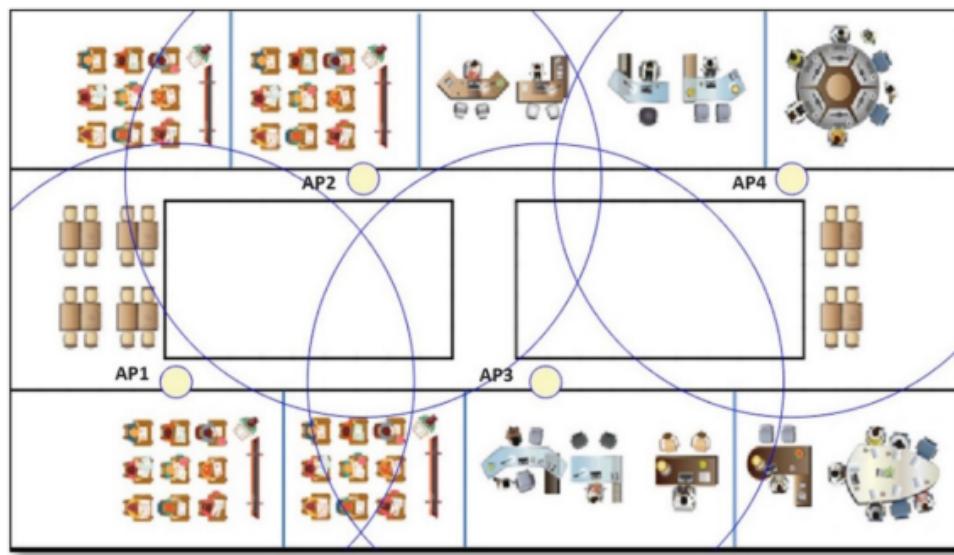


Figura 3. Diagrama de cobertura y ubicación de AP.

Fuente: Martha Contreras y Vesga (2021). «Modelo de optimización para la ubicación de Access Point en redes WLAN». (p. 14)

2.1.2 «An Optimization for Access Point Placement in Indoor Communication»

Según el acta de la conferencia "TInternational Conference on Computational Science and Technology", que se llevó a cabo en 2022, Alathari (2023) publicaron el artículo conocido como «An Optimization for Access Point Placement in Indoor Communication», «Optimización de la ubicación de puntos de acceso en comunicaciones interiores» en español.

El estudio presenta un modelo de optimización para la ubicación de puntos de acceso (AP) en redes inalámbricas. Utilizando técnicas sofisticadas de algoritmos genéticos y simulaciones de Monte Carlo, el objetivo principal es maximizar la cobertura y minimizar la interferencia. La necesidad creciente de mejorar la eficiencia de las redes inalámbricas en entornos de alta densidad es el tema de esta investigación.

La técnica utilizada consta de numerosos pasos cruciales. Primero, se recopilan datos sobre la distribución del espacio y la cobertura. Después, se utiliza un algoritmo genético para crear las ubicaciones iniciales potenciales de AP. Se utilizan simulaciones de Monte Carlo para evaluar la efectividad de estas ubicaciones en términos de cobertura y minimización de interferencia. Se siguen estos pasos hasta llegar a la configuración de AP ideal.

Comparado con las técnicas convencionales, los resultados muestran una mejora signifi-

ficativa en la cobertura de la red y una reducción en la interferencia que se puede observar en la Figura 4. Se logró aumentar la cobertura en un 25 % y disminuir la interferencia en un 15 %. Estos hallazgos se comprobaron en un entorno simulado que emulaba las condiciones de una red inalámbrica de alta densidad real.

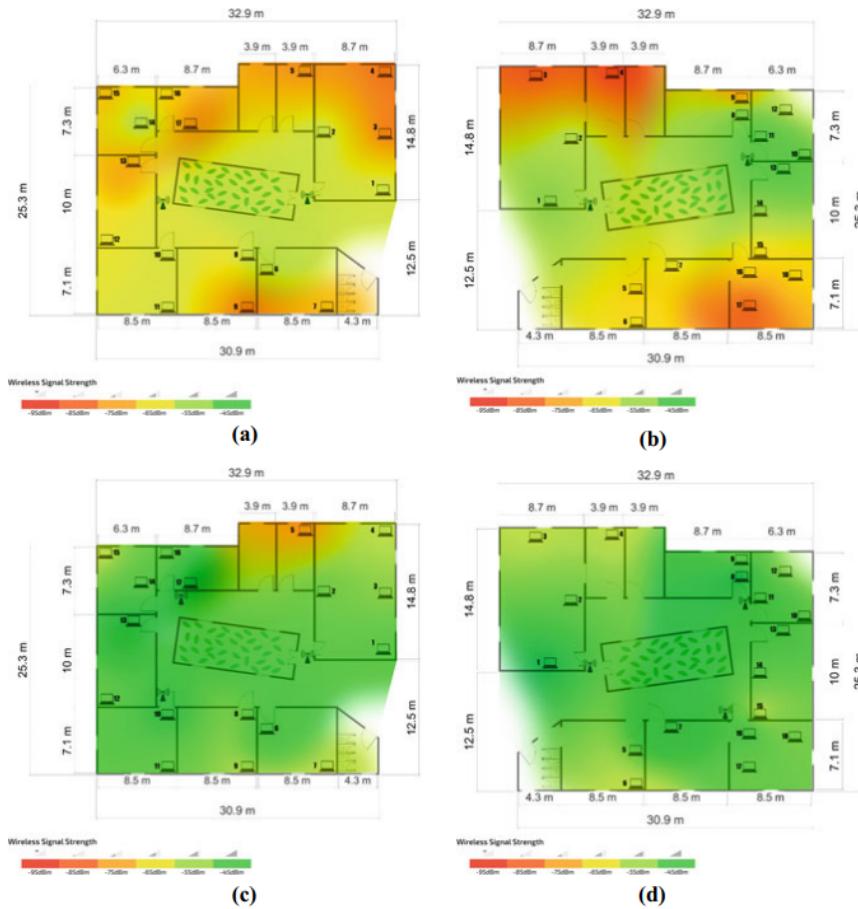


Figura 4. Un mapa de calor que describe la intensidad de la señal recibida antes y después. a Área de cobertura de la señal para los puntos de acceso de la izquierda, b Área de cobertura de la señal para los puntos de acceso de la derecha, c Área de cobertura de la señal para los puntos de acceso de la izquierda, d Área de cobertura de la señal para los puntos de acceso de la derecha.

Fuente: Alathari (2023). «An Optimization for Access Point Placement in Indoor Communication». (p. 11)

2.1.3 «Location Prediction of Rogue Access Point Based on Deep Neural Network Approach»

Ketkhaw y Thipchaksurat (2022) publicaron la investigación «Location Prediction of Rogue Access Point Based on Deep Neural Network Approach», en español "Predicción de la ubicación de puntos de acceso no autorizados basada en redes neuronales profundas", se publicó en el journal tailandés «Journal of Mobile Multimedia» en 2022.

El objetivo del estudio es desarrollar un método llamado LPRAP que utiliza redes neuronales profundas para predecir la ubicación de puntos de acceso no autorizados en redes inalámbricas locales. La detección y localización precisa de estos RAPs es esencial para garantizar la seguridad de las redes y proteger la información confidencial de posibles amenazas.

Los dos mecanismos principales del proceso LPRAP son la detección de RAPs y la predicción de su ubicación. Para determinar la intensidad de la señal recibida (RSSI) en cada subárea, se recopila un conjunto de marcos de balizas en la detección de RAP. Posteriormente, se clasifica la ubicación de los RAPs utilizando un espacio de características de 81 dimensiones. En cuanto a la predicción de ubicación, se utiliza la precisión de la predicción de ubicación para evaluar el rendimiento del esquema propuesto comparándolo con otros algoritmos de aprendizaje automático como SVM, KNN, Naive Bayes y MLP.

Los resultados del experimento muestran que LPRAP supera a todos los demás algoritmos de aprendizaje automático evaluados. La precisión de la predicción de la ubicación de los RAPs aumenta significativamente con el aumento del número de subáreas. Por ejemplo, LPRAP logra una precisión de predicción del 88,31 % para 3 subáreas, lo que demuestra su capacidad para detectar y encontrar RAPs en entornos de redes inalámbricas como se puede observar en la Figura 6.

2.1.4 «House-GAN++: Generative Adversarial Layout Refinement Network towards Intelligent Computational Agent for Professional Architects»

Nauata et al. (2021) ,en la conferencia "2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)", que tuvo lugar en Nashville, Tennessee, Estados Unidos en el año 2021, publicaron un artículo titulado «House-GAN++: Generative Adversarial Layout Refinement Network towards Intelligent Computational Agent for Professional Architects», en español se traduce como "House-GAN++: Generative Adversarial Layout Refinement Network hacia un agente computacional inteligente para arquitectos profesionales".

Para la generación automatizada de planos de planta, se sugiere una red generativa rival de refinamiento de diseño de planos de planta (House-GAN++). El sistema recibe un diagrama

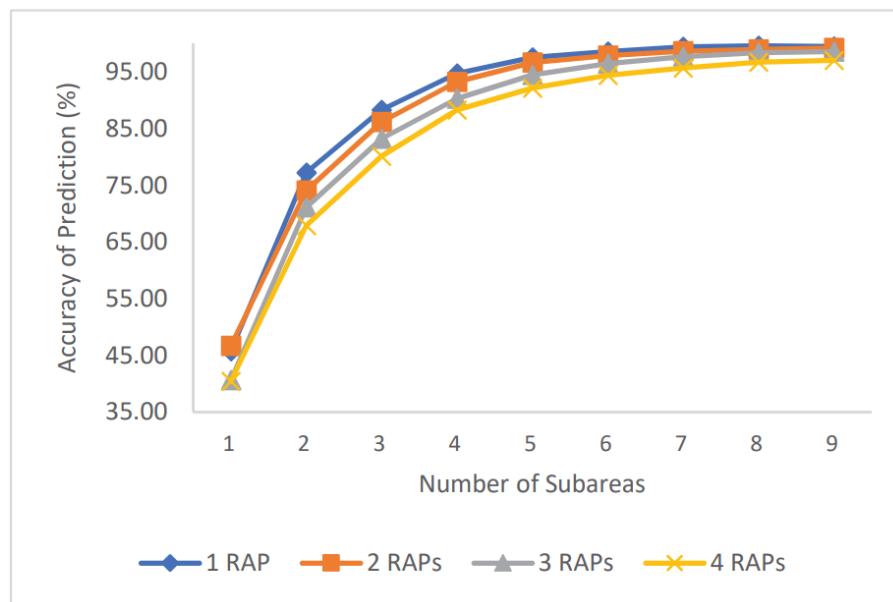


Figura 5. Precisión de la predicción en función del número de subzonas para la predicción de la ubicación de 1 a 4 RAP.

Fuente: Ketkhaw y Thipchaksurat (2022). «Location Prediction of Rogue Access Point Based on Deep Neural Network Approach». (p. 13)

de burbujas que muestra las conexiones funcionales entre las habitaciones y, como salida, crea un plano de planta realista.

Como se muestra en la Figura 7, la arquitectura sugerida integra una GAN relacional con restricciones de grafo y una GAN condicional. El generador itera el diseño antes de convertirlo en la siguiente restricción de entrada. Cada componente recibe una máscara de segmentación de la verdad fundamental con una probabilidad aleatoria durante el entrenamiento (condicionamiento GT por componente).

El sistema sugerido supera ampliamente los enfoques del estado del arte actuales en las tres métricas estándar de realismo, diversidad y compatibilidad. En un estudio de usuarios con arquitectos profesionales, el sistema obtuvo puntajes de realismo de -0.7 para los métodos comparativos y puntajes de 0.5 para el sistema propuesto en la tarea más difícil de generar planos de 8 habitaciones. Como se muestra en la Figura 8, la distancia de edición de gráficos (compatibilidad) aumenta de 11.8 para el estado del arte a 6.5 para el sistema propuesto en planos de 8 habitaciones.

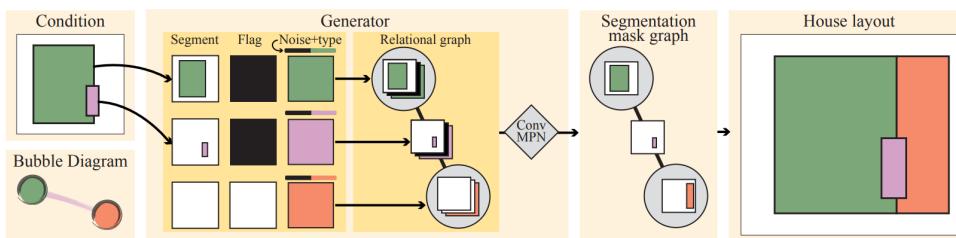


Figura 6. La arquitectura se basa en un GAN relacional. Se puede especificar una máscara de segmentación 2D adicional para cada habitación/puerta como condición de entrada, lo que permite un refinamiento iterativo del diseño.

Fuente: Nauata et al. (2021). «House-GAN++: Generative Adversarial Layout Refinement Network towards Intelligent Computational Agent for Professional Architects». (p. 3)

2.1.5 «Precise WiFi Indoor Positioning using Deep Learning Algorithms»

Cai y Lin (2023) publicaron un artículo que se llamaba «Precise WiFi Indoor Positioning using Deep Learning Algorithms», el término se traduce al español como "Posicionamiento WiFi preciso en el interior mediante algoritmos de aprendizaje profundo" para la revista científica «ArXiv:2307.02011v» publicada en 2023.

Este artículo presenta una nueva estrategia para el posicionamiento en interiores que emplea tecnología WiFi. Para mejorar la precisión del posicionamiento en comparación con el enfoque tradicional basado únicamente en RSSI, se recomienda utilizar una combinación de mediciones de la Intensidad de la Señal Recibida (RSSI) y el Ángulo de Llegada (AoA).

La metodología se compone de tres pasos principales: 1) Usando puntos de referencia, crear modelos de posicionamiento basados en RSSI y el método híbrido RSSI-AoA; 2) Entrenar los modelos utilizando varios algoritmos de aprendizaje profundo, como BPNN, RBF y CNN; 3) Probar el rendimiento de los modelos y calcular los errores en tres entornos de prueba diferentes: un salón de clases grande, un salón de clases pequeño y un salón de clases pasillo.

Independientemente del algoritmo de aprendizaje profundo utilizado y del entorno de prueba, los resultados muestran que el método híbrido RSSI-AoA tiene un error medio absoluto (MAE) más pequeño que el método basado únicamente en RSSI. Por ejemplo, el MAE del método híbrido con CNN es inferior a 300 mm en un salón de clases grande, mientras que el MAE del método basado en RSSI con CNN es inferior a 400 mm. Como se muestra en la Figura 9, el algoritmo CNN supera a BPNN y RBF en ambos modelos de posicionamiento.

Model	Realism (\uparrow)		Diversity (\downarrow)			Compatibility (\downarrow)			
	8	5	6	7	8	5	6	7	8
Ashual <i>et al.</i> [2]	-0.7	120.6±0.5	172.5±0.2	162.1±0.4	183.0±0.4	7.5±0.0	9.2±0.0	10.0±0.0	11.8±0.0
Johnson <i>et al.</i> [14]	-0.7	167.2±0.3	168.4±0.4	186.0±0.4	186.0±0.4	7.7±0.0	6.5±0.0	10.2±0.0	11.3±0.1
House-GAN [24]	0.0	37.5±1.1	41.0±0.6	32.9±1.2	66.4±1.7	2.5±0.1	2.4±0.1	3.2±0.0	5.3±0.0
Ours ^{50%} _{heur}	0.2	30.4±4.4	37.6±3.0	27.3±4.9	32.9±4.9	1.9±0.3	2.2±0.3	2.4±0.3	3.9±0.5

Figura 7. Evaluación del realismo. Se muestra un diseño generado para cada diagrama de burbujas de entrada.

Fuente: Nauata et al. (2021). «House-GAN++: Generative Adversarial Layout Refinement Network towards Intelligent Computational Agent for Professional Architects». (p. 6)

2.1.6 «NSGA-II based optimal Wi-Fi access point placement for indoor positioning: A BIM-based RSS prediction»

En el año 2023, la revista “Automation in Construction” publicó Hosseini et al. (2023) publicaron el artículo conocido como «NSGA-II based optimal Wi-Fi access point placement for indoor positioning: A BIM-based RSS prediction», “Ubicación óptima de puntos de acceso Wi-Fi basada en NSGA-II para posicionamiento interior: una predicción RSS basada en BIM”, según su traducción al español.

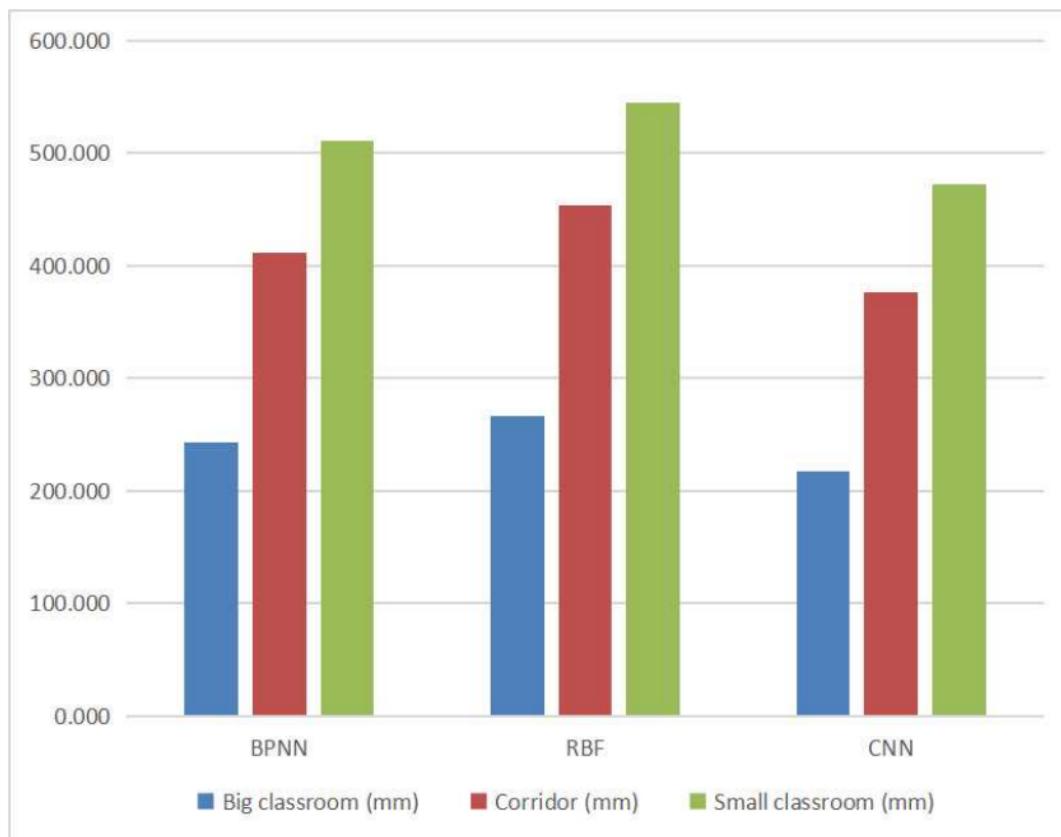


Figura 8. Los MAE del modelo híbrido de posicionamiento.

Fuente: Cai y Lin (2023). «Precise WiFi Indoor Positioning using Deep Learning Algorithms». (p. 26)

Este artículo presenta un método para optimizar la colocación de puntos de acceso Wi-Fi (AP) en interiores utilizando un modelo de propagación de señal calibrado y un algoritmo genético multiobjetivo (NSGA-II).

La técnica consta de varias etapas: 1) Voxelización del modelo BIM del edificio, 2) Muestreo de intensidad de señal recibida (RSS) en puntos de control y verificación, 3) Calibrar el modelo de propagación de señal mediante el método de cuadrados mínimos, 4) Creación de huellas digitales virtuales 3D y 5) Uso de NSGA-II para optimizar la ubicación de los AP Wi-Fi.

Los resultados demuestran que el método sugerido puede reducir significativamente el número de AP Wi-Fi necesarios sin sacrificar la precisión de la ubicación. La mejor solución encontrada tenía 4 APs y 13 APs, respectivamente, con una mejora en la precisión del posicionamiento del 35.54 % y 44.82 % en comparación con la distribución actual de 6 APs, como se muestra en la Figura 10.

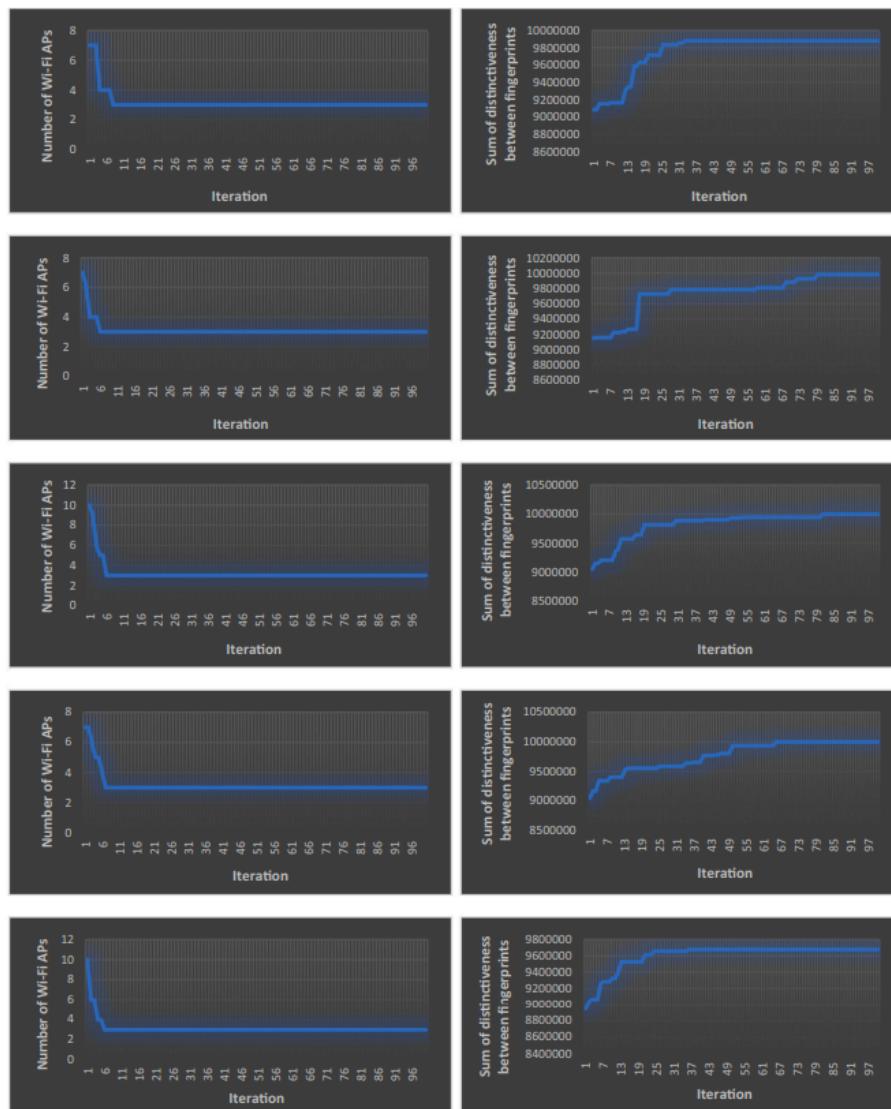


Figura 9. Los resultados de la evaluación de la convergencia del NSGA-II.

Fuente: Hosseini et al. (2023). «NSGA-II based optimal Wi-Fi access point placement for indoor positioning: A BIM-based RSS prediction». (p. 16)

2.1.7 «3D coverage location modeling of Wi-Fi access point placement in indoor environment»

En noviembre del 2015, en la publicación "Computers, Environment and Urban Systems", Lee (2015) publicaron un artículo que se llamaba «3D coverage location modeling of Wi-Fi access point placement in indoor environment», "Modelización 3D de la ubicación de puntos de acceso Wi-Fi en interiores.^{en} español.

Este documento presenta un modelo de optimización para la ubicación de puntos de acceso (AP) Wi-Fi en un entorno interior de múltiples pisos con el objetivo de maximizar la

cobertura de la señal. El modelo utiliza el modelo de sombra log-normal para considerar la atenuación de la señal en tres dimensiones. Esto permite una representación más precisa de la cobertura de la señal en comparación con los métodos tradicionales en dos dimensiones.

El artículo aborda los siguientes puntos importantes: Para estimar la atenuación de la señal en 3D, se define un modelo de propagación de señal log-normal en sombra. El problema de ubicación de AP se identificó como un problema de cobertura de señal máxima (MSCLP), Resolver el MSCLP utilizando un algoritmo de optimización para encontrar las ubicaciones de AP ideales, y finalmente, utilizando esferas que representan la fuerza de la señal en los puntos de demanda para visualizar la cobertura 3D resultante.

El modelo sugerido indica que las ubicaciones de AP ideales se encuentran en varios pisos, con el 70 % de las ubicaciones en los pisos centrales tercero y cuarto. Se logra una cobertura del 98.81 % de los puntos de demanda para una solución con 10 AP sin restricción de capacidad. A medida que se agregan más AP, la fuerza de señal promedio aumenta, pero la tasa de aumento disminuye. La solución propuesta con el mismo número de AP cubre significativamente más puntos de demanda que la solución actual de 117 AP en el edificio de prueba (77.61 % en comparación con 54.63 %). Según el modelo, solo se necesitarían 21 AP sin restricción de capacidad para una cobertura completa, como se muestra en la Figura 11.

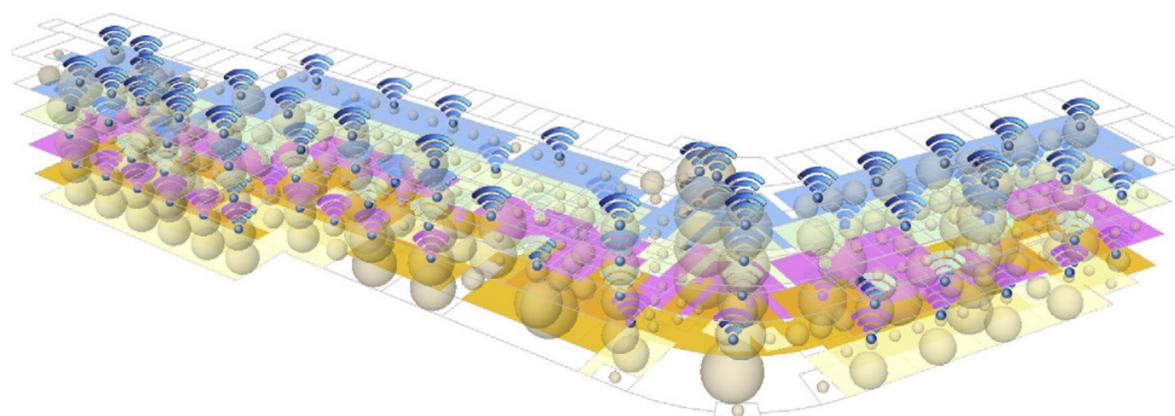


Figura 10. Colocación óptima de AP capacitados con demandas ponderadas ($p = 117$).

Fuente: Lee (2015). «3D coverage location modeling of Wi-Fi access point placement in indoor environment». (p. 9)

2.1.8 Generating Mass Housing Plans Through Gans - A Case in Toki, Turkey

En marzo de 2023, en la revista científica "Architecture and Planning Journal (APJ)", Özerol y Arslan (2023) publicaron el artículo conocido como *Generating Mass Housing Plans*

Through Gans - A Case in Toki, Turkey, en español, esto se traduce como “Creación de planes de vivienda colectiva a través de Gans - Un caso en Tokio, Turquía”.

El estudio investigó la capacidad de Generative Adversarial Neural Networks (GAN) para crear dibujos arquitectónicos de proyectos de vivienda masiva de TOKI utilizando conjuntos de datos. El objetivo principal fue capacitar al algoritmo HouseGAN para crear tipologías de planos de TOKI actuales y diagramas de burbujas.

En el artículo se explica cómo se multiplicaron planos correlacionados espacialmente con la configuración RGB de 21 tipologías de planos para obtener 157 conjuntos de datos de planos. Estos datos se utilizaron para entrenar al algoritmo de deep learning HouseGAN, que generó imágenes de fondo realistas como salidas del proceso de entrenamiento. El estudio siguió los siguientes pasos: Los diseños arquitectónicos de los proyectos de vivienda masiva de TOKI se utilizaron como conjuntos de datos. Después, se multiplicaron los planos para obtener 157 conjuntos de datos de planos, que se correlacionaron espacialmente con la configuración RGB de 21 tipologías de planos. Posteriormente, se empleó el conjunto de datos generado para entrenar a HouseGAN. Finalmente, los resultados del entrenamiento se convirtieron en imágenes de fondo realistas.

La investigación reveló que la planificación del diseño espacial del algoritmo HouseGAN proporciona diagramas de burbujas y tipologías de planos de TOKI actuales. Como se muestra en la Figura 12, este método permitió crear planos arquitectónicos útiles y realistas para el desarrollo de proyectos de vivienda masiva.

2.1.9 «Building-GAN: Graph-Conditioned Architectural Volumetric Design Generation»

En abril del 2021, en la revista científica “arXiv”, Chang et al. (2021) publicaron el artículo conocido como «Building-GAN: Graph-Conditioned Architectural Volumetric Design Generation», el título ”Building-GAN: generación de diseños arquitectónicos volumétricos condicionados por grafos” se traduce al español.

Para mejorar la eficiencia en el diseño volumétrico de edificios en la industria de la arquitectura y la construcción, este artículo presenta un enfoque innovador llamado Building-GAN. Para visualizar los diseños arquitectónicos, se introduce un grafo de voxels tridimensional, así como un generador que incorpora un módulo de punteros cruzados para conectar el grafo de programas y el grafo de voxels.

El artículo detalla los pasos que se deben seguir para crear el modelo Building-GAN. Comienza con la recopilación de datos, que produce un conjunto de datos sintéticos que incluye 120,000 diseños volumétricos de edificios comerciales. Luego se implementa un Grafo Neural Generativo (GNN) de voxels y se crea un grafo de programas jerárquico. Un módulo cruzado

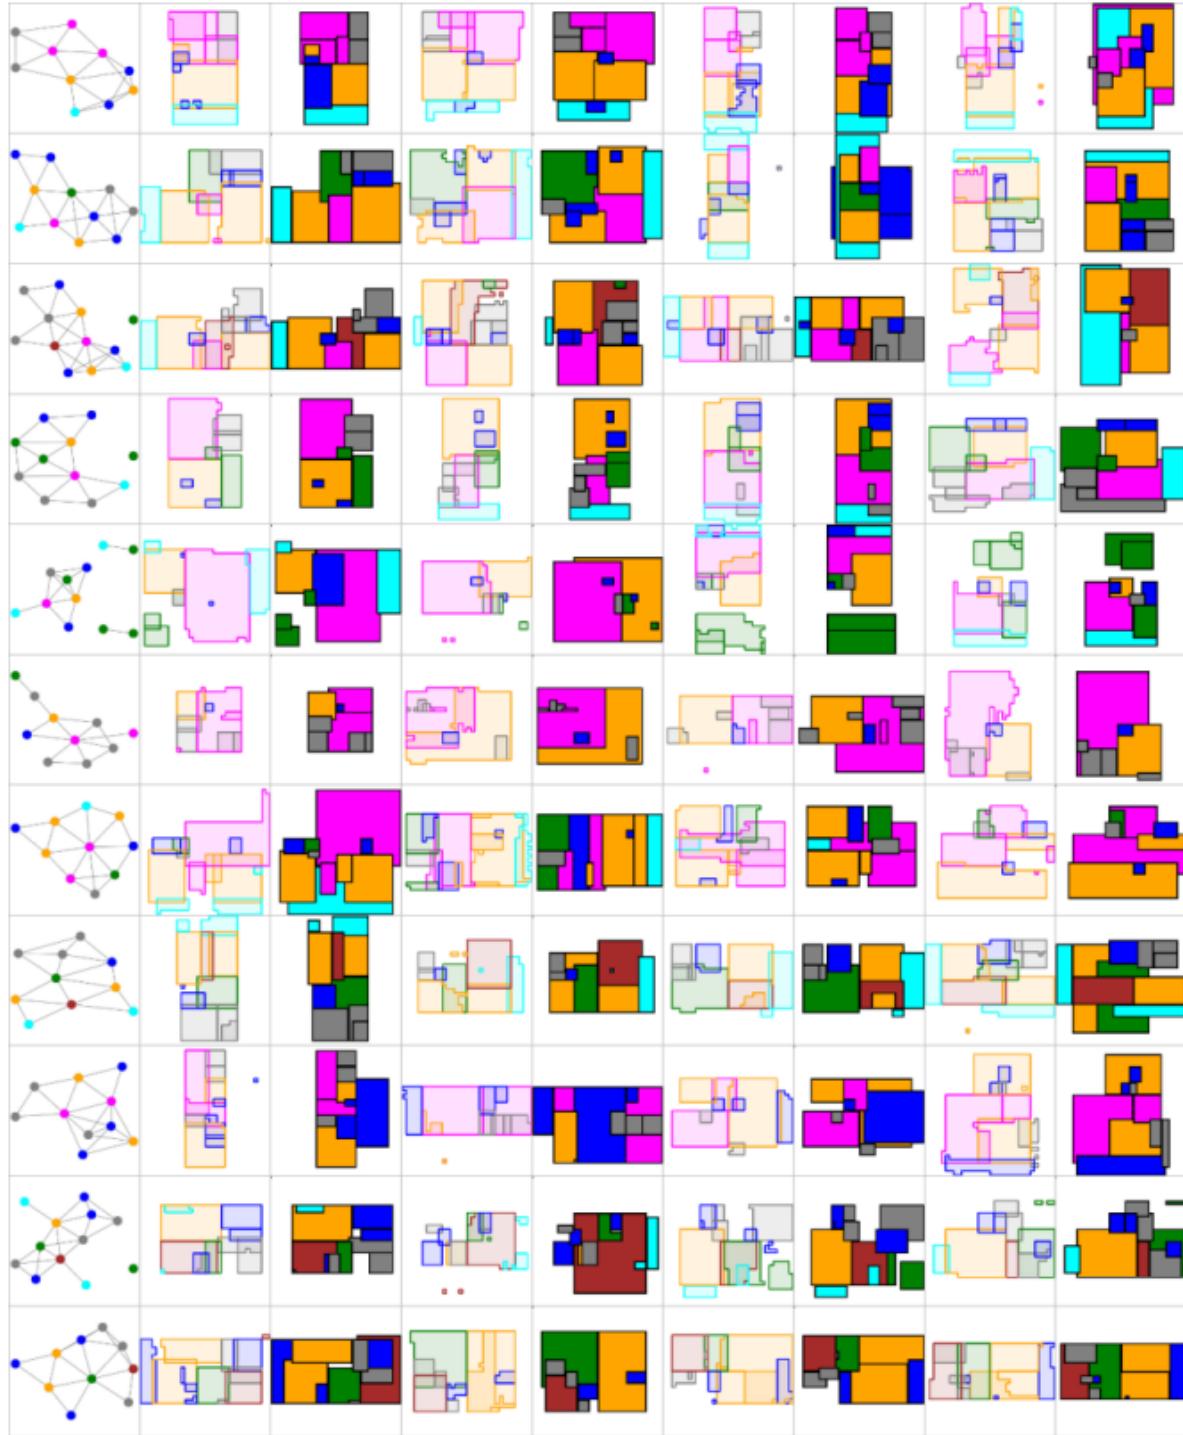


Figura 11. HouseGAN con LIFULL HOMES Datasets, imágenes generadas por los autores.

Fuente: Özerol y Arslan (2023). *Generating Mass Housing Plans Through Gans - A Case in Toki, Turkey.* (p. 10)

basado en punteros también se agrega para conectar los grafos de programas y los voxels.

Los resultados muestran que el modelo propuesto supera significativamente al método anterior, House-GAN, en un estudio de usuarios con 20 arquitectos profesionales, con una puntuación promedio de 0.85 y 0.92, respectivamente. Además, el modelo propuesto obtiene una puntuación promedio de 0.37 en comparación con el modelo Ground Truth, lo que indica que los arquitectos a menudo no pueden distinguir claramente entre el modelo Ground Truth y el modelo propuesto, como se muestra en la Figura 13.

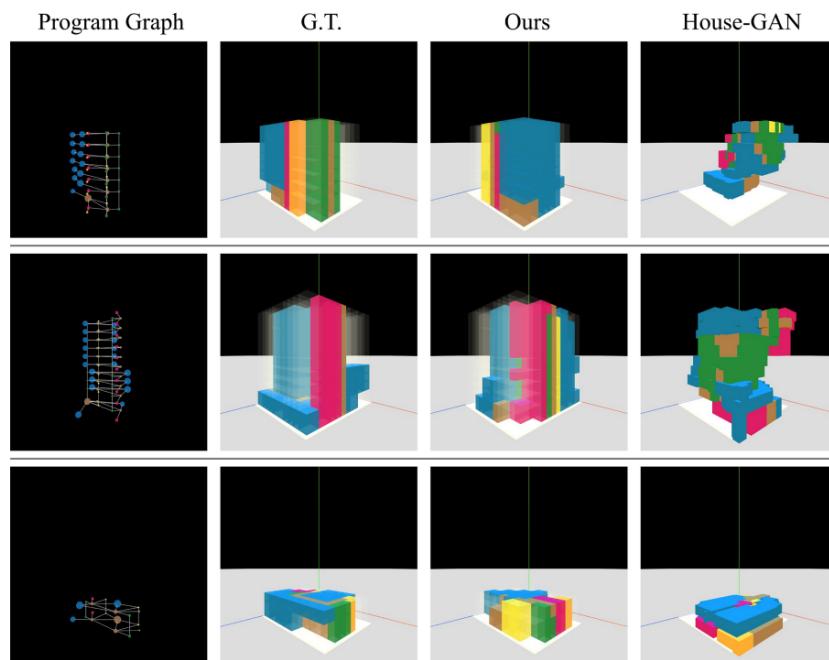


Figura 12. Para cada gráfico de programa, se generan diseños volumétricos mediante nuestro modelo y mediante House-GAN.

Fuente: Chang et al. (2021). «Building-GAN: Graph-Conditioned Architectural Volumetric Design Generation». (p. 7)

2.1.10 «Intelligent Home 3D: Automatic 3D-House Design from Linguistic Descriptions Only»

Chen et al. (2020) publicaron un artículo que se llamaba «Intelligent Home 3D: Automatic 3D-House Design from Linguistic Descriptions Only», en español, se ha traducido como “Inteligente Casa 3D: Diseño automático de casas en 3D solo a partir de descripciones lingüísticas” para la revista científica ^arXiv.^{en} 2020.

Este artículo presenta un modelo generativo que utiliza descripciones lingüísticas para diseñar automáticamente planos de casas en tres dimensiones. Dos tareas principales componen

el proceso: generar el plano de la planta y la síntesis de las texturas internas.

Los siguientes son los pasos que componen la metodología: representar las descripciones lingüísticas en un grafo estructural utilizando un analizador de escenas de Stanford, utilizando una red neuronal condicional de grafos (GC-LPN) para crear un diseño de planta grueso. Refinar el diseño grueso para crear un plano que incluya puertas y ventanas, Usando una red generativa adversaria condicional a lenguaje (LCT-GAN), se pueden sintetizar las texturas interiores de cada habitación. crear y mostrar la escena 3D completa a partir del plano con texturas.

Los hallazgos indican que el 39,41 % de los diseños creados por el modelo no se distingúan de los creados por humanos en un estudio en el que participaron 20 personas. Además, en evaluaciones cuantitativas, el modelo obtuvo un puntaje de IoU de 0,4765 para la generación de planos y un FID de 27,32 para la síntesis de texturas.

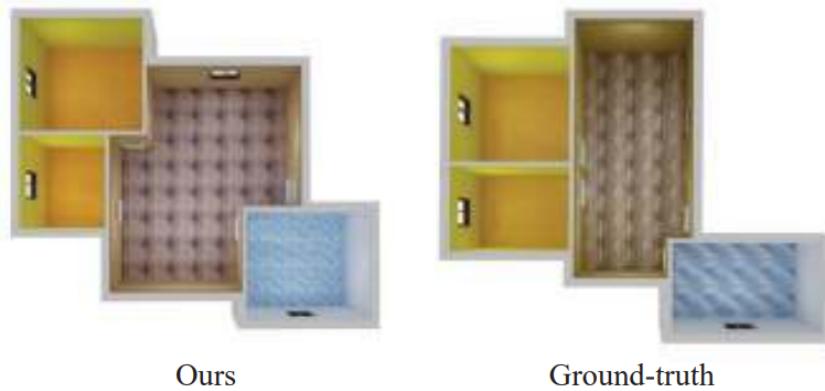


Figura 13. Comparación de nuestros planos de casas en 3D generados con sus contrapartes reales (hechas por humanos).

Fuente: Chen et al. (2020). «Intelligent Home 3D: Automatic 3D-House Design from Linguistic Descriptions Only». (p. 8)

2.1.11 «Research on Wireless Network Coverage for Transformation and Upgrading of Exhibition Management with Artificial Intelligence Technology»

Dou y Zheng (2023) publicaron un artículo que se llamaba «Research on Wireless Network Coverage for Transformation and Upgrading of Exhibition Management with Artificial Intelligence Technology», Investigación sobre cobertura de red inalámbrica para la transformación y actualización de la gestión expositiva con tecnología de inteligencia artificial”, según la revista académica internacional ”Matemáticas aplicadas y ciencias no lineales.” en junio de 2023.

El rápido crecimiento de la inteligencia artificial y la tecnología de comunicación moderna ofrece una oportunidad poderosa para transformar, actualizar y desarrollar una gestión de exposiciones de alta calidad. Sin embargo, es necesario abordar el problema de la cobertura ideal de la red inalámbrica en el área de exposición. Se ha introducido un nuevo algoritmo de inteligencia artificial basado en la optimización de Harris Hawk (HHO) para abordar este problema.

El artículo resuelve el problema de cobertura de la red inalámbrica utilizando un método de optimización multiobjetivo. Primero, el problema de la cobertura se plantea como una función de objetivo que busca maximizar la cobertura y minimizar la redundancia. Como se muestra en la Figura 14, se resuelve este problema utilizando el algoritmo de optimización de Harris Hawk mejorado (IHHO). El IHHO permite una búsqueda eficiente del espacio de soluciones al simular el comportamiento de los halcones de Harris al cazar presas. Además, para inicializar la población, se utiliza un muestreo de hipercubo latino, lo que mejora la diversidad de la población inicial y reduce la probabilidad de convergencia prematura.

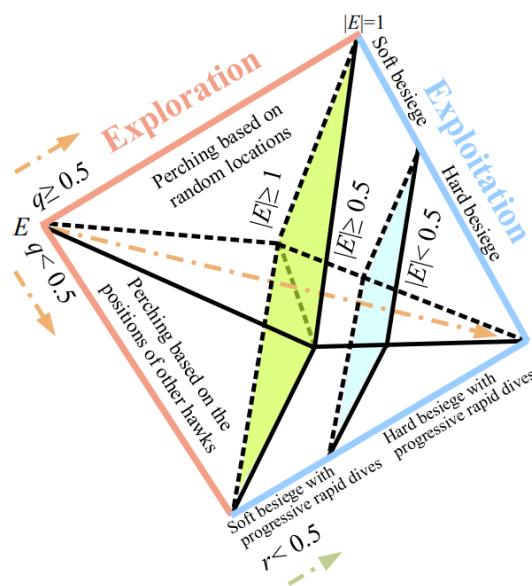


Figura 14. Estructura de HHO.

Fuente: Dou y Zheng (2023). «Research on Wireless Network Coverage for Transformation and Upgrading of Exhibition Management with Artificial Intelligence Technology». (p. 5)

Como se muestra en la Figura 15, los resultados de la simulación muestran que el algoritmo de optimización tiene un índice de evaluación integral del 98,03 %, que es superior al del optimizador de enjambre de partículas (PSO) y al algoritmo HHO estándar. Esto demuestra que el algoritmo IHHO sugerido es efectivo para resolver los problemas de cobertura de la red inalámbrica y mejora la cobertura de los nodos más que los métodos de optimización

convencionales.

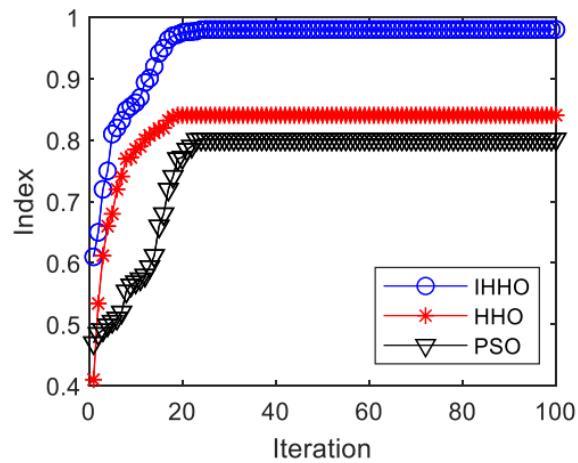


Figura 15. Comparaciones entre los métodos.

Fuente: Dou y Zheng (2023). «Research on Wireless Network Coverage for Transformation and Upgrading of Exhibition Management with Artificial Intelligence Technology». (p. 11)

2.2 Bases Teóricas

2.2.1 Inteligencia Artificial

El método racional combina la ingeniería y las matemáticas en base a las "leyes del pensamiento", que se remontan a la antigua Grecia y son influenciadas por filósofos como Aristóteles. Se desarrollaron programas capaces de resolver problemas de lógica en el siglo XIX. Por lo tanto, el objetivo de la inteligencia artificial en el mundo real es desarrollar sistemas inteligentes que tengan estas capacidades. Incluso cuando hay incertidumbre, un ^agente racional^actúa para lograr el mejor resultado posible. La inteligencia artificial se basa en una variedad de ciencias, como la ingeniería computacional, la teoría de control, la cibernetica, la lingüística, la filosofía, la economía, la psicología, la neurociencia y las matemáticas, según (Russell & Norvig, 2004).

Dos investigadores en neurociencia crearon el primer modelo de IA basado en neuronas artificiales en 1943, dando inicio al análisis de la inteligencia artificial. Warren McCulloch y Walter Pitts idearon un modelo que permitía que las neuronas fueran ^activadas^o "desactivadas", lo que demostró que una red de neuronas era capaz de realizar cualquier tarea computacional. Posteriormente, Donald Hebb propuso la regla de aprendizaje hebbiano". John McCarthy, Allen Newell y Herbert Simon desarrollaron un programa capaz de pensar de forma no numérica en el taller de Dartmouth, aunque no se publicó. El término "Inteligencia Artificial" fue acuñado por McCarthy, (Russell & Norvig, 2004).

La IA comenzó a entrar en la industria en los años 80, especialmente en grandes empresas de países desarrollados, a través de la investigación en sistemas expertos y el desarrollo de computadoras más poderosas.

2.2.2 Aprendizaje Automático

El aprendizaje automático es una rama de la inteligencia artificial que se centra en técnicas que permiten a las computadoras aprender mediante algoritmos, transformando muestras de datos en programas sin necesidad de programación explícita. (Russell & Norvig, 2009) describen el aprendizaje automático como una rama de la inteligencia artificial. Estos algoritmos utilizan tecnologías como el procesamiento del lenguaje natural, el aprendizaje profundo y las redes neuronales. Ambos tipos de aprendizaje, supervisado y no supervisado, se basan en lecciones derivadas de datos. El desarrollo de algoritmos que puedan recibir datos de entrada y utilizar análisis estadístico para predecir una salida, que cambia a medida que se adquieren nuevos datos, es la base del aprendizaje automático. (Alpaydin, 2014)

Se puede clasificar en cuatro tipos principales de la siguiente manera según el objetivo que se desea alcanzar mediante el uso de ML:

- **Aprendizaje supervisado:** El aprendizaje supervisado se ganó su nombre porque los científicos de datos actúan como una guía para enseñarle al algoritmo las conclusiones a las que debe llegar. Es similar a la forma en que un estudiante aprende aritmética básica de un maestro. Este tipo de aprendizaje requiere datos etiquetados con las respuestas correctas que se esperan del resultado del algoritmo. Para problemas de clasificación y regresión, el aprendizaje supervisado demostró ser preciso y rápido según (Zambrano, 2018).

Los dos tipos de aprendizaje supervisado son:

- **La Clasificación:** es la predicción del valor categórico de salida que permite dividir los datos en clases específicas. La clasificación se puede usar para varios propósitos, como determinar el clima, determinar si un correo electrónico es spam o no o identificar tipos de animales después de recibir una educación adecuada, un conjunto de datos con etiquetas de imágenes que incluyen la especie y algunas identificaciones características, según (Zambrano, 2018).
- **La Regresión:** es un tipo de problema en el que la predicción de un valor de respuesta continua es necesaria, como los precios de las acciones y la vivienda, según (Zambrano, 2018).

Por lo tanto, funciona modelando las relaciones y dependencias entre las características de entrada y la salida de predicción objetivo, lo que permite predecir los valores de salida para nuevos datos utilizando las relaciones que aprendió de conjuntos de datos anteriores, según (Alpaydin, 2014).

- **Aprendizaje no supervisado:** Por otro lado, el aprendizaje no supervisado se asemeja más a lo que algunos expertos llaman inteligencia artificial real: la idea de que una máquina puede aprender a identificar patrones y procesos complejos sin la supervisión de humanos. Cuando los expertos no saben qué buscar en los datos y los datos en sí no incluyen objetivos, este método es particularmente útil. La agrupación de k-means, el análisis de componentes principales e independientes y las reglas de asociación según (Zambrano, 2018) son algunos de los muchos casos de uso del aprendizaje automático no supervisado.

- **Agrupación K-means:** es un tipo de problema en el que cosas similares están agrupadas, como se muestra en la Figura 16. Comparte el mismo concepto con la clasificación, pero no se proporcionan etiquetas, por lo que el sistema entenderá los datos y los agrupará. Un uso de esto sería agrupar los artículos y las noticias según su género y contenido, según (Sancho Caparrini, 2018)

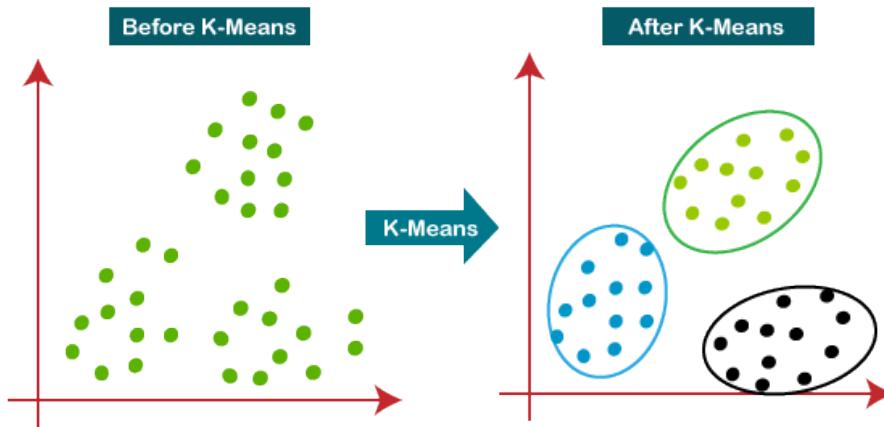


Figura 16. El algoritmo de K medias.

Fuente: Sancho Caparrini (2018). *Clasificación Supervisada y No Supervisada*.

Debido a su complejidad y dificultad de implementación, este tipo de aprendizaje automático no se utiliza tan frecuentemente como el aprendizaje supervisado, a pesar de que abre las puertas a la resolución de problemas que los humanos normalmente no abordarían, según (Sancho Caparrini, 2018)

- **Aprendizaje semisupervisado:** Hasta el momento, todos los datos enviados han sido etiquetados con el resultado deseado o no han sido etiquetados en absoluto. El aprendizaje automático semisupervisado utiliza ambos. El costo de etiquetar es bastante alto en muchas situaciones prácticas y, en el caso de grandes conjuntos de datos, se vuelve aburrido y requiere mucho tiempo. Además, proporcionar demasiados datos etiquetados puede hacer que el modelo tenga sesgos humanos. A pesar de que los datos sin etiquetar son desconocidos para la red, ofrecen información útil sobre los parámetros del grupo objetivo. que conduce a la conclusión de que se puede mejorar la precisión del modelo al incluir datos sin etiquetar y, al mismo tiempo, ahorrar tiempo y dinero en su construcción. Por ejemplo, la clasificación de páginas web, el reconocimiento de voz o la secuenciación genética pueden usar aprendizaje automático semisupervisado. En esos casos, los científicos de datos pueden acceder a grandes cantidades de datos sin etiquetarlos, y la tarea de etiquetarlos todos llevaría mucho tiempo, según (Zambrano, 2018).

Se puede comparar estos tres tipos de aprendizaje automático para el mismo uso, como clasificación, utilizando los datos recopilados hasta ahora:

- **Clasificación supervisada:** el algoritmo clasificará los tipos de páginas web según las etiquetas proporcionadas desde el principio, según (Zambrano, 2018).
- **Agrupación no supervisada:** el algoritmo buscará patrones y características que ayudan a agrupar páginas web en grupos, según (Zambrano, 2018).

- **Clasificación semi no supervisada:** identificará varios grupos de páginas web utilizando los datos etiquetados, luego utilizará los datos no etiquetados para establecer los límites de esos grupos de páginas web y buscar otros tipos que posiblemente no aparezcan en los datos etiquetados, según (Zambrano, 2018).
- **Aprendizaje por refuerzo:** junto con el aprendizaje supervisado y no supervisado, es el aprendizaje por refuerzo. Como se muestra en la Figura 17, se compone de cinco componentes principales: el agente, el entorno, el estado, la acción y la recompensa. Utilizando su interacción con el entorno, RL busca maximizar la recompensa y reducir el riesgo. El algoritmo RL (también conocido como agente) mejorará el entorno a intervalos regulares experimentando varios estados potenciales. Los agentes seleccionarán automáticamente el comportamiento ideal para maximizar el rendimiento. La retroalimentación, también conocida como recompensa, es lo que permite al agente mejorar su comportamiento, según (Sutton & Barto, 2018).

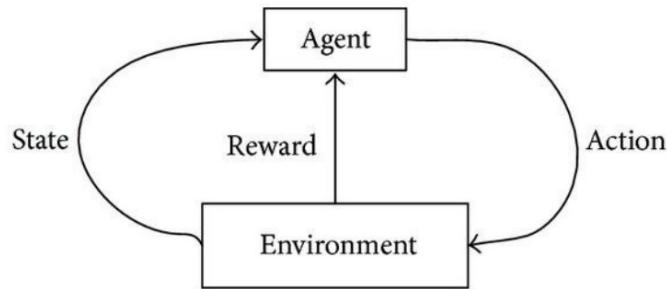


Figura 17. Características del Aprendizaje por Refuerzo.

Fuente: Sutton y Barto (2018). *Finite Markov Decision Processes*. (p. 48)

2.2.3 Aprendizaje Profundo

Desde que llegó la Inteligencia Artificial hace un tiempo, tiene una amplia gama de aplicaciones y se divide en muchas ramas, como se menciona en (SAS Institute, s.f.). El aprendizaje profundo es un subconjunto del aprendizaje automático, que es en sí mismo un subcampo de la IA. La Figura 18 es una representación visual de la relación entre AI, ML y DL.

El aprendizaje profundo no solo permite representar datos de la manera correcta, sino que también permite que la computadora aprenda programas informáticos de varios pasos al incluir el concepto de profundidad en sus modelos. Como se muestra en la Figura 19, cada capa de representación puede interpretarse como el estado de la memoria de la computadora. Las computadoras interpretan las imágenes como una colección de valores de píxeles que representan escenas de nuestra realidad. Según (House of Bots, 2018), identificar un objeto o mapear

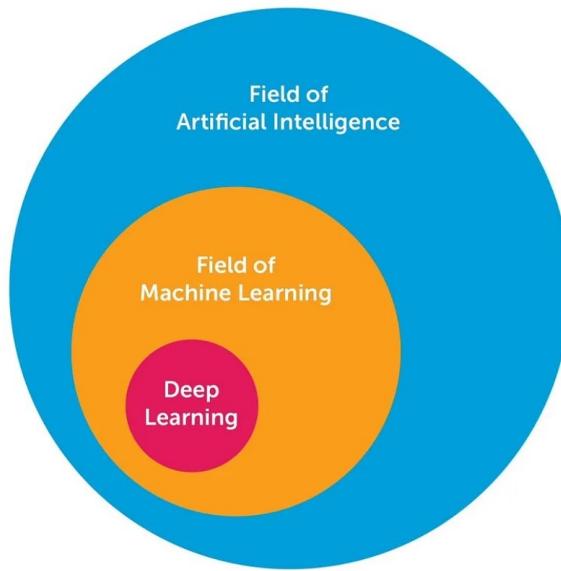


Figura 18. Relación entre IA, ML y DL.

Fuente: House of Bots (2018). *Most Popular 20 Free Online Courses to Learn Deep Learning*.

su identidad a partir de esos valores es una tarea difícil para las máquinas y puede resultar casi imposible cuando se intenta aprender este mapeo directamente.

2.2.4 Aprendizaje Profundo Multimodal

Como se muestra en la Figura 19, el fundamento del aprendizaje profundo multimodal es la integración de diversas modalidades a través del uso de redes neuronales profundas. (Deng & Liu, 2018).

Baheti (2020) afirman que el uso de modelos multimodales mejora el rendimiento de las redes neuronales y permite una extracción más efectiva de características, lo que favorece predicciones mayores. Uno de las ventajas es que los datos de diferentes fuentes ofrecen información complementaria que revela patrones ocultos que no se pueden ver cuando las modalidades se analizan individualmente, mejorando así la precisión de las predicciones.

2.2.5 Inteligencia Artificial Generativa

La inteligencia artificial generativa es el campo de la ciencia que estudia cómo crear inteligencia totalmente automatizada. Esto contrasta con el campo de la inteligencia artificial moderna, que investiga cómo los humanos comprenden y construyen la inteligencia. La construcción manual es lo que hacen los investigadores, pero la parte "por humanos" de la definición

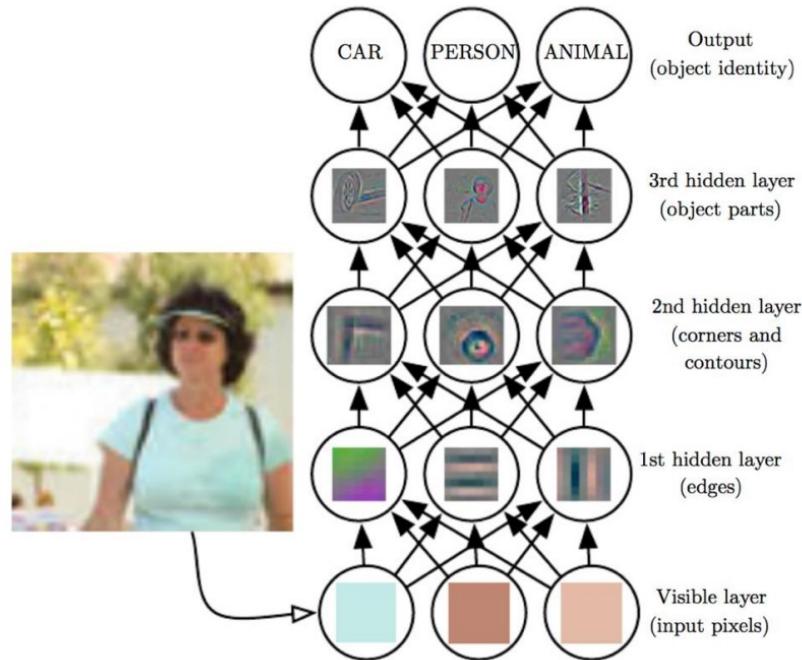


Figura 19. Modelo de aprendizaje profundo.

Fuente: House of Bots (2018). *Most Popular 20 Free Online Courses to Learn Deep Learning*.

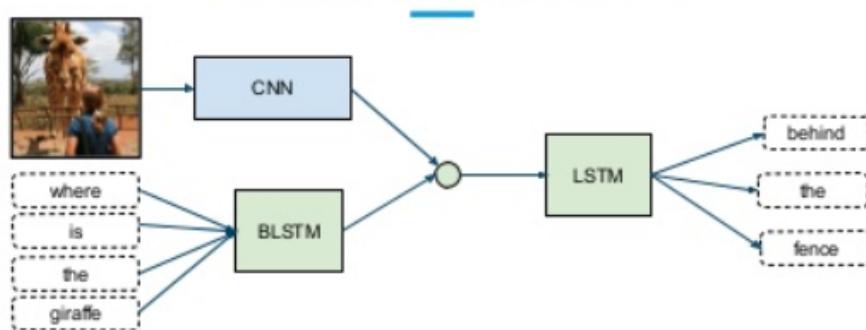


Figura 20. Modelo que combina imágenes y texto.

Fuente: Nishida y Nakayama (2015). *Multimodal gesture recognition using multi-stream recurrent neural network*.

de IA suele ser una variable oculta en la construcción de los sistemas de IA contemporáneos. Aunque la diferencia puede parecer sutil, incluso innecesaria, la construcción automatizada requiere una perspectiva completamente nueva, que no está disponible en la literatura sobre IA actual. No importa si los humanos comprenden cómo funcionan los mecanismos internos de

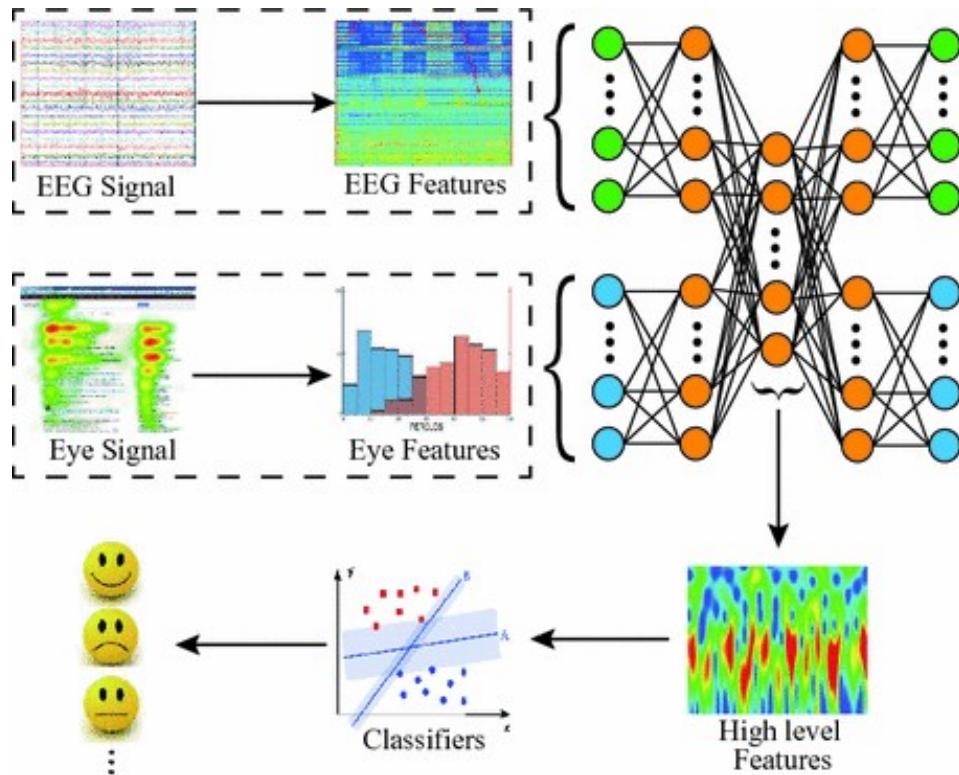


Figura 21. Un modelo multimodal para las señales de la vista.

Fuente: Baheti (2020). «Introduction to Multimodal Deep Learning».

una máquina en la Inteligencia Artificial Generativa, aunque podría ayudar a los investigadores en su búsqueda de la creación de máquinas inteligentes. Lo que importa es que la máquina pueda controlar y dirigir el proceso de creación de estructuras internas en la dirección deseada. Es como criar hijos: los seres humanos no son conscientes de los procesos mentales, pero interactúan con sus hijos en un nivel diferente al hablar de sus sustratos neuronales. En lugar de eso, utilizan una variedad de máquinas clasificadoras para diferenciar los comportamientos positivos de los negativos, que podrían ser beneficiosos para el niño cuando sea mayor. Los castigos corporales, los institutos educativos, los medios de comunicación y otros lugares son algunos de los usos de estas máquinas clasificadoras, según (Zant, 2010)

A continuación, ofrecemos una variedad de categorías de modelos de inteligencia artificial generativa.

- **Modelos de difusión:** crean nuevos datos iterando cambios aleatorios controlados en una muestra de datos previa. Empezan con los datos originales y luego agregan cambios sutiles, también conocidos como ruido, que hacen que gradualmente pierdan la similitud con el original. Este ruido se controla minuciosamente para garantizar que los datos generados sigan siendo consistentes y realistas. El modelo de difusión invierte el proceso

después de agregar ruido en varias iteraciones. Como se muestra en la Figura 22, la eliminación de ruido inversa crea una muestra de datos nueva que se asemeja a la original, según (Amazon, 2023).

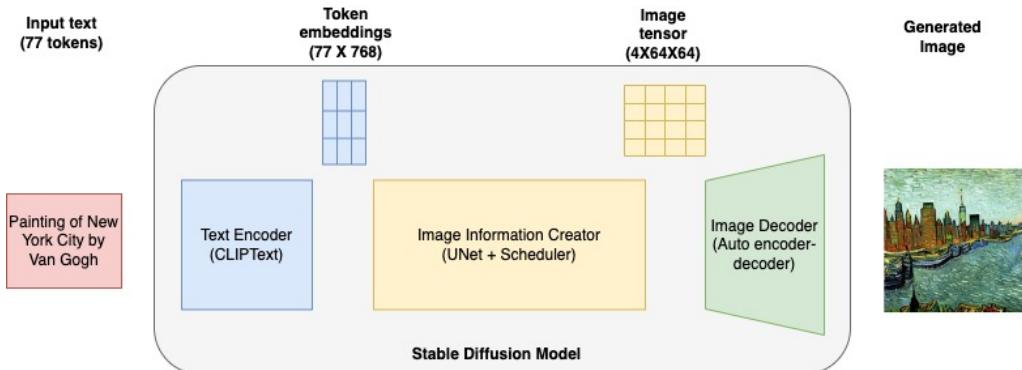


Figura 22. Modelos de difusión.

Fuente: Amazon (2023). «¿Qué es la IA generativa?»

- **Redes generativas adversativas:** compiten con dos redes neuronales. La primera red, también conocida como generador, agrega ruido aleatorio para crear muestras de datos falsas. La segunda red, conocida como discriminador, ayuda a distinguir entre los datos reales y falsos generados por el generador. El generador mejora continuamente su capacidad de generar datos realistas, mientras que el discriminador mejora su capacidad de distinguir entre lo real y lo falso. Hasta que el generador produzca datos tan persuasivos que el discriminador no pueda diferenciarlos de los datos reales, este proceso adversativo termina, según (Amazon, 2023).
- **Autocodificadores variacionales:** aprenden sobre el espacio latente, una pequeña representación de datos. La representación matemática de los datos se conoce como espacio latente. Puede verse como un código único que representa los datos en función de cada característica. Por ejemplo, cuando se estudian los rostros, el espacio latente contiene números que representan la forma de las orejas, los pómulos, la nariz y los ojos. Las dos redes neuronales utilizadas por los VAE son el codificador y el decodificador. Para cada dimensión del espacio latente, la red neuronal del codificador mapea los datos de entrada a una media y una varianza. Crea una muestra aleatoria utilizando la distribución normal gaussiana. Este ejemplo es un punto en el espacio latente, y como se puede ver en la Figura 23, representa una versión comprimida y simplificada de los datos de entrada, según (Amazon, 2023).

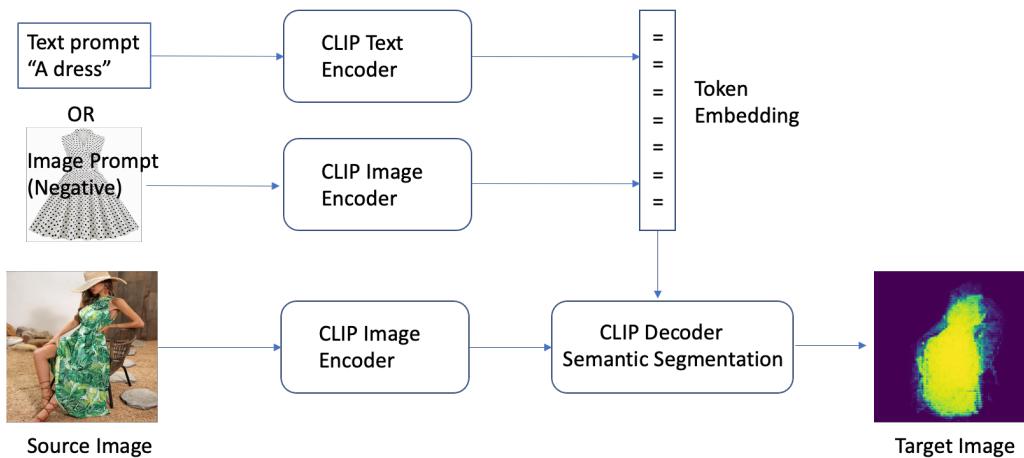


Figura 23. Autocodificadores variacionales.

Fuente: Amazon (2023). «¿Qué es la IA generativa?»

2.2.6 Modelos de Predicción

Los modelos estadísticos se utilizan para prever comportamientos futuros mediante la recopilación de datos actuales e históricos, la creación de modelos estadísticos, la realización de predicciones y la validación continua a medida que se recopilan más datos. Estos modelos predictivos identifican patrones ocultos y usan los sucesos anteriores con el fin de calcular las diversas opciones de si el individuo presente algún cambio tiempo después. (Gartner, 2019)

2.2.7 Análisis de Datos Espaciales

El análisis espacial es una colección de técnicas y modelos que utilizan explícitamente referencias espaciales para cada valor de datos u objeto especificado en el sistema en estudio. Los métodos de análisis espacial necesitan hacer suposiciones o basarse en datos para describir las relaciones espaciales o interacciones espaciales entre casos. Los resultados de cualquier análisis espacial no son iguales cuando se reordenan la distribución espacial de valores o se reconfigura la estructura espacial del sistema. (Haining, 2003)

Al realizar un análisis estadístico, es necesario tener en cuenta muchas características de los datos espaciales. El análisis de la dependencia espacial es crucial para el análisis de datos espaciales y central, por ejemplo, para realizar predicciones espaciales o especificar diseños de muestreo. Sin embargo, concentrarse demasiado en este aspecto de los datos espaciales puede llevar al analista a ignorar otras cuestiones. Por ejemplo, el impacto de una partición de área en la precisión de un estimador o el conjunto más amplio de supuestos y efectos de los datos que determinan si un modelo puede considerarse apropiado para el propósito previsto. Por lo tanto, el análisis de datos espaciales es una rama del análisis de datos más amplio. (Haining, 2003)

Existe, por lo tanto, un papel importante para las áreas de la teoría estadística desarrolladas para manejar otros tipos de datos no espaciales, al definir las habilidades y conceptos necesarios para realizar un análisis adecuado de datos espaciales. Se mantiene un vínculo con el cuerpo más amplio de teoría y métodos estadísticos al adoptar esta definición bastante más amplia de análisis de datos espaciales. (Haining, 2003)

Los métodos utilizados para el análisis espacial son:

- **Análisis Exploratorio de Datos Espaciales (ESDA):**describe cómo utilizar técnicas de visualización y análisis numérico para explorar y comprender la estructura espacial de los datos como se ve en la Figura 24. Esto incluye métodos numéricos para identificar propiedades de los datos espaciales, como suavización espacial, métodos de agrupación y comparación de mapas, así como métodos visuales para explorar los datos espaciales, como mapas y gráficos. (Haining, 2003)

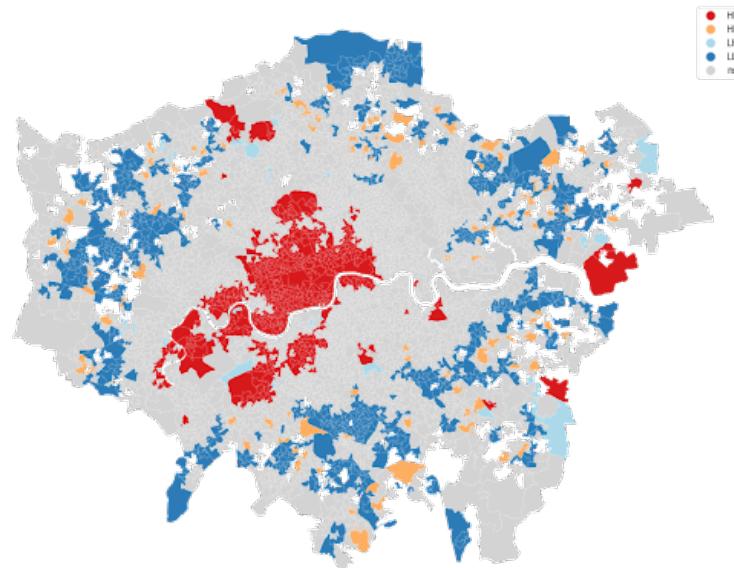


Figura 24. Análisis Exploratorio de Datos Espaciales (ESDA).

Fuente: Haining (2003). «Spatial Data Analysis». (p. 181)

- **Modelos de Análisis Espacial:**para estimar y modelar el semivariograma, se presentan modelos de análisis espacial, como kriging con datos gaussianos que se muestra en la Figura 25. Esto es particularmente útil para datos de superficies continuos. (Haining, 2003)
- **Logistic Regression:** modela fenómenos espaciales como las relaciones entre variables espaciales y no espaciales. (Haining, 2003)

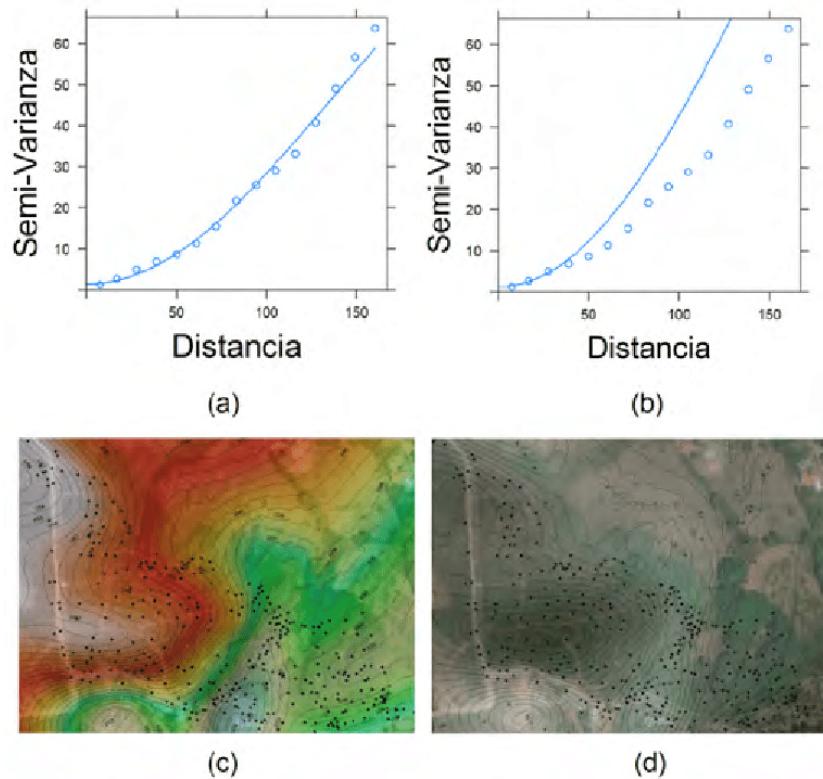


Figura 25. El modelo gaussiano isotrópico; el modelo gaussiano anisotrópico ajustado; la predicción de Kriging Simple Residual; y la varianza de Kriging Simple Residual.

Fuente: Haining (2003). «Spatial Data Analysis». (p. 352)

2.2.8 Procesamiento del Lenguaje Natural

El procesamiento del lenguaje natural (PLN) es una rama de la ciencia de la computación, la lingüística computacional, la ciencia cognitiva e la inteligencia artificial, y es un campo interdisciplinario. El objetivo es que las computadoras aprendan a hablar el lenguaje humano para que puedan realizar tareas útiles y comunicarse con las personas. (Deng & Liu, 2018)

En su libro, los autores Deng y Liu dividen el aprendizaje profundo, el racionalismo y el empiricismo en tres corrientes históricas.

- **Racionalismo:** se basa en la teoría de la naturaleza de la comunicación humana, desarrollada en las décadas de 1960 y 1980. Se basa en el conocimiento inherente, transmitido genéticamente y presente desde el nacimiento. La primera utilización de esta táctica se remonta a los años 50, cuando Alan Turing realizó experimentos para la simulación de diálogos en lenguaje natural entre un humano y una computadora con el fin de obtener parecidas respuestas a las de un ser humano y evaluar así sus capacidades. Durante las

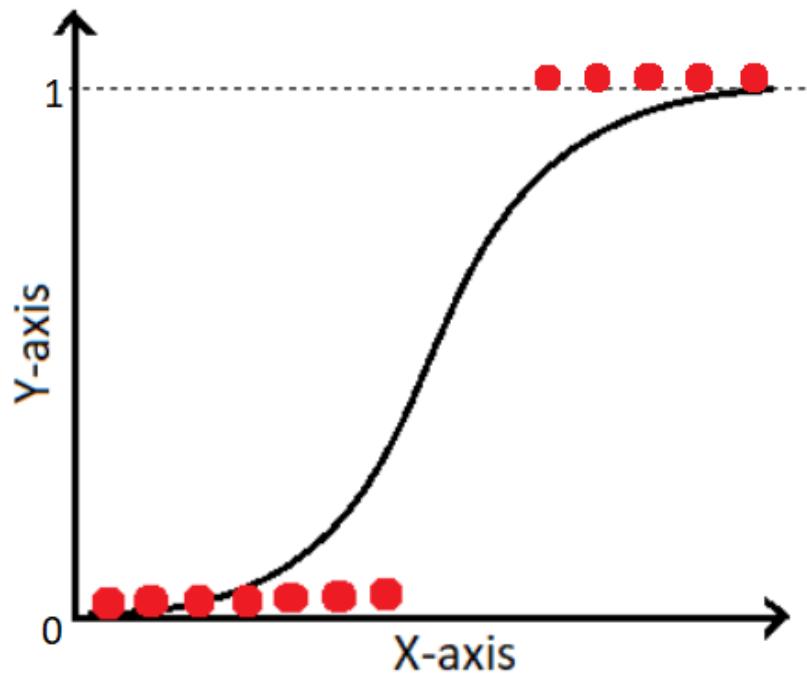


Figura 26. Regresión Logística.

Fuente: Haining (2003). «Spatial Data Analysis». (p. 358)

décadas de 1970 y 1980, los sistemas de comprensión del lenguaje que se empleo se dieron a cabo en grupos de medidas creados mediante la experiencia.

- **Empirismo:** se distingue por utilizar el Aprendizaje Automático y utilizar grandes corpus de texto. Esta perspectiva sostiene que el cerebro humano funciona mediante asociaciones, reconocimiento de patrones y generalizaciones.
- **Aprendizaje Profundo:** resuelve las inquietudes que tiene el lenguaje natural y el Aprendizaje Automático usual no sabe aún resolver, particularmente cuando se trata de grandes cantidades de datos. Debido a su capacidad para personalizar su arquitectura a través de múltiples capas e hiperparámetros, que permite un entrenamiento extenso, las redes neuronales artificiales son las más utilizadas. Sin embargo, a pesar de sus ventajas, tienen limitaciones, como la alta necesidad de capacidad computacional, la falta de precisión para obtener resultados estadísticos sobresalientes y la dificultad para comprender relaciones interrelacionadas.

Los modelos mencionados anteriormente incluyen las Redes Neuronales Convolucionales (CNN) y las Redes Neuronales Recurrentes (RNN), que son algunas de las técnicas de aprendizaje profundo que se utilizan actualmente para resolver problemas de lenguaje natural. A continuación se describen algunos de los más comunes, junto con las principales característi-

cas y diferencias de los ejemplos ya mencionados.

- **Redes Neuronales Convolucionales:** Hoy en día, el procesamiento de imágenes, que incluye problemas de clasificación y visión por computadora, es una de sus aplicaciones más relevantes. El proyecto de Yann LeCun, ImageNet, utiliza el reconocimiento de objetos en imágenes.

Estas redes también se utilizan para clasificar textos. Ronan Collobert y Jason Weston modificaron la arquitectura y los parámetros internos de las CNN para usarlas en tareas de procesamiento de lenguaje natural. La Figura 27 muestra la estructura de una CNN para problemas de procesamiento de información natural. (Kamath et al., 2019)

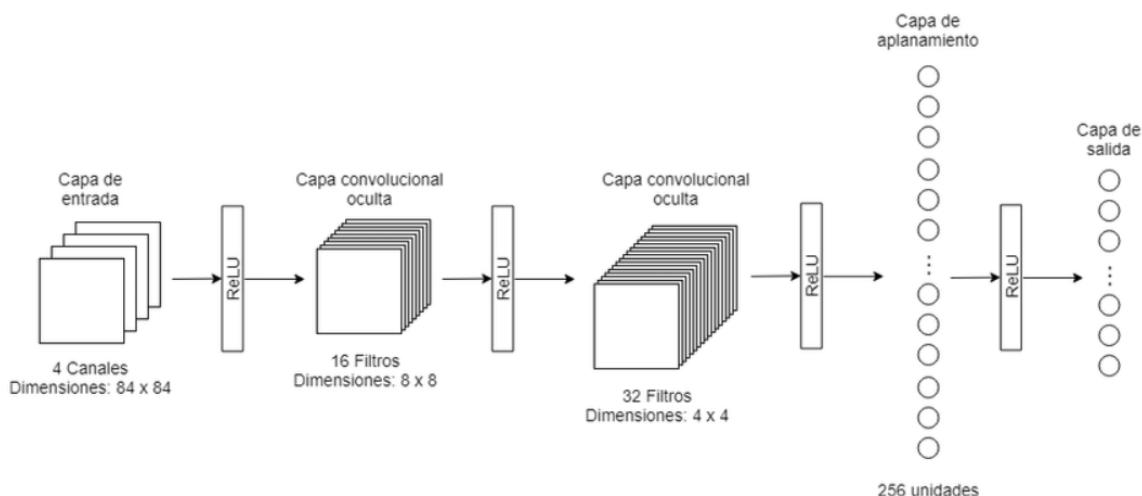


Figura 27. Arquitectura de un modelo CNN.

Fuente: Kim (2014). «Convolutional Neural Networks for Sentence Classification». (p. 1747)

Debido a que se mueven a través de matrices en dos dimensiones, las convoluciones de imágenes suelen ser bidimensionales (2D). Sin embargo, debido a que están conformadas por vectores, las convoluciones unidimensionales son extremadamente útiles para las series de tiempo. La Figura ?? compara los tipos de convolución en función del tamaño de la dimensión. (Rao & McMahan, 2019)

El proceso de arquitectura CNN generalmente está situado en los problemas de clasificación de texto considerados en esta investigación y algunas priorizaciones relacionadas con el contenido del texto.

La ID genérica es la creación de los vectores de los códigos Mots para la matriz de entidad genérica, que es la misma que los unidimensionales para los mapas de características genéricos de la siguiente entrada. Para generar vectores nuevos y consistentes después

de cada resultado, se reagrupan según la función de los criterios utilizados (por ejemplo, máximo, mínimo, mes, etc.) y luego se vinculan al valor.

- **Redes Neuronales Recurrentes:** son muy utilizadas porque los datos son secuencias. En la comunicación del ser humano, se sabe que los fonemas son secuencias de palabras, se puede usar un elemento dependiente para predecir la palabra que sigue de una oración. (Rao & McMahan, 2019)
- **Modelo Secuencia a Secuencia:** una técnica común en la traducción es la generación de lenguaje natural (NLG), basado en dos capas LSTM. De esto, 1º capa transforma la oración inicial para un "vector de pensamiento", mientras que en 2º capa decodifica la respuesta, como se observa en la Figura 28. (Deng & Liu, 2018).

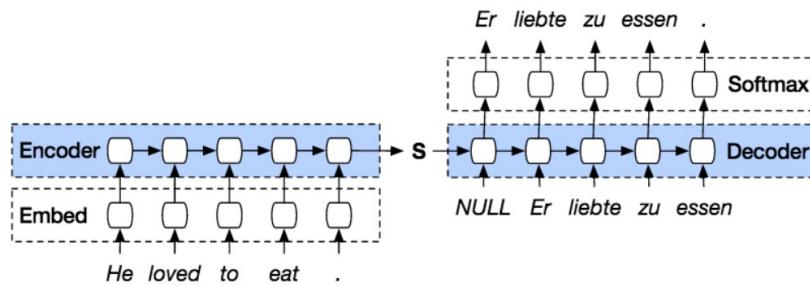


Figura 28. Modelo Seq2seq.

Fuente: Kostadinov (2019). «Understanding Encoder-Decoder Sequence to Sequence Model».

Debido a que estos modelos no pueden incluir el texto en su estado original sin limpiarlo previamente, estos modelos requieren un preprocesamiento del contenido textual. La biblioteca Natural Language Toolkit (NLTK) de Python facilita la modelización y el trabajo con texto. Sus funciones incluyen dividir el texto en oraciones, tokenizar, eliminar puntos y palabras de parada, reducir palabras a su forma raíz y convertir palabras a su forma base o diccionario. (Brownlee, 2017)

2.2.9 Redes Generativas Antagónicas

Las redes generadoras y discriminadoras son las dos redes que compiten entre sí en las Generative Adversarial Networks (GAN). El discriminador determina si los datos son reales o generados por el generador, mientras que la función del generador es producir nuevos datos que se asemejen al conjunto de datos de entrenamiento. (Goodfellow et al., 2014)

En este juego de suma cero, quien gana pierde. El generador tiene un alto error si el discriminador clasifica correctamente los datos generados, y viceversa. Debido a que dos tipos

de redes trabajan juntos, el proceso de entrenamiento es esencial. (Goodfellow et al., 2014)

Las GAN se utilizan principalmente para producir datos que se asemejan a los de entrada. Esto puede ser simplemente para generar nuevos datos o para aumentar el tamaño de un conjunto de datos existente para entrenar otra red neuronal. (Goodfellow et al., 2014)

2.2.9.1. Arquitectura de las GAN

La Figura 30 muestra la relación entre el generador y el discriminador en una GAN. El discriminador debe determinar la procedencia de cada imagen que recibe, que puede provenir de un generador o de un conjunto de datos. Mientras tanto, los valores aleatorios se convierten en imágenes que el discriminador reconoce como pertenecientes al conjunto de datos a través del generador. (Goodfellow et al., 2014)

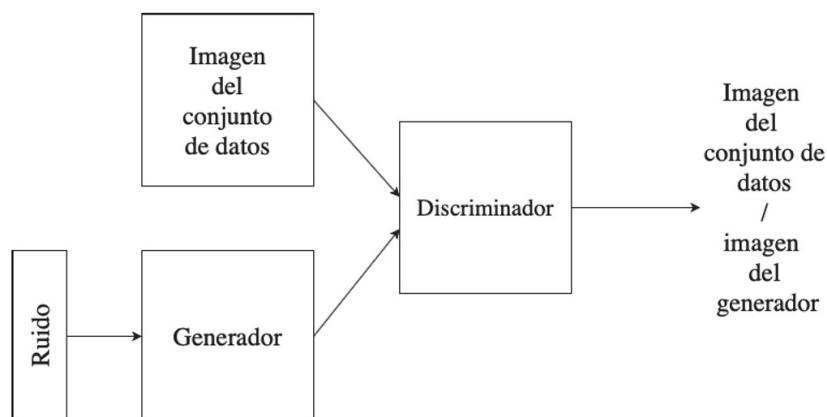


Figura 29. Red Generativa Antagónica de Imágenes.

Fuente: Goodfellow et al. (2014). «Generative Adversarial Networks».

El uso de GANs es amplia y no se limita a un tipo de datos específico. La Figura 31 muestra una GAN con un generador y un discriminador de dos capas. En el generador, cada capa es gradualmente más grande, mientras que en el discriminador, cada capa se vuelve más pequeña hasta que se encuentra una neurona en la última capa. (Goodfellow et al., 2014)

Como se muestra en la Figura 32 con imágenes en blanco y negro, la entrada del generador es una distribución aleatoria gaussiana. Su salida es comparable a la del conjunto de datos, y la capa de salida debe tener suficientes neuronas dispuestas de manera adecuada para producir datos con la misma estructura que el conjunto de datos original, ya sea imágenes, audio o cualquier otro tipo de datos. Por ejemplo, si se quieren imágenes de 20 x 20 píxeles, el generador debe producir 400 neuronas. Cada capa del generador es más grande que la anterior y generalmente utiliza la activación Selu, excepto la capa final, que utiliza Sigmoide. (Goodfellow et al., 2014)

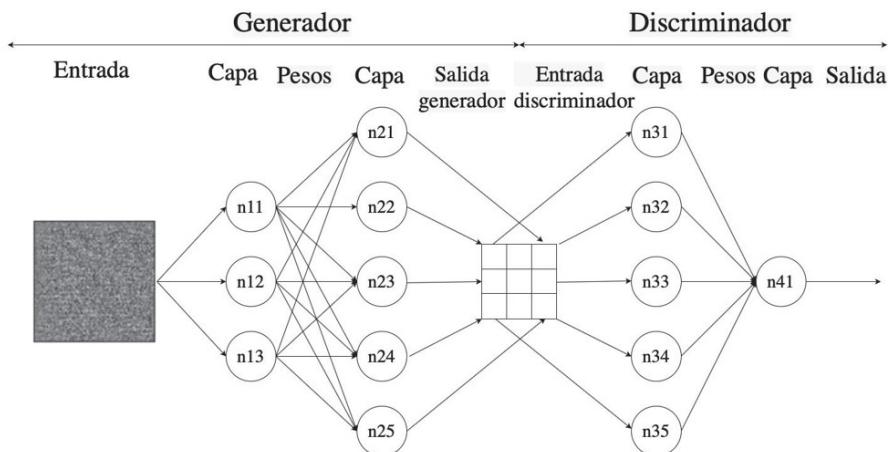


Figura 30. Red Generativa Antagónica de Imágenes.

Fuente: Goodfellow et al. (2014). «Generative Adversarial Networks».

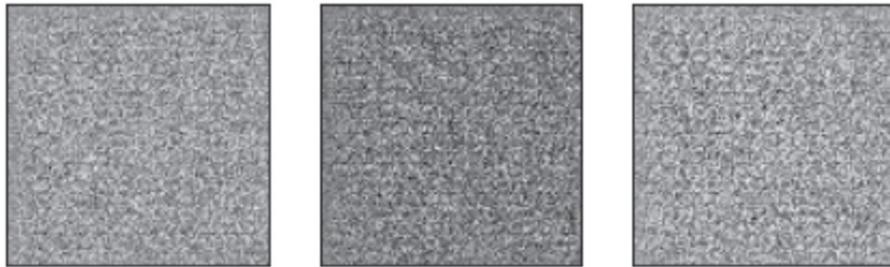


Figura 31. Imágenes de Ruido Gaussiano.

Fuente: Goodfellow et al. (2014). «Generative Adversarial Networks».

Los datos del conjunto de datos o los creados por el generador son la entrada del discriminador. Su salida consiste en una neurona con un solo valor numérico que intenta determinar si la entrada proviene del generador o del conjunto de datos. Por lo general, cada capa del discriminador contiene menos neuronas hasta que solo queda una neurona en la capa más alta. (Goodfellow et al., 2014)

2.2.9.2. Entrenamiento de las GAN

En el primer paso del proceso, el discriminador recibe capacitación para diferenciar entre imágenes reales y imágenes creadas por el generador. El generador se entrena para crear imágenes en el segundo paso, pero los pesos del discriminador no se actualizan en este caso. Las imágenes generadas se etiquetan como reales y el generador ajusta sus pesos para que el discriminador piense que son reales. Esto mejora su capacidad para generar imágenes más

parecidas al conjunto de datos original mediante la retropropagación del gradiente. (Géron, 2019)

Hasta que el generador produzca resultados satisfactorios, estos pasos se repiten. El discriminador se entrena con las imágenes recién generadas y luego se enseña al generador con lo que el discriminador ha aprendido. (Géron, 2019)

2.2.9.3. Dificultades del entrenamiento de las GAN

El juego de suma cero en las GAN significa que cuanto menor sea el error de uno de los elementos, mayor será el error del otro. Cuando ninguna de las dos redes cambia su estrategia, se alcanza un estado de equilibrio de Nash. Este equilibrio se alcanza cuando el generador crea imágenes perfectamente realistas y el discriminador intenta clasificarlas con una probabilidad del 50 % como generadas o del conjunto de datos. Es necesario aplicar la técnica de prueba y error durante el entrenamiento de una GAN porque no se puede garantizar que se llegue a este equilibrio. (Géron, 2019)

Cuando el conjunto de datos incluye varias clases, como diferentes tipos de mascotas (gatos, perros y conejos), el entrenamiento de una GAN se vuelve más difícil. Aunque el objetivo del discriminador sigue siendo distinguir entre imágenes reales y generadas, puede haber una clase en la que el generador produzca más imágenes que el discriminador clasifique como reales, mientras que en otras clases puede haber deficiencias. Por ejemplo, el generador puede ser muy hábil en la creación de imágenes de perros, pero no lo es en otras categorías. Esto puede llevar al generador a producir más imágenes de perros y olvidarse de cómo producir imágenes de otras clases. Al recibir principalmente imágenes de perros, el discriminador puede fallar en clasificar correctamente las imágenes de otras clases. (Géron, 2019)

2.2.10 Generación de Imágenes

En los últimos años, ha habido una notable evolución en la generación de imágenes a través de la inteligencia artificial, impulsada por dos modelos generativos importantes: los auto-codificadores variacionales y las redes generativas antagónicas, particularmente las que utilizan capas convolucionales. Aunque existen otras técnicas para generar imágenes no relacionadas con la IA, como las utilizadas en cine o videojuegos, se utiliza el término imágenes generadas por ordenador^º CGI en inglés para estos fines. A pesar de que este término incluye una variedad de técnicas, en su mayoría implica modelar objetos en tres dimensiones, aplicar texturas y renderizarlos en dos dimensiones. (Kingma & Welling, 2019)

DCGAN, o GAN con capas convolucionales, es una herramienta común para la generación de imágenes. Como las GAN convencionales, tiene un generador y un discriminador. La Figura 33 muestra la estructura típica de una DCGAN, que utiliza una capa inicial de tres

neuronas, seguida de tres capas de normalización y convolución transpuesta, produciendo una imagen a color. El discriminador, por otro lado, utiliza dos capas de convolución, dos capas de reducción y dos capas totalmente conectadas. (Kingma & Welling, 2019)

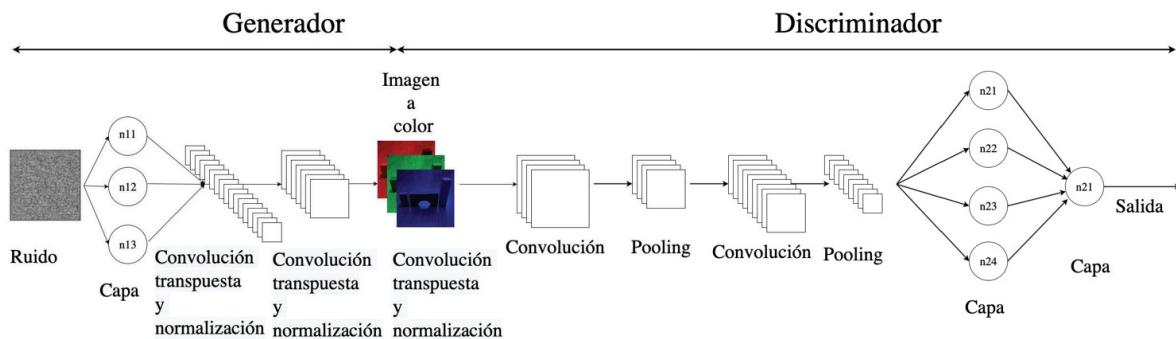


Figura 32. Arquitectura de Red Generativa Antagónica con Capas Convolucionales (DC-GAN).

Fuente: Kingma y Welling (2019). «An Introduction to Variational Autoencoders».

La entrada de ruido del generador se procesa a través de capas de normalización y convolución transpuesta para crear la imagen deseada. La entrada del discriminador conecta la salida del generador, que clasifica las imágenes como generadas o reales. El discriminador generalmente se compone de capas convolucionales y redes neuronales, con una sola neurona de salida con activación Sigmoide. (Kingma & Welling, 2019)

Los autocodificadores variacionales (VAE), que tienen similitudes con las GAN, son otra técnica común para generar imágenes. Los VAE consisten en un codificador y un decodificador y tienen como objetivo reconstruir las entradas de la red. El codificador reduce gradualmente la dimensionalidad de los datos hasta obtener una representación latente, que el decodificador reconstruye posteriormente. Los VAE pueden producir datos similares a los de entrenamiento y aplicar aleatoriedad para generar nuevas muestras. (Kingma & Welling, 2013)

La interpolación de datos es otra aplicación de los autocodificadores y los VAE; en este caso, la representación latente de dos datos se combina ponderadamente para generar nuevas muestras. Interpolando entre dos muestras ya existentes permite la creación de nuevas instancias de datos. (Kingma & Welling, 2013)

2.3 Marco Conceptual

2.3.1 Redes Inalámbricas

Una red inalámbrica es un sistema de comunicación de datos flexible que reduce la necesidad de conexiones físicas al enviar y recibir datos por aire a través de medios inalámbricos, como la tecnología de radiofrecuencia. Las redes de datos están experimentando un cambio significativo gracias a la revolución de las comunicaciones inalámbricas. Los recientes avances en las redes y la tecnología inalámbrica han permitido que la gran mayoría de los dispositivos inalámbricos que se utilizan hoy en día se conecten fácilmente. Es necesario maximizar el uso de los recursos del espectro para permitir que millones de dispositivos inalámbricos se conecten inalámbricamente. (Pundalik et al., 2023)

Las redes inalámbricas utilizan ondas electromagnéticas para transferir información entre lugares sin tener conexiones físicas. Las ondas de radio suelen denominarse portadoras de radio, ya que sólo envían energía a un receptor distante. Los datos que se transfieren se superponen a la onda de radio para garantizar una extracción precisa en el extremo receptor. Debido a que la frecuencia de la información de modulación o la velocidad de bits se suman a la portadora de radio después de que los datos se superponen (modulan) sobre ella, la señal de radio tiene muchas frecuencias. Si las ondas de radio se envían en diferentes frecuencias de radio, varias portadoras de radio pueden coexistir en el mismo espacio sin interferir entre sí. Las señales de radio, los formatos de datos y la arquitectura de la red son los tres componentes de una red inalámbrica. Dado que estos tres elementos no están relacionados entre sí, deben describirse al construir una nueva red. Mientras que la señal de radio opera en la capa física, el formato de datos tiene un impacto en varios niveles superiores del modelo de referencia OSI. Las estaciones base y los adaptadores de interfaz de red inalámbrica son componentes de la estructura de la red que envían y reciben señales de radio. Cada computadora y estación base en una red inalámbrica tiene adaptadores de interfaz de red que transforman los datos digitales en señales de radio, que luego se envían a otros dispositivos conectados. Además, reciben y transforman las señales de radio entrantes de otros componentes de la red en datos digitales. Los formatos de datos, las arquitecturas de red y las señales de radio son distintos para cada servicio de datos inalámbricos de banda ancha. (Rafaqat & Muhammad, 2019)

Las redes inalámbricas se clasifican normalmente en cinco grupos distintos. La región de aplicación y el rango de señal son los principales criterios utilizados para esta clasificación (Figura 30). Las redes inalámbricas en el primer grupo, WBAN, conectan dispositivos en la superficie del cuerpo entre sí. Las señales de estas redes pueden alcanzar un máximo de dos metros. El segundo grupo, conocido como WPAN, está compuesto por redes inalámbricas con un alcance de señal mínimo de 10 metros que se utilizan para conectar varios dispositivos entre sí. El tercer grupo cumple con el estándar de redes inalámbricas, que busca cubrir un edificio o

habitación como máximo. El alcance de señal de este grupo, conocido como WLAN, suele ser de 30 metros en interiores y de 100 a 200 metros en exteriores. El término fidelidad inalámbrica (Wi-Fi o IEEE 802.11) se usa con frecuencia para describir la tecnología inalámbrica. La WMAN, la cuarta clase de red inalámbrica, permite a los usuarios conectarse a Internet con un alcance de señal de entre 5 y 20 kilómetros. Este protocolo a menudo se conoce como IEEE 802.16-2001, también conocido como interoperabilidad mundial para acceso por microondas (WiMAX). El WWAN es el grupo final. Las redes WWAN (redes basadas en GSM y CDMA) ofrecen conexiones inalámbricas en una área mucho más amplia que el grupo anteriormente mencionado utilizando la infraestructura de red de los operadores móviles. (IEEE, 2010)

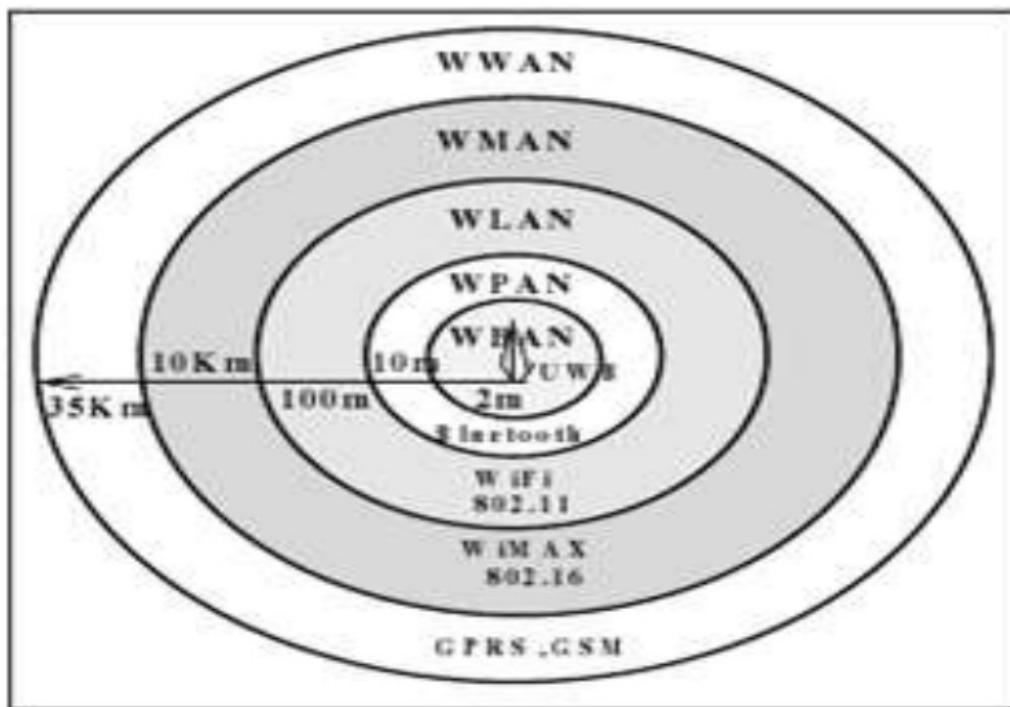


Figura 33. Clasificación de redes inalámbricas con su alcance de señal.

Fuente: IEEE (2010). «IEEE P802.11s Task Group IEEE Unapproved Draft Standard P802.11s/D4.0».

2.3.2 Calidad de Servicio (QoS)

La expansión de las redes de datos de alta velocidad depende de la calidad de servicio (QoS). Esto es particularmente cierto cuando se trata de cumplir con las limitaciones de velocidad de datos y latencia de paquetes de los consumidores de datos en tiempo real. Al transferir un flujo de paquetes desde el origen al destino, la red debe cumplir con ciertos requisitos de calidad de servicio (QoS). Debido a este requisito, las redes que utilizan comunicación inalámbrica enfrentan desafíos especiales. La calidad de un canal inalámbrico varía significativamente en-

tre los usuarios y cambia enormemente con el tiempo, tanto en escalas de tiempo lentas como rápidas. Además, el ancho de banda inalámbrico generalmente es limitado y debe utilizarse con precaución. Encontrar formas eficientes de proporcionar QoS para datos en tiempo real (como transmisiones de audio y video en vivo) a través de canales inalámbricos es necesario para brindar la calidad de servicio (QoS) adecuada a la mayor cantidad de personas posible (Pang et al., 2010). La confiabilidad de la red siempre ha sido crucial para muchas aplicaciones de red. Sin embargo, con el aumento en la cantidad de datos de audio y video que se transmiten a través de las redes abiertas de conmutación de paquetes, la capacidad de garantizar la calidad de servicio (QoS) en las redes actuales puede ser más crucial que nunca. Como resultado, se ha dedicado una gran cantidad de tiempo y esfuerzo a encontrar una forma de mantener un rendimiento constante de la red mientras se utilizan todos los recursos disponibles. Las garantías de servicio probablemente sean el requisito previo más importante para el éxito de la transmisión de audio y video. Muchos proveedores de servicios han comenzado a utilizar redes de conmutación de paquetes para ofrecer servicios de video y telefonía en los últimos años. Una de las razones por las que se crearon estos servicios es que la red IP ofrece capacidad adicional que puede utilizarse por una fracción del costo de una red dedicada de conmutación de circuitos. Otro argumento es que la naturaleza libre de forma de una red de conmutación de paquetes aumenta su adaptabilidad y permite la creación de nuevos servicios como video bajo demanda. Los diferentes métodos de compresión codifican los flujos a diferentes velocidades de bits para maximizar la eficiencia, lo que crea un problema único para la transmisión de audio/vídeo (VBR). Es posible garantizar el rendimiento a tasas de bits más altas para tales flujos, pero esto es ineficaz. Un sistema de calidad de servicio (QoS) mejorado también garantizaría el rendimiento a la velocidad de bits promedio y permitiría el tráfico en ráfagas con la menor pérdida y retraso. (Pang et al., 2010)

2.3.3 Diferentes parámetros que deben enviarse para las comunicaciones de extremo a extremo a través de redes inalámbricas

Actualmente, la información se presenta en una variedad de formatos, como texto, imágenes, sonido y video.

- **Textos:** En tecnología de la información, el texto es una serie de caracteres que los humanos pueden leer y luego codificar en formatos legibles por computadora como ASCII. Las imágenes visuales en forma de mapas de bits, que en realidad están en su propio formato legible por computadora, y el código de programa, al que con frecuencia se hace referencia como "binario", son ejemplos de datos que no han sido codificados con caracteres. En las transmisiones de datos, el texto se representa como una serie de bits o un patrón de bits (0 o 1). Muchos conjuntos de patrones de bits se han desarrollado para representar símbolos de texto. El proceso de representar símbolos se conoce como codi-

fificación, y cada conjunto se denomina código. El sistema de codificación popular actual, Unicode, representa cada letra o símbolo en cualquier idioma del mundo en 32 bits. El Código Estándar Americano para el Intercambio de Información (ASCII), creado hace muchos años en los Estados Unidos, es responsable de los primeros 127 caracteres de Unicode, que se conocen comúnmente como Latín Básico. (Marks & Gifford, 2001)

- **Imágenes:** Las imágenes también se pueden representar utilizando patrones de bits. Una matriz de píxeles, o “componentes de imagen”, donde cada píxel es un punto diminuto, compone una imagen. El tamaño de un píxel está influenciado por la resolución. Por ejemplo, una imagen se puede dividir en 1.000 o 10.000 píxeles. En el segundo escenario, la imagen tiene una mejor resolución y representación, pero necesita más memoria para retenerla. Después de dividirlo en píxeles individuales en una imagen, a cada píxel se le asigna un patrón de bits. El tamaño y el valor del patrón se determinan por la imagen. Por ejemplo, puede mostrar escala de grises en cuatro niveles diferentes utilizando patrones de dos bits. Los números 00, 01, 10 y 11 pueden usarse para representar un píxel negro, mientras que el número 10 puede usarse para representar un píxel gris claro. Es posible representar una imagen en color de varias maneras. Como resultado de la combinación de los colores rojo, verde y azul, una técnica conocida como RGB crea cada color. Después de medir la intensidad de cada color, se le asigna un patrón de bits. Otra técnica llamada YCM combina tres colores principales: amarillo, cian y magenta. (Singh et al., 2011)
- **Audios:** El término “audio” se refiere a la transmisión o grabación de sonido o música. El sonido se distingue del texto, los números y las imágenes por sus características propias. No es diferente; es constante. Incluso cuando utilizamos un micrófono para convertir música o voz en señal eléctrica, seguimos produciendo una señal continua. Los Capítulos 4 y 5 nos enseñan cómo convertir sonido o música a una señal digital o analógica. (Singh et al., 2011)
- **Videos:** Un video es una imagen o película que ha sido grabada o transmitida. El video se puede crear como una entidad continua (como una cámara de televisión) o como una colección de imágenes discretas combinadas para crear la ilusión de movimiento. El video se puede convertir nuevamente en una señal digital o analógica. (Karnik & Passerini, 2005)

2.3.4 Access Points

Un dispositivo de red que permite la conexión de dispositivos inalámbricos a una red cableada se conoce como punto de acceso inalámbrico (WAP). La instalación de WAP es más rápida y fácil que conectar todos los dispositivos mediante cables. (Cisco, 2023)

Los puntos de acceso también se conocen como AP o WAP. Son dispositivos que pueden conectar dispositivos móviles o tarjetas de red inalámbricas a equipos a través de una red inalámbrica externa, que puede ser local o de Internet. Esta red inalámbrica, conocida como WLAN (Red inalámbrica de área local), se utiliza para disminuir las conexiones cableadas. Conozca el significado de AP y todas sus características. (YMANT, 2023)



Figura 34. Access Points.

Fuente: Cisco (2023). «¿Qué es un access point?»

Se pueden configurar para una variedad de funciones según nuestras necesidades. Algunas de las características incluyen:

- **Modo cliente:** Se utiliza como receptor y se conecta a una red como un cable de red. (YMANT, 2023)
- **Modo AP (punto de Acceso):** El punto de acceso es donde se instala el cableado y permite que varios usuarios accedan a la red. (YMANT, 2023)
- **Modo Repetidor:** Este modo puede extender la señal para que el punto de acceso amplifique la señal que recibe para maximizar el rango de acción. (YMANT, 2023)
- **Modo Bridge:** Este método se emplea para cubrir distancias considerables, como dos edificios distintos. Podemos establecer una red Wi-Fi a distancias significativas si conectamos dos puntos de acceso entre sí. (YMANT, 2023)

Los WAP conectan cada dispositivo a la red de manera más fácil, segura y económica que los cables. El uso de WAP para establecer una red inalámbrica puede ser muy ventajoso

para las pequeñas empresas. Las redes inalámbricas facilitan el acceso y la incorporación de nuevos usuarios. Con una contraseña segura para la red inalámbrica, un invitado puede acceder fácilmente a Internet. También es posible dividir a los usuarios, incluidos los invitados, para proteger los recursos y los activos de la red. (Cisco, 2023)

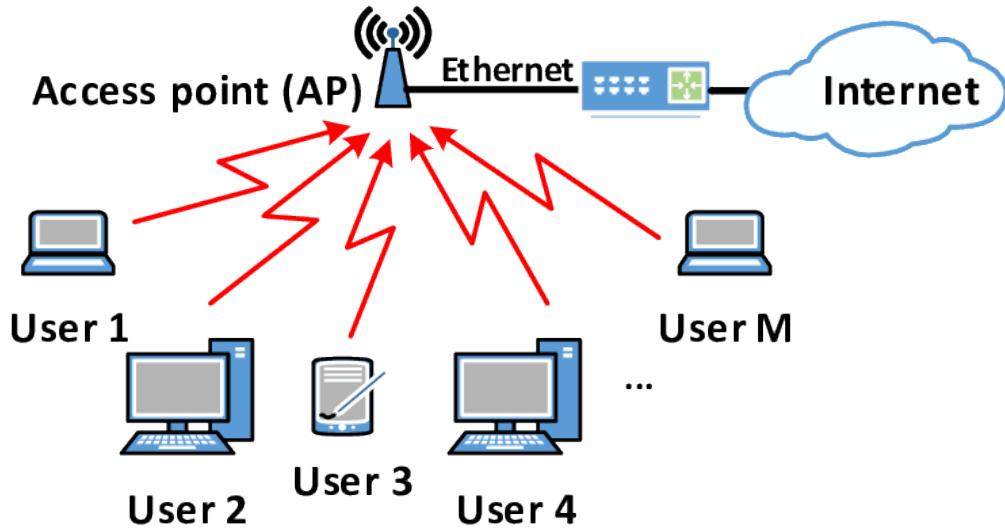


Figura 35. Funcionamiento de un AP.

Fuente: YMANT (2023). «¿Qué es un AP (Access Point) y que usos y modos tiene?»

Capítulo III: Metodología de la Investigación

3.1 Diseño de la investigación

Esta sección del documento describe el diseño de la investigación, el tipo y el enfoque, así como la población y la muestra.

3.1.1 Tipo de investigación

Se determinó que este estudio tenía un diseño experimental para determinar el tipo de investigación, ya que, según Hernández Sampieri et al. (2014) en su libro *Metodología de la Investigación*, se busca establecer el posible efecto de una causa que se manipula. En particular, se clasifica como un diseño experimental puramente porque se utilizaron variables independientes intencionalmente (agregadas, eliminadas o agregadas) para evaluar su impacto en la variable dependiente, que es la predicción de las ubicaciones de puntos de acceso (AP) dentro de varios planes.

3.1.2 Enfoque de la investigación

Según Hernández Sampieri et al. (2014) en su libro *Metodología de la Investigación*, este estudio adoptó un enfoque cuantitativo porque se basa en la recolección de datos para probar hipótesis mediante la medición numérica y el análisis estadístico con el objetivo de establecer pautas de comportamiento y validar teorías. Esto se puede ver en los diez pasos del proceso cuantitativo que el autor mencionó, que se utilizaron en la investigación desde el inicio de la idea hasta el final del informe de resultados.

3.1.3 Población

La población estaría compuesta por los diversos entornos y espacios interiores (planos de edificios, oficinas, centros comerciales, etc.) donde se planea optimizar la cobertura de redes inalámbricas mediante la predicción de ubicaciones para puntos de acceso (APs) utilizando inteligencia artificial generativa.

3.1.4 Muestra

La muestra consistió en 19,154 imágenes de planos interiores en formato vectorial del antecedente Wu et al. (2019), que se obtuvieron del conjunto RPLAN público. El criterio de selección de esta categoría se basó en los problemas que enfrentan tanto empresas como usuarios en la actualidad con la cobertura Wi-Fi y la ubicación ineficaz de los puntos de acceso interior, lo que resulta en quejas y pérdidas de dinero al realizar una reinstalación o reubicación de estos puntos.

3.1.5 Operacionalización de Variables

La operacionalización de las variables de investigación se muestra en la Tabla 1.

Tabla 1
Matriz de Variables Principales.

VARIABLE	DIMENSIÓN	INDICADOR DEL INDICADOR	DEFINICIÓN	TÉCNICA DE MEDICIÓN	ESCALA
Independiente: Imágenes de Planos Interiores	Calidad de la Imagen	Resolución	Número de píxeles por unidad de área (píxeles por pulgada)	Análisis de propiedades de la imagen	ppi (píxeles por pulgada)
	Detalle Arquitectónico	Elementos Arquitectónicos Identificables	Cantidad de detalles arquitectónicos (paredes, puertas, ventanas) Identificables claramente identificables en la imagen	Contaje manual o mediante software de análisis de imágenes	Número
Dependiente: Predicción de Ubicaciones de APs Indoor Con Inteligencia Artificial Generativa	Precisión de la Predicción	Diferencia de Cobertura Predicha vs Real	Diferencia entre la cobertura predicha por el algoritmo y la cobertura real medida	Comparación de resultados de simulación y medición real	Porcentaje
	Sensibilidad	Tasa de Verdaderos Positivos	Proporción de ubicaciones predichas correctamente como óptimas respecto al total de ubicaciones óptimas reales	Evaluación de predicciones respecto a un conjunto de prueba	Porcentaje

Puntaje F1	Media Armónica de Precisión y Sensibilidad	Combina la precisión y la sensibilidad en un solo valor	Evaluación de predicciones respecto a un conjunto de prueba	Valor F1
Área Bajo la Curva ROC	AUC-ROC	Medida de la capacidad del modelo para distinguir entre clases	Evaluación de la curva ROC	Valor AUC

Fuente: Elaboración propia.

3.2 Técnicas de recolección de datos

La recolección de planos interiores es un paso crucial para la optimización de la cobertura de redes inalámbricas mediante la inteligencia artificial generativa. Una de las técnicas más accesibles y efectivas para obtener estos planos es a través del uso de bases de datos públicas y repositorios en línea. Estas fuentes ofrecen una amplia variedad de planos de planta, que pueden ser utilizados para modelar y predecir las ubicaciones óptimas de puntos de acceso (APs) en diferentes entornos interiores.



Figura 36. Plano interior.

Fuente: Wu et al. (2019).

- **Repositorios de Arquitectura y Diseño:** Existen múltiples repositorios en línea dedicados específicamente a la arquitectura y el diseño. Sitios web como ArchDaily, Floorplanner y otros, ofrecen planos de planta y modelos 3D de edificios que pueden ser descargados y utilizados para diversos fines. Estos repositorios suelen incluir planos de diferentes tipos de edificios, desde residenciales hasta comerciales y educativos, lo que proporciona una amplia gama de opciones para la optimización de redes inalámbricas.
- **Bibliotecas Digitales y Bases de Datos Académicas:** Las bibliotecas digitales y bases de datos académicas son otra fuente valiosa para la recolección de planos interiores. Instituciones académicas y bibliotecas públicas a menudo mantienen colecciones de planos de edificios históricos y contemporáneos. Plataformas como JSTOR, Google Scholar y las bibliotecas digitales universitarias pueden contener planos de planta detallados en publicaciones académicas, tesis y proyectos de investigación.
- **Plataformas de Colaboración y Repositorios de Código Abierto:** Plataformas como GitHub y otros repositorios de código abierto también pueden ser recursos útiles para la recolección de planos interiores. Investigadores y profesionales de la industria a menudo comparten conjuntos de datos, modelos y planos como parte de sus proyectos de colaboración. Estos recursos pueden ser utilizados libremente bajo licencias abiertas, lo que facilita su integración en proyectos de optimización de redes inalámbricas.
- **Repositorios de Proyectos de Construcción:** Sitios web como Procore y otros repositorios de gestión de proyectos de construcción ofrecen planos y documentos relacionados con proyectos de construcción. Estos repositorios son utilizados por profesionales de la construcción para gestionar y compartir información sobre proyectos, y a menudo incluyen planos de planta detallados que pueden ser utilizados para análisis posteriores.

3.3 Técnicas para el procesamiento y análisis de la información

3.3.1 Metodología de implementación de la solución

La Generación de Imágenes con IA Generativa implica una serie de etapas de desarrollo, que van desde la recolección de imágenes hasta la interpretación de ellas, según cite Kingma y Welling (2019). La imagen captada debe seguir un proceso que se detallará más adelante para llegar a la etapa final. La Figura 37 muestra la metodología del trabajo de investigación actual.

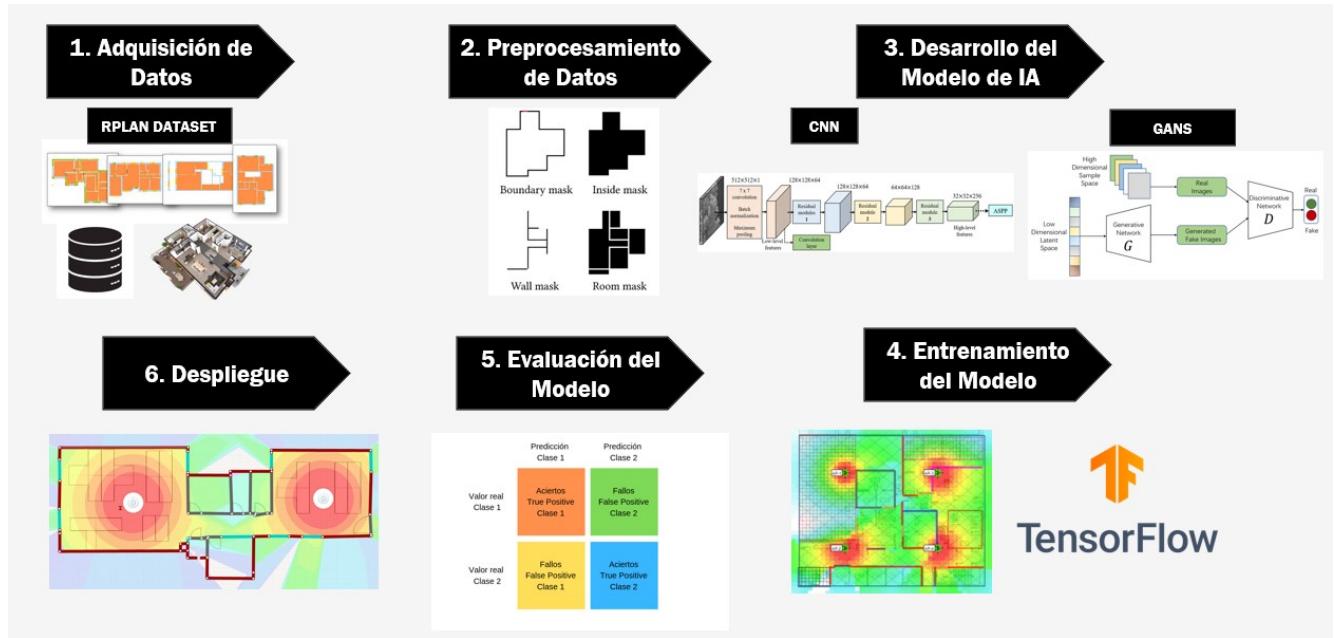


Figura 37. Metodología de la Investigación.

Fuente: Elaboración propia.

3.3.1.1. Adquisición de Datos

Esta sección describe el procedimiento utilizado para obtener el conjunto de datos de esta investigación. La siguiente tabla muestra las tareas y actividades realizadas durante esta etapa de adquisición. La recopilación de datos fue el primer paso. La lista de actividades y tareas se presenta en la Tabla 2.

Tabla 2

Actividades de la fase de Adquisición de Datos.

Actividades	Descripción	Tareas
Identificación de bases de datos de imágenes de planos interiores de planta con la misma dimensión y características similares.	Identificación de bases de datos que contengan imágenes de planos interiores de planta adecuados para el estudio.	<ul style="list-style-type: none"> ■ Analizar y identificar bases de datos con planos de planta interiores. ■ Validar que la base de datos sea de uso público y sea adecuada para el estudio. ■ Descargar la base de datos del repositorio correspondiente.

Fuente: Elaboración propia.

A continuación, cada actividad de la anterior tabla es detallada y se indican sus entregables respectivos.

Actividad 1: Identificación de bases de datos de imágenes de planos interiores de planta con la misma dimensión y características similares

Esta actividad explica la identificación de la base de datos. Para la base de datos, se obtuvieron más de ochenta mil planos de plantas de edificios residenciales reales de la base de datos pública RPLAN, que recolectó planos del mercado inmobiliario de Asia en 2019. Las imágenes de planos interiores se encuentran en la base de datos. La Figura 38 muestra ejemplos de cómo es la data. Cada plano de planta tiene gráficos vectoriales dentro de una región cuadrada de 18m × 18m con elementos geométricos e información semántica, y cada plano de planta tiene una imagen de 256 × 256.

Entregable: Dataset, creado en Asia, contiene imágenes de planos interiores del mercado inmobiliario asiático.

3.3.1.2. Preprocesamiento de Datos

Se realizará el preprocesamiento de las imágenes del conjunto en esta etapa. La tabla 3 incluye las tareas y actividades necesarias para completar la etapa de preprocesamiento:

Tabla 3
Actividades de la fase de Preprocesamiento de Datos.

Actividades	Descripción	Tareas
Filtración de las imágenes de los planos interiores	Filtrado de datos no estándar para evitar interferencias y mejorar la fiabilidad del conjunto de datos.	<ul style="list-style-type: none"> ■ Eliminar planos de planta que contengan tipos de habitaciones indefinidas o de muy baja frecuencia. ■ Mantener planos de planta que cumplan con los siguientes requisitos: <ol style="list-style-type: none"> 1. Área total del plano de planta superior a 60 m² y menor a 120 m². 2. Número de habitaciones en el plano de planta mayor que 3 y menor que 9. 3. El plano de planta tiene sala de estar. 4. La proporción del área de la sala de estar respecto al área total del plano de planta es mayor que 0.25 y menor que 0.55. 5. El área promedio de cada habitación es mayor a 10 m² y menor a 20 m².

Actividades	Descripción	Tareas
Representación de las imágenes de los planos interiores	Representación de cada plano de planta como una imagen de cuatro canales.	<ul style="list-style-type: none"> ■ Guardar la máscara interior en el primer canal. ■ Almacenar la información de límites en el segundo canal. ■ Representar la semántica de habitaciones y paredes en el tercer canal con números enteros específicos. ■ Usar el cuarto canal para almacenar información adicional que distinga entre diferentes habitaciones con las mismas etiquetas. Diferentes números enteros se utilizan para distinguir habitaciones con las mismas etiquetas.

Tabla 3
Actividades de la fase de Preprocesamiento de Datos.

Fuente: Elaboración propia.

A continuación, se detalla cada actividad y su entregable respectivo.

Actividad 1: Filtración de las imágenes de los planos interiores

En la fase de preprocesamiento de datos, la actividad de Filtración se enfoca en depurar y mejorar la calidad del conjunto de datos al eliminar información irrelevante o poco confiable. Esto se logra a través de la eliminación de datos no estándar y la conservación de aquellos que cumplen con criterios específicos de relevancia y fiabilidad.

Entregable: Conjunto de datos filtrado y optimizado para su posterior análisis.

Actividad 2: Representación de las imágenes de los planos interiores

Por otro lado, la actividad de Representación se encarga de convertir los datos en un formato visual o estructurado más adecuado para su análisis y comprensión. Esto implica transformar los datos en imágenes o representaciones gráficas que faciliten su visualización y entendimiento, contribuyendo así a una mejor interpretación por parte de los usuarios finales, como podemos observar en la Figura 38.

Entregable: Representación visual y estructurada de cada plano de planta en un formato adecuado para su procesamiento y análisis posterior.

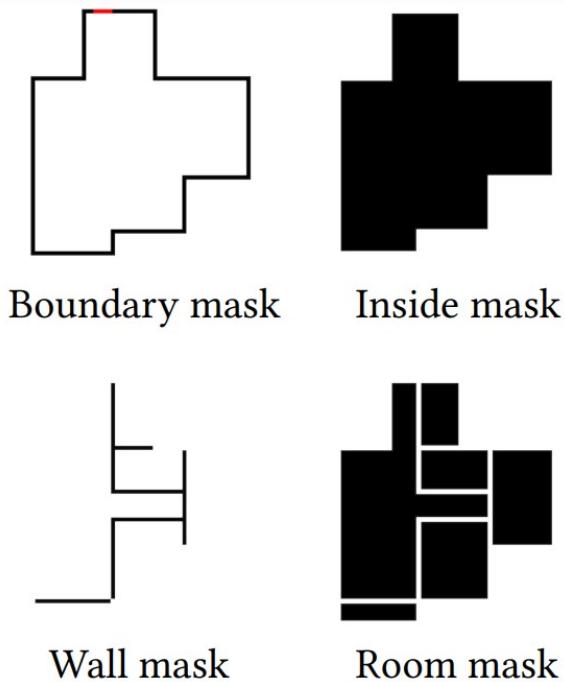


Figura 38. Representación de las imágenes de los planos interiores.

Fuente: Wu et al. (2019). «Data-driven Interior Plan Generation for Residential Buildings».

3.3.1.3. Desarrollo del Modelo de IA

Tres actividades fundamentales componen el modelo generativo para la optimización de la cobertura de las redes inalámbricas para la predicción de las ubicaciones de los puntos de acceso. Cada una de estas actividades utiliza estrategias de aprendizaje profundo avanzadas para trabajar de manera secuencial y colaborativa. La Tabla 4 muestra todo esto más a fondo.

Tabla 4
Actividades de la fase de Desarrollo del Modelo de IA.

Actividades	Descripción	Tareas
Arquitectura de la Red	Diseñar la arquitectura de la red neuronal para la predicción de APs.	<ul style="list-style-type: none"> ■ Selección del tipo de red CNN y GAN. ■ Diseño de la arquitectura de la red (capas convolucionales). ■ Implementación de la red en un framework de aprendizaje profundo. ■ Definición de entradas y salidas.

Fuente: Elaboración propia

A continuación, se detalla cada actividad y su entregable respectivo.

Actividad 1: Arquitectura de la Red

En esta actividad se diseñará e implementará la arquitectura de una red neuronal para la predicción de ubicaciones de puntos de acceso (APs). Se utilizará una combinación de Redes Neuronales Convolucionales (CNN) y Redes Generativas Antagónicas (GANs) para aprovechar sus capacidades en la extracción de características espaciales y generación de soluciones óptimas.

Respecto, al proceso de Red Neuronal Convolutacional (CNN) para la extracción de características, podemos verla con más detalle en la Figura 39, donde se ve el uso de la capa Conv2D (Varias capas convolucionales para extraer características espaciales), la capa Max-Pooling2D (Capas de pooling para reducir dimensionalidad y mantener características importantes), la capa Flatten (Aplanar la salida para conectarla con capas densas) y finalmente la capa Dense (Capas densas para aprendizaje y combinación de características extraídas).

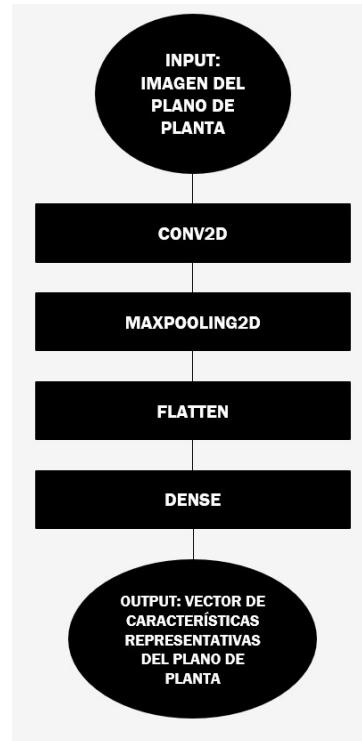


Figura 39. Red Neuronal Convolucional (CNN) para la extracción de características.

Fuente: Elaboración propia.

Por consiguiente, al proceso del Generador del GAN, podemos verla con más detalle en la Figura 40, donde se ve el uso de la capa Dense (Varias capas densas para transformar el vector de características en un plano con las ubicaciones de los Ap's), la capa Reshape (Dar forma al plano para que corresponda con las dimensiones del plano de planta), la capa Flatten (Aplanar la salida para conectarla con capas densas) y finalmente la capa Conv2DTranspose (Capas convolucionales transpuestas para generar la imagen final).

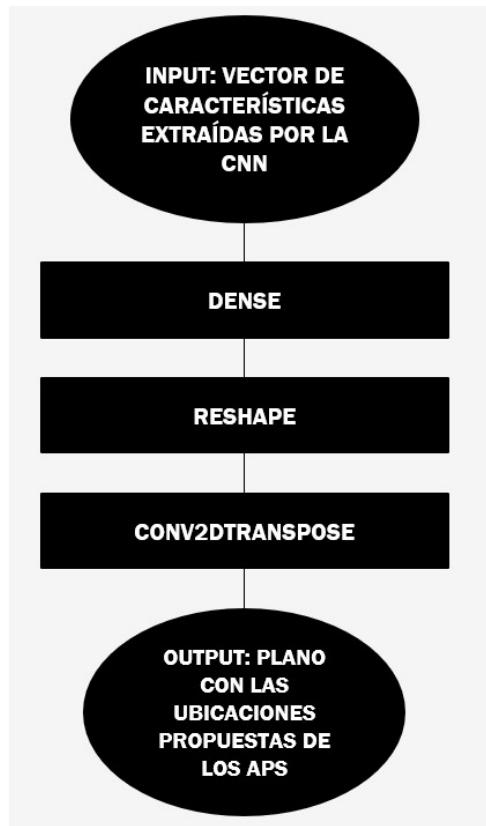


Figura 40. Generador del GAN.

Fuente: Elaboración propia.

Finalmente, al proceso del Discriminador del GAN, podemos verla con más detalle en la Figura 41, donde se ve el uso de la capa Conv2D (Varias capas convolucionales para analizar la imagen y evaluar la calidad de las ubicaciones propuestas), la capa MaxPooling2D (Capas de pooling para reducir dimensionalidad), la capa Flatten (Aplanar la salida para conectarla con capas densas) y finalmente la capa Dense (Capas densas para la clasificación final).

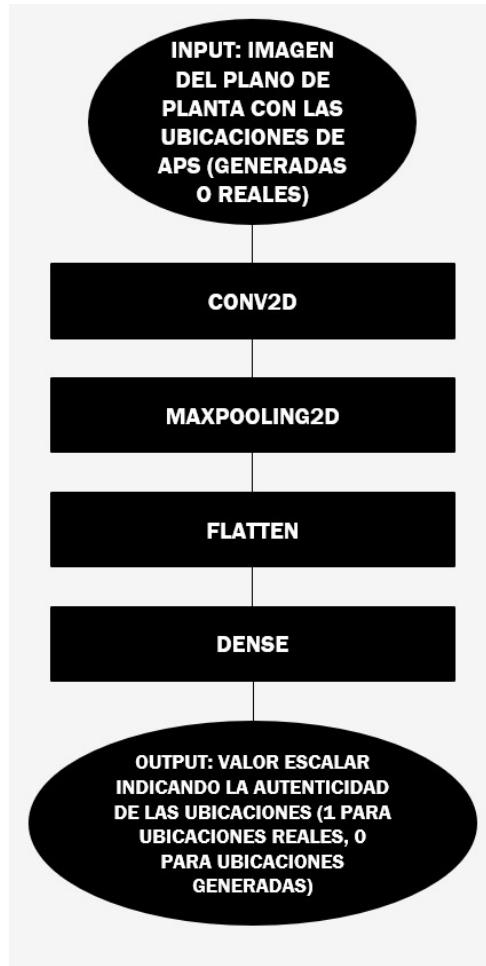


Figura 41. Discriminador del GAN.

Fuente: Elaboración propia.

A todo ello se utilizará TensorFlow para implementar la arquitectura descrita. A continuación, se presenta un pseudocódigo para la implementación en la Figura 42.

```

import tensorflow as tf
from tensorflow.keras.layers import Conv2D, MaxPooling2D, Flatten, Dense, Reshape, Conv2DTranspose, Input
from tensorflow.keras.models import Model

# CNN para extracción de características
input_image = Input(shape=(256, 256, 1))
x = Conv2D(32, (3, 3), activation='relu', padding='same')(input_image)
x = MaxPooling2D((2, 2))(x)
x = Conv2D(64, (3, 3), activation='relu', padding='same')(x)
x = MaxPooling2D((2, 2))(x)
x = Flatten()(x)
features = Dense(128, activation='relu')(x)

# Generador del GAN
g_input = Input(shape=(128,))
g = Dense(64 * 64 * 128, activation='relu')(g_input)
g = Reshape((64, 64, 128))(g)
g = Conv2DTranspose(64, (3, 3), strides=(2, 2), padding='same', activation='relu')(g)
g = Conv2DTranspose(32, (3, 3), strides=(2, 2), padding='same', activation='relu')(g)
g_output = Conv2DTranspose(1, (3, 3), activation='sigmoid', padding='same')(g)

# Discriminador del GAN
d_input = Input(shape=(256, 256, 1))
d = Conv2D(32, (3, 3), activation='relu', padding='same')(d_input)
d = MaxPooling2D((2, 2))(d)
d = Conv2D(64, (3, 3), activation='relu', padding='same')(d)
d = MaxPooling2D((2, 2))(d)
d = Flatten()(d)
d_output = Dense(1, activation='sigmoid')(d)

# Modelos
cnn_model = Model(input_image, features)
generator = Model(g_input, g_output)
discriminator = Model(d_input, d_output)

# Compilación de modelos
discriminator.compile(optimizer='adam', loss='binary_crossentropy', metrics=['accuracy'])
discriminator.trainable = False

gan_input = Input(shape=(128,))
gan_output = discriminator(generator(gan_input))
gan_model = Model(gan_input, gan_output)
gan_model.compile(optimizer='adam', loss='binary_crossentropy')

```

Figura 42. Pseudocódigo para la implementación.

Fuente: Elaboración propia.

Entregable: Código fuente de la red neuronal implementada, Diagramas y especificaciones de la arquitectura de la red y Especificaciones de entrada y salida del modelo.

3.3.1.4. Entrenamiento del Modelo

Al concluir la etapa del Desarrollo del Modelo de IA, se continua con el Entrenamiento, que fueron diseñados siguiendo las actividades de la Tabla 5.

Tabla 5
Actividades de la fase de Entrenamiento del Modelo.

Actividades	Descripción	Tareas
Entrenamiento Supervisado	Utilizar datos anotados para entrenar el modelo de predicción de APs.	<ul style="list-style-type: none"> ■ Entrenamiento del modelo utilizando el dataset anotado. ■ Evaluación y ajuste de hiperparámetros.
Optimización de Cobertura	Entrenar el modelo para maximizar la cobertura y minimizar la interferencia.	<ul style="list-style-type: none"> ■ Uso de técnicas de regularización para evitar sobreajuste. ■ Simulaciones para evaluar el impacto de las predicciones de APs en la cobertura de red. ■ Ajuste iterativo del modelo basado en los resultados de las simulaciones.

Actividad 1: Entrenamiento Supervisado

El entrenamiento supervisado implica el uso de un conjunto de datos anotado donde las ubicaciones óptimas de los puntos de acceso (APs) están previamente definidas. Este proceso es fundamental para enseñar al modelo a reconocer patrones y aprender a predecir ubicaciones óptimas de APs en base a la disposición de los planos de planta. Asimismo, se elaboró el pseudocódigo el cual se puede ver en la Figura 43.

```

import tensorflow as tf
from tensorflow.keras.optimizers import Adam
from tensorflow.keras.losses import BinaryCrossentropy

# Definición de modelos (CNN, Generador, Discriminador)

# Función de pérdida personalizada para la cobertura
def custom_loss(y_true, y_pred):
    # Implementar lógica para penalizar falta de cobertura y alta interferencia
    coverage_penalty = ...
    interference_penalty = ...
    return coverage_penalty + interference_penalty

# Compilar modelos
discriminator.compile(optimizer=Adam(learning_rate=0.0002), loss=BinaryCrossentropy(), metrics=['accuracy'])
discriminator.trainable = False

gan_input = Input(shape=(128,))
gan_output = discriminator(generator(gan_input))
gan_model = Model(gan_input, gan_output)
gan_model.compile(optimizer=Adam(learning_rate=0.0002), loss=custom_loss)

# Preparar datos (subconjunto anotado)
train_images, train_labels = load_annotated_data() # Función para cargar datos anotados

# Entrenamiento del GAN
batch_size = 64
epochs = 10000
for epoch in range(epochs):
    # Entrenar el discriminador
    real_data = get_real_samples(train_images, train_labels, batch_size)
    fake_data = generator.predict(np.random.normal(0, 1, (batch_size, 128)))

    discriminator.train_on_batch(real_data, np.ones((batch_size, 1)))
    discriminator.train_on_batch(fake_data, np.zeros((batch_size, 1)))

    # Entrenar el generador
    gan_model.train_on_batch(np.random.normal(0, 1, (batch_size, 128)), np.ones((batch_size, 1)))

    if epoch % 100 == 0:
        print(f'Epoch {epoch}/{epochs}')

# Guardar el modelo entrenado
generator.save('generator_model.h5')
discriminator.save('discriminator_model.h5')
gan_model.save('gan_model.h5')

```

Figura 43. Pseudocódigo para el Entrenamiento Supervisado.

Fuente: Elaboración propia.

Entregable: Modelo entrenado y archivos de checkpoints.

Actividad 2: Optimización de Cobertura

La optimización de la cobertura implica ajustar el modelo para maximizar la cobertura de red y minimizar la interferencia. Esto se logra implementando métricas específicas en la función de pérdida y realizando simulaciones de cobertura.

Asimismo, se elaboró el pseudocódigo el cual se puede ver en la Figura 44.

```

import numpy as np
import matplotlib.pyplot as plt

# Función de simulación de cobertura
def simulate_coverage(ap_locations, floor_plan):
    # Implementar Lógica para simular la cobertura basada en las ubicaciones de los APs y el plano de planta
    coverage = ...
    interference = ...
    return coverage, interference

# Función de evaluación del modelo
def evaluate_model(generator, validation_data):
    total_coverage = 0
    total_interference = 0
    for floor_plan in validation_data:
        noise = np.random.normal(0, 1, (1, 128))
        ap_locations = generator.predict(noise)
        coverage, interference = simulate_coverage(ap_locations, floor_plan)
        total_coverage += coverage
        total_interference += interference
    return total_coverage / len(validation_data), total_interference / len(validation_data)

# Cargar datos de validación
validation_data = load_validation_data() # Función para cargar datos de validación

# Evaluar el modelo inicial
initial_coverage, initial_interference = evaluate_model(generator, validation_data)
print(f'Initial Coverage: {initial_coverage}, Initial Interference: {initial_interference}')

# Ajuste iterativo del modelo
iterations = 10
for iteration in range(iterations):
    # Reentrenar el modelo con ajustes
    for epoch in range(epochs):
        real_data = get_real_samples(train_images, train_labels, batch_size)
        fake_data = generator.predict(np.random.normal(0, 1, (batch_size, 128)))

        discriminator.train_on_batch(real_data, np.ones((batch_size, 1)))
        discriminator.train_on_batch(fake_data, np.zeros((batch_size, 1)))

        gan_model.train_on_batch(np.random.normal(0, 1, (batch_size, 128)), np.ones((batch_size, 1)))

    # Evaluar el modelo ajustado
    coverage, interference = evaluate_model(generator, validation_data)
    print(f'Iteration {iteration + 1}: Coverage: {coverage}, Interference: {interference}')

    # Ajustar hiperparámetros o realizar otros ajustes según sea necesario
    # Por ejemplo, modificar la tasa de aprendizaje, agregar más capas, etc.

    # Guardar modelo ajustado
    generator.save(f'generator_model_iteration_{iteration + 1}.h5')
    discriminator.save(f'discriminator_model_iteration_{iteration + 1}.h5')
    gan_model.save(f'gan_model_iteration_{iteration + 1}.h5')

```

Figura 44. Pseudocódigo para la Optimización de Cobertura.

Fuente: Elaboración propia.

Entregable: Función de pérdida mejorada con métricas de cobertura e interferencia y Reporte de resultados de simulaciones de cobertura.

3.3.1.5. Evaluación del Modelo

Esta fase comprende la evaluación de los modelos desarrollados en la investigación a través de las métricas de clasificación seleccionadas y explicadas en la sección 3.3.2. En la Tabla 6 se indican las actividades y tareas seguidas para esta etapa.

Tabla 6
Actividades de la fase de Evaluación del Modelo.

Actividad	Descripción	Tareas
Preparación de Datos de Validación	Seleccionar y preparar un conjunto de datos de validación representativo.	<ul style="list-style-type: none"> ■ Selección de planos de planta no utilizados en el entrenamiento. ■ Preprocesamiento de imágenes.
Definición de Métricas de Evaluación	Definir métricas cuantitativas para evaluar la cobertura y la interferencia.	<ul style="list-style-type: none"> ■ Identificación de métricas adecuadas. ■ Implementación de funciones para calcular estas métricas.
Evaluación del Modelo	Evaluar el modelo entrenado en el conjunto de datos de validación para obtener una línea base.	<ul style="list-style-type: none"> ■ Predicción de ubicaciones de APs en el conjunto de validación. ■ Cálculo de métricas de evaluación.

Fuente: Elaboración propia

Actividad 1: Preparación de Datos de Validación

La preparación de datos de validación es crucial para evaluar la efectividad del modelo en datos que no ha visto antes. Esta actividad implica seleccionar un subconjunto representativo del dataset que no se utilizó durante el entrenamiento del modelo. La selección debe considerar

la diversidad en los planos de planta y configuraciones para asegurar que el modelo generaliza bien a diferentes escenarios.

Entregable: Un conjunto de datos listo para su uso en la evaluación del modelo, que incluye imágenes preprocesadas y listas para ser utilizadas en el análisis.

Actividad 2: Definición de Métricas de Evaluación

Para evaluar el rendimiento del modelo de manera cuantitativa, es esencial definir métricas claras que reflejen tanto la cobertura de la red como los niveles de interferencia. Estas métricas proporcionarán una base objetiva para comparar el rendimiento del modelo en diferentes escenarios y con otros enfoques existentes.

Entregable: Un documento detallado que describe cada métrica y proporciona el código o las funciones necesarias para calcularlas.

Actividad 3: Evaluación del Modelo

La evaluación del modelo implica usar el conjunto de datos de validación para obtener una línea base de su rendimiento. Esta evaluación es fundamental para entender cómo el modelo se comporta en situaciones no vistas durante el entrenamiento y para identificar posibles áreas de mejora.

Entregable: Un informe que presenta los resultados de la evaluación inicial, incluyendo las métricas de rendimiento calculadas y cualquier observación relevante sobre el comportamiento del modelo.

3.3.1.6. Despliegue

En la última fase de la metodología seguida, se desplegó el modelo propuesto una vez terminada su entrenamiento y evaluación correspondiente. Las actividades que se llevaron a cabo son detalladas en la Tabla 7.

Tabla 7
Actividades de la fase de Despliegue.

Actividad	Descripción	Tareas
Preparación del Entorno de Despliegue	Configurar el entorno necesario para desplegar el modelo en producción.	<ul style="list-style-type: none"> ■ Selección de infraestructura. ■ Configuración del entorno de hardware y software. ■ Pruebas iniciales.
Despliegue del Modelo en Producción	Implementar el modelo en el entorno de producción para su uso real.	<ul style="list-style-type: none"> ■ Implementación del modelo en producción. ■ Configuración de parámetros en tiempo de ejecución. ■ Monitoreo inicial del desempeño.

Fuente: Elaboración propia

Actividad 1: Preparación del Entorno de Despliegue

La preparación del entorno de despliegue es una etapa fundamental para asegurar que el modelo de IA pueda ser ejecutado eficientemente en producción. Este proceso implica la selección y configuración de la infraestructura necesaria, incluyendo tanto hardware como software, y la realización de pruebas iniciales para confirmar que todo funciona correctamente antes del despliegue completo.

Entregable: Un entorno completamente preparado, con todos los componentes necesarios instalados y configurados, listo para el despliegue del modelo.

Actividad 2: Despliegue del Modelo en Producción

El despliegue del modelo en producción es el paso en el que el modelo de IA se pone en funcionamiento en el entorno de producción. Este proceso incluye la implementación del modelo, la configuración de parámetros necesarios para su ejecución en tiempo real, y el monitoreo inicial para asegurar que el modelo funciona correctamente en condiciones reales.

Entregable: El modelo está completamente implementado y operando en el entorno

de producción, con los parámetros ajustados y el desempeño monitoreado para asegurar su correcto funcionamiento.

3.3.2 Metodología para la medición de resultados

Para medir el rendimiento de un modelo, se utilizan varias métricas que actúan como herramientas de evaluación basadas en los resultados proporcionados por la Matriz de confusión. A continuación, se explican su concepto y componentes.

- **Matriz de confusión:** Es una tabla de NxN que resume la precisión de las predicciones de un modelo de clasificación, mostrando la relación entre la etiqueta predicha y la etiqueta real. Un eje de la matriz de confusión representa las etiquetas predichas por el modelo, mientras que el otro eje muestra las etiquetas reales. N representa el número de clases. En un problema de clasificación binaria, N=2 (Kohavi & Provost, 1998). Su principal objetivo es describir cómo se desempeña un modelo supervisado de Machine Learning en datos de prueba, donde los valores reales son desconocidos. Se llama "matriz de confusión" porque facilita la identificación de dónde el sistema confunde dos clases (SitioBigData.com, 2019). Se representa en la Figura 45.

		Predicción	
		Positivos	Negativos
Observación	Positivos	Verdaderos Positivos (VP)	Falsos Negativos (FN)
	Negativos	Falsos Positivos (FP)	Verdaderos Negativos (VN)

Figura 45. Matriz de Confusión.

Fuente: Izco (2018). «Base de Datos Corporativa».

- **Resultado Verdadero Positivo (TP o True Positive):** Se refiere al caso en el que el modelo hizo una predicción precisa de la clase positiva. Por ejemplo, el modelo acertó al identificar que un paciente con ciertas características específicas tiene cáncer (Google Developers, 2018).
- **Resultado Verdadero Negativo (TN o True Negative):** Este caso se presenta cuando el modelo hace una predicción acertada de la clase negativa. Por ejemplo, el modelo correc-

tamente determinó que una especie animal según sus características no es un mamífero (Google Developers, 2018).

- **Resultado Falso Positivo (FP, False Positive o Error Tipo I):** Sucede cuando el modelo predice incorrectamente la clase positiva. Por ejemplo, el modelo indica erróneamente que un paciente varón está embarazado (clase positiva) cuando en realidad no lo está (Google Developers, 2018).
- **Resultado Falso Negativo (FN, False Negative o Error Tipo II):** Este caso ocurre cuando el modelo predice incorrectamente la clase negativa. Por ejemplo, el modelo clasifica erróneamente un correo electrónico como no spam (clase negativa), cuando en realidad sí es spam (Google Developers, 2018).

Después de explicar los conceptos previos, se obtienen las siguientes métricas comúnmente utilizadas en clasificación, de las cuales se utilizarán solo las tres primeras según lo referenciado en los documentos anteriores:

- **Exactitud (accuracy):** Representa la proporción de predicciones correctas sobre el total de ejemplos en un modelo de clasificación. Se calcula mediante la siguiente fórmula (Kohavi & Provost, 1998):

$$\text{Exactitud} = \frac{V.P. + V.N.}{V.P. + V.N. + F.P. + F.N.} \quad (1)$$

La pregunta que responde esta métrica es ¿Cuál es la proporción de predicciones correctas?

- **Precisión (precision):** Mide el número de elementos correctamente identificados como positivos en relación al total de elementos identificados como positivos. Se calcula mediante la siguiente fórmula:

$$\text{Precisión} = \frac{V.P.}{V.P. + F.P.} \quad (2)$$

La pregunta que responde esta métrica es ¿Qué proporción de predicciones positivas es correcta?

- **Área bajo la curva ROC (AUC):** Considera todos los umbrales de clasificación posibles. Representa la probabilidad de que un clasificador tenga más seguridad de que un ejemplo

resulte ser un verdadero positivo con respecto a que sea un falso positivo (Google Developers, 2018). Para entender el concepto del área, se necesita entender qué es la curva ROC y para qué sirve en primer lugar.

La curva ROC es una herramienta que evalúa la capacidad de distinguir entre dos categorías en un modelo, como por ejemplo, determinar si un paciente tiene cáncer o no.

Al ajustar el umbral hacia la izquierda, es decir, aumentando la sensibilidad, la especificidad tiende a disminuir. En cambio, al mover el umbral hacia la derecha, la sensibilidad disminuye y la especificidad aumenta. Esto revela una relación inversa entre la sensibilidad y la especificidad. La curva ROC representa la sensibilidad (1-especificidad) (González, 2019).

El área bajo esta curva indica qué tan efectivo es el modelo. Un mayor rendimiento se refleja en una curva que se aleja de la diagonal principal, como se calcula con la siguiente fórmula:

$$P(score(x^+) > score(x^-)) \quad (3)$$

Respecto a la interpretación del área bajo la curva ROC se sabe que:

- Si el área bajo la curva ROC = 0.5, entonces el poder discriminante del modelo es nulo.
 - Si el área bajo la curva $0.5 < \text{ROC} < 0.7$, entonces el poder discriminante del modelo no es aceptable.
 - Si el área bajo la curva $0.7 \leq \text{ROC} < 0.8$, entonces el poder discriminante del modelo es aceptable.
 - Si el área bajo la curva $0.8 \leq \text{ROC} < 0.9$, entonces el poder discriminante del modelo es excelente.
 - Si el área bajo la curva $\text{ROC} \geq 0.9$, entonces el poder discriminante del modelo es excepcionalmente bueno.
- **Sensibilidad** (*recall, sensitivity* o *True Positive Rate*): Representa el número de elementos correctamente identificados como positivos del total de positivos verdaderos (Sitio-BigData.com, 2019). Se calcula mediante la siguiente fórmula:

$$\text{Sensibilidad} = \frac{V.P.}{V.P. + F.N.} \quad (4)$$

- **Puntaje F1 (F1-Score):** Representa la media armónica de la precisión y la sensibilidad. Normalmente, se usa cuando uno difiere mucho del otro y no es posible realizar una conclusión determinante ya que solo es posible predecir bien una clase (SitioBigData.com, 2019). Se calcula mediante la siguiente fórmula:

$$\text{PuntajeF1} = \frac{2 * \text{Precisión} * \text{Sensibilidad}}{\text{Precisión} + \text{Sensibilidad}} \quad (5)$$

3.4 Cronograma de actividades y presupuesto

Se creó un plan de trabajo detallado para el proyecto de investigación, representado en la Figura 46, abarcando desde su inicio a inicios de 2024 hasta la presentación del trabajo prevista para finales de 2024.

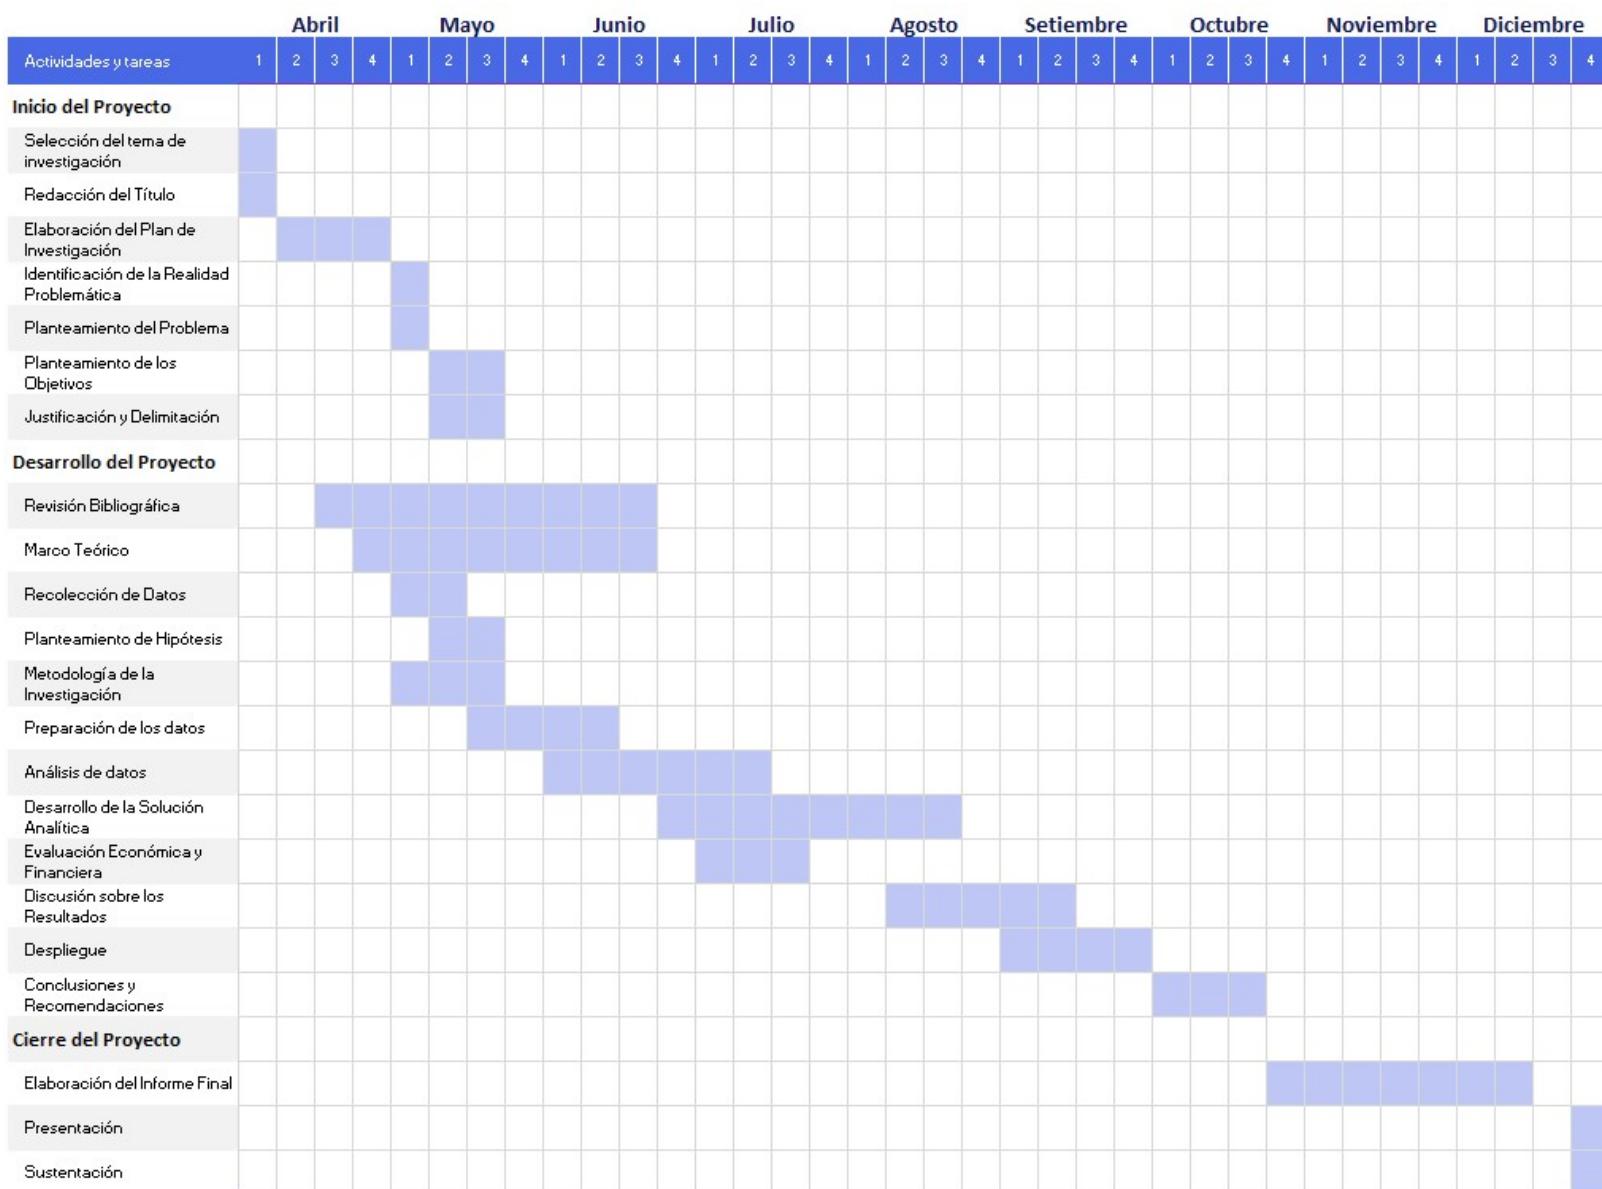


Figura 46. Cronograma de actividades.

Fuente: Elaboración propia.

La Tabla 8 detalla los gastos personales del autor de la investigación, que comprenden la compra de herramientas como una computadora portátil antes del inicio del proyecto, así como los pagos asociados a servicios generales y al proceso de elaboración y defensa pública de la tesis.

Tabla 8
Presupuesto.

Item	Tiempo usado (horas)	Costo (soles)	Subtotal
Recursos materiales			
Laptop Lenovo ideapad S340-15IIL Core i7 10va Gen		S/.5,700.00	S/.5,700.00
Pagos del trámite de elaboración y sustentación pública de Tesis			
Derecho de inscripción de tema de investigación		S/.800.00	S/.800.00
Reserva del tema de tesis		S/.2,700.00	S/.2,700.00
Derecho de sustentación		S/.1,500.00	S/.1,500.00
Recursos humanos			
Avance de tesis	900	Incalculable	-
Servicios generales			
Internet + luz (8 meses)	110	S/.100.00	S/.600.00
Total			S/.11,300.00

Fuente: Elaboración propia.

Referencias

- Alathari, B. (2023). An Optimization for Access Point Placement in Indoor Communication. *Springer*. doi: https://doi.org/10.1007/978-981-19-8406-8_48.
- Alpaydin, E. (2014). *Introduction to Machine Learning* (3^a ed.). MIT Press.
- Amazon. (2023). ¿Qué es la IA generativa? Recuperado de <https://www.bbvaopenmind.com/tecnologia/mundo-digital/que-es-el-aprendizaje-profundo/>.
- Baheti, P. (2020). *Introduction to Multimodal Deep Learning*. Recuperado de <https://heartbeat.fritz.ai/introduction-to-multimodal-deep-learning-630b259f9291>.
- Brownlee, J. (2017). *Deep Learning for Natural Language Processing: Develop Deep Learning Models for your Natural Language Problems*. Machine Learning Mastery. Recuperado de http://ling.snu.ac.kr/class/AI_Agent/deep_learning_for_nlp.pdf.
- Cai, M., & Lin, Z. (2023). Precise WiFi Indoor Positioning using Deep Learning Algorithms. *arXiv:2307.02011*. doi: <https://doi.org/10.48550/arxiv.2307.02011>.
- Chang, K.-H., Cheng, C.-Y., & Luo, J. (2021). Building-GAN: Graph-Conditioned Architectural Volumetric Design Generation. *arXiv:2104.13316v1*. doi: <https://doi.org/10.48550/arxiv.2104.13316>.
- Chen, Q., Wu, Q., & Tang, R. (2020). Intelligent Home 3D: Automatic 3D-House Design from Linguistic Descriptions Only. *arXiv*. doi: <https://doi.org/10.48550/arxiv.2003.00397>.
- Cisco. (2022). Los puntos de acceso C9120 no inician PnP o IOx. Recuperado de https://www.cisco.com/c/es_mx/support/docs/wireless/catalyst-9120axi-access-point/218069-c9120-access-points-do-not-start-pnp.html.
- Cisco. (2023). ¿Qué es un access point? Recuperado de https://www.cisco.com/c/es_mx/solutions/small-business/resource-center/networking/what-is-access-point.html.
- Deng, L., & Liu, Y. (2018). *Deep Learning in Natural Language Processing*. Springer. doi: [10.1007/978-981-10-5209-5](https://doi.org/10.1007/978-981-10-5209-5).
- Dou, P., & Zheng, G. (2023). Research on Wireless Network Coverage for Transformation and Upgrading of Exhibition Management with Artificial Intelligence Technology. *Applied Mathematics and Nonlinear Sciences*, 9. doi: <https://doi.org/10.2478/amns.2023.1.00180>.
- El País. (2023). El wifi de la mayoría de los hogares se enfrenta al colapso por el aumento de dispositivos conectados y el tráfico de datos. Recuperado de <https://elpais.com/tecnologia/2023-09-26/el-wifi-de-la-mayoria-de-hogares-se-enfrenta-al-colapso-por-el-aumento-de-dispositivos-conectados-y-el-trafico-de-datos.html>.
- Gartner. (2019). Gartner IT Glossary - Predictive Modeling. Recuperado de <https://www.gartner.com/it-glossary/predictive-modeling/>.
- Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (2nd). O'Reilly Media.

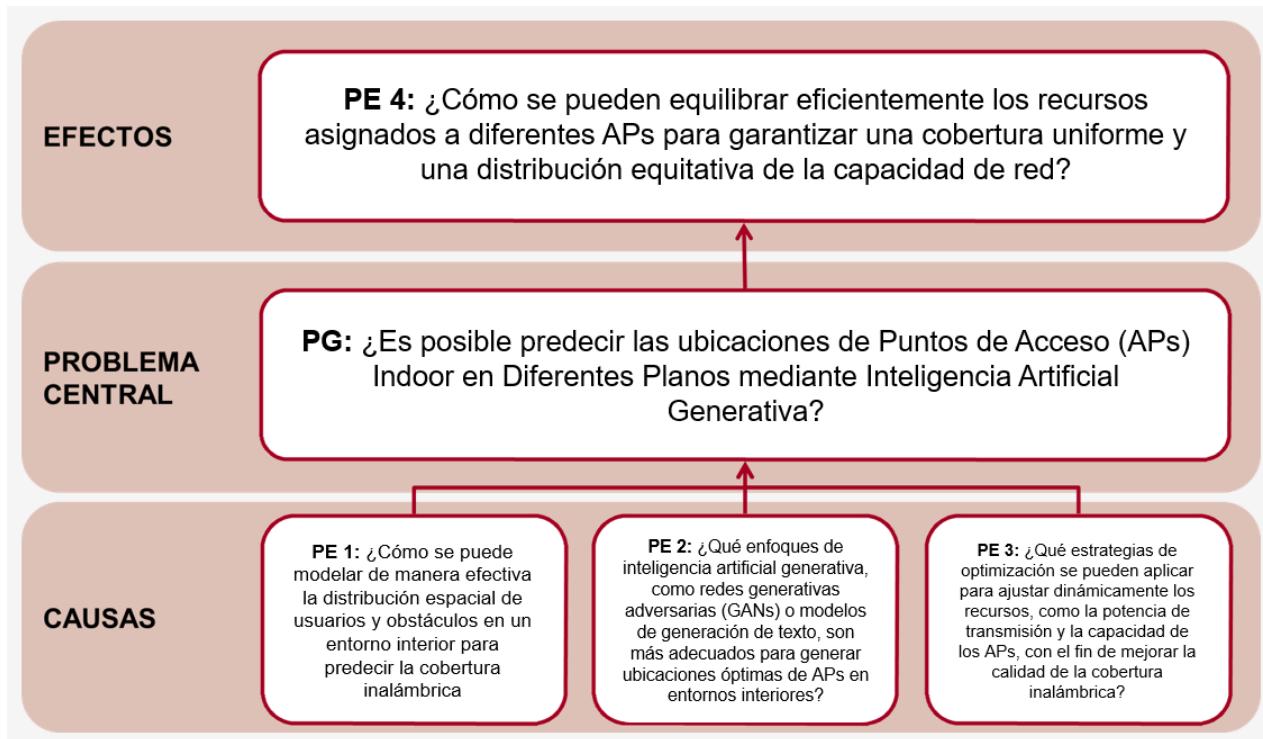
- González, L. (2019). Curvas ROC y Área bajo la curva (AUC). Recuperado de <http://ligdigonzalez.com/curvas-roc-y-area-bajo-la-curva-auc-machine-learning/>.
- Goodfellow, Pouget-Abadie, Mirza, Xu, Warde-Farley, Ozair, Courville & Bengio. (2014). Generative Adversarial Networks, 1-9. doi: 10.1001/jamainternmed.2016.8245.
- Google Developers. (2018). Glosario sobre aprendizaje automático. Recuperado de <https://developers.google.com/machine-learning/glossary/?hl=es-419>.
- Haining, R. (2003). *Spatial Data Analysis* [Tesis de grado]. University of Cambridge.
- Hernández Sampieri, R., Fernández Collado, C., & Baptista Lucio, P. (2014). *Metodología de la Investigación* (G. Hirst, Ed.; 6^a ed.). McGraw Hill Education. Recuperado de <https://academia.utp.edu.co/grupobasicoclinicayaplicadas/files/2013/06/Metodolog%C3%ADA-De-la-Investigaci%C3%B3n.pdf>.
- Hosseini, H., Taleai, M., & Zlatanova, S. (2023). NSGA-II based optimal Wi-Fi access point placement for indoor positioning: A BIM-based RSS prediction. *Automation in Construction*, 152. doi: <https://doi.org/10.1016/j.autcon.2023.104897>.
- House of Bots. (2018). Most Popular 20 Free Online Courses to Learn Deep Learning (K. Cook, Ed.). Recuperado de <https://www.houseofbots.com/news-detail/3620-4-most-popular-20-free-online-courses-to-learn-deep-learning>.
- IEEE. (2010). IEEE P802.11s Task Group IEEE Unapproved Draft Standard P802.11s/D4.0.
- Izco, F. (2018). Base de Datos Corporativa. Recuperado de https://bookdown.org/f_izco/BDC-POC/metricas.html.
- Kamath, U., Liu, J., & Whitaker, J. (2019). *Deep Learning for NLP and Speech Recognition*. Springer.
- Karnik & Passerini. (2005). Wireless Network Security - A Discussion from a Business Perspective. *Symposium, 2005 Wireless Telecommunications*, 261-267. doi: 10.1109/wts.2005.1524796.
- Ketkhaw, A., & Thipchaksurat, S. (2022). Location Prediction of Rogue Access Point Based on Deep Neural Network Approach. *Journal of Mobile Multimedia*, 18(4). doi: 10.13052/jmm1550-4646.1845.
- Kim, Y. (2014). Convolutional Neural Networks for Sentence Classification. *2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 1746-1751. doi: 10.3115/v1/d14-1181.
- Kingma & Welling. (2013). Auto-Encoding Variational Bayes. Recuperado de <http://arxiv.org/abs/1312.6114>.
- Kingma & Welling. (2019). An Introduction to Variational Autoencoders. *Foundations and Trends in Machine Learning*. Recuperado de <http://arxiv.org/abs/1906.02691>.
- Kohavi, R., & Provost, F. (1998). Glossary of Terms Journal of Machine Learning. Recuperado de <http://ai.stanford.edu/~ronnyk/glossary.html>.

- Kostadinov, S. (2019). *Understanding Encoder-Decoder Sequence to Sequence Model*. Towards Data Science. Recuperado de <https://towardsdatascience.com/understanding-encoder-decoder-sequence-to-sequence-model-679e04af4346>.
- Lee, G. (2015). 3D coverage location modeling of Wi-Fi access point placement in indoor environment. *Computers, Environment and Urban Systems*, 54. doi: <https://doi.org/10.1016/j.comenvurbsys.2015.05.002>.
- Marks & Gifford. (2001). Standards in IEEE 802 Unleash the Wireless Internet. *IEEE Microwave Magazine*, 2(2), 46-56.
- Martha Contreras, J. V., & Vesga, J. (2021). Modelo de optimización para la ubicación de Access Point en redes WLAN. *Investigación e Innovación en Ingenierías*, 9(1). doi: 10.17081/invinno.9.1.4203.
- NapIT. (2017). 3 Problemas que pueden perjudicar su Wireless Corporativo. Recuperado de <https://napit.com.br/3-problemas-que-pueden-perjudicar-su-wireless-corporativo/>.
- Nauata, N., Hosseini, S., & Chang, K.-H. (2021). House-GAN++: Generative Adversarial Layout Refinement Network towards Intelligent Computational Agent for Professional Architects. *Computer Vision Foundation*. doi: <https://doi.org/10.1109/cvpr46437.2021.01342>.
- Nishida, N., & Nakayama, H. (2015). *Multimodal gesture recognition using multi-stream recurrent neural network* (Reporte técnico). Universidad de Tokio. Recuperado de <http://www.nlab.ci.i.u-tokyo.ac.jp/projects/deeplearn-e.html>.
- Özerol, G., & Arslan, S. (2023). *Generating Mass Housing Plans Through Gans - A Case in Toki, Turkey*. doi: <https://doi.org/10.54729/2789-8547.1197>.
- Pang, Greenstein, Kaminsky, McCoy & Seshan. (2010). Wifi-Reports: Improving Wireless Network Selection with Collaboration. *IEEE Transactions on Mobile Computing*, 9(12), 1713-1731. doi: 10.1109/tmc.2010.151.
- Pundalik, C., Anooja, A., Ramaprasad, H., H, R., Hari, K., & Satish, E. (2023). Analysis of Wireless Networks: Successful and Failure Existing Technique. *Data Science and Intelligent Computing Techniques*, 877-891. doi: <https://doi.org/10.56155/978-81-955020-2-8-75>.
- Rafaqat, A., & Muhammad, T. (2019). A Survey on Wired and Wireless Network. *Lahore Garrison University Research Journal of Computer Science and Information Technology*, 2. doi: <http://dx.doi.org/10.54692/lgurjcsit.2018.020350>.
- Rao, D., & McMahan, B. (2019). *Natural Language Processing with PyTorch: Build Intelligent Language Applications Using Deep Learning*. O'Reilly.
- Russell, S., & Norvig, P. (2004). *Inteligencia Artificial: Un Enfoque Moderno* (J. M. Corchado Rodríguez, F. Martín Rubio, J. M. Cadenas Figueredo, L. D. Hernández Molinero, E. Paniagua Arís, R. Fuentetaja Pinzán, M. Robledo de los Santos & R. Rizo Aldeguer, Trad.; 2^a ed.). Pearson Educación, S.A. Recuperado de <https://luismejias21.files.wordpress.com/2017/09/inteligencia-artificial-un-enfoque-moderno-stuart-j-russell.pdf>.

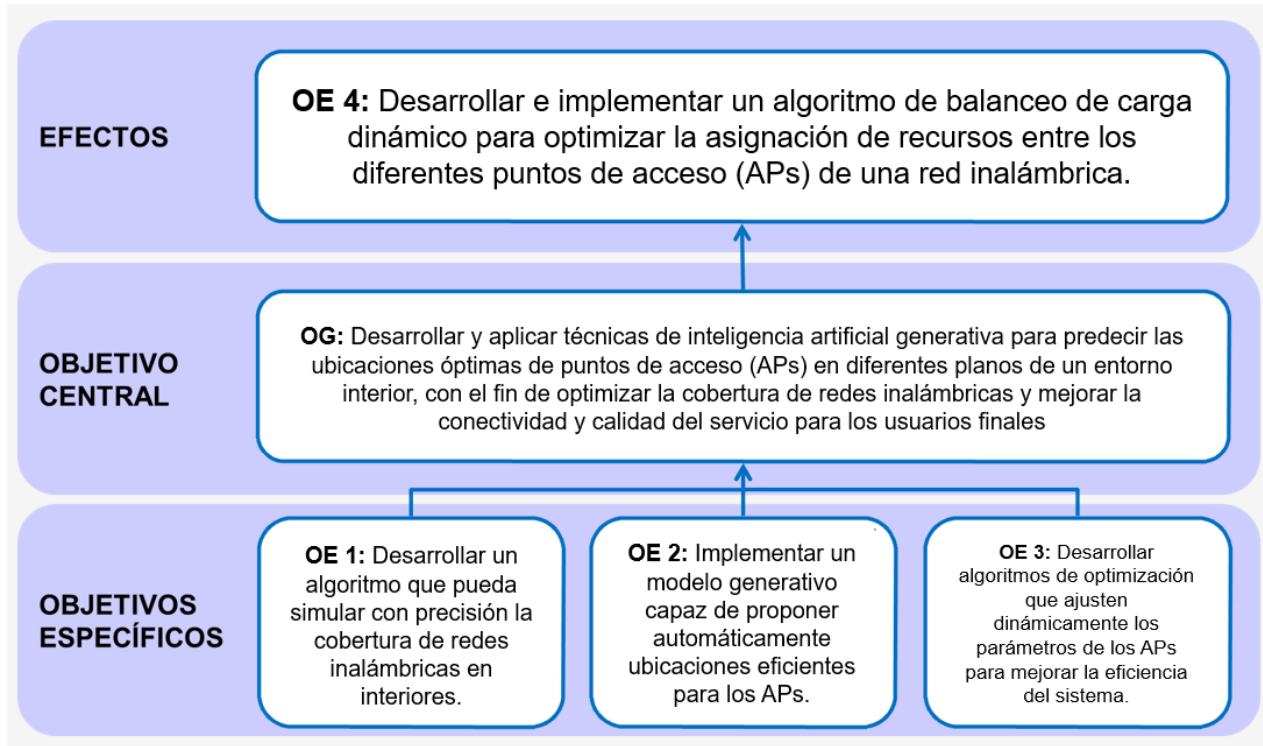
- Russell, S., & Norvig, P. (2009). *Inteligencia Artificial: Un Enfoque Moderno* (3^a ed.). Prentice Hall.
- Sancho Caparrini, F. (2018). *Clasificación Supervisada y No Supervisada* (Reporte técnico). Universidad de Sevilla. Sevilla, España. Recuperado de <http://www.cs.us.es/~fsancho/?e=77>.
- SAS Institute. (s.f.). ¿Qué es Deep Learning? Recuperado de https://www.sas.com/es_pe/insights/analytics/deep-learning.html.
- Singh, M., Lee, S., & Lee, H.-J. (2011). Performance of Mobility Models for Routing Protocol in Wireless Ad-hoc Networks. *Journal of Information and Communication Convergence Engineering*, 9(5), 610-617. doi: 10.6109/jicce.2011.9.5.610.
- SitioBigData.com. (2019). Machine Learning: Selección Métricas de clasificación. Recuperado de <http://sitiobigdata.com/2019/01/19/machine-learning-metrica-clasificacion-parte-3/#>.
- Sutton, R. S., & Barto, A. G. (2018). Finite Markov Decision Processes. En *Reinforcement Learning: An Introduction* (2^a ed., p. 48). MIT Press. Recuperado de <http://incompleteideas.net/book/RLbook2018.pdf>.
- Wu, W., Fu, X.-M., Tang, R., Wang, Y., Qi, Y.-H., & Liu, L. (2019). Data-driven Interior Plan Generation for Residential Buildings. *ACM Transactions on Graphics (SIGGRAPH Asia)*, 38(6).
- YMANT. (2023). ¿Qué es un AP (Access Point) y que usos y modos tiene? Recuperado de <https://www.ymant.com/blog/que-es-un-ap-access-point-y-que-usos-y-modos-tiene/>.
- Zambrano, J. (2018, marzo). *¿Aprendizaje supervisado o no supervisado? Conoce sus diferencias dentro del machine learning y la automatización inteligente*. Medium. Recuperado de <https://medium.com/@juanzambrano/aprendizaje-supervisado-o-no-supervisado-39ccf1fd6e7b>.
- Zant, C. M. v. d. (2010). *Generative AI: a neo-cybernetic analysis* [Tesis de grado]. University of Groningen. Recuperado de <https://pure.rug.nl/ws/portalfiles/portal/2582687/thesis.pdf>.
- Zignani, A. (2020). ABI: 6 GHz band essential amid growing WiFi demand. Recuperado de <https://www.abiresearch.com/market-research/insight/7781240-as-the-6-ghz-spectrum-battleground-heats-u/>.

Anexos

A Árbol de Problemas



B Árbol de Objetivos



C Matriz de Consistencia

Título de la tesis	Optimización de Cobertura de Redes Inalámbricas mediante Inteligencia Artificial GENERATIVA para la Predicción de Ubicaciones de Puntos de Acceso (APs) Indoor en Diferentes Planos					
Problema General	Objetivo General	Hipótesis General	Variables	Dimensiones	Indicadores	Metodología
¿Es posible predecir las ubicaciones de Puntos de Acceso (APs) Indoor en Diferentes Planos mediante Inteligencia Artificial Generativa?	Desarrollar técnicas de inteligencia artificial generativa para predecir las ubicaciones óptimas de puntos de acceso (APs) en diferentes planos de un entorno interior, con el fin de optimizar la cobertura de redes inalámbricas y mejorar la conectividad y calidad del servicio para los usuarios finales.	La aplicación de técnicas de inteligencia artificial generativa para la predicción de la ubicación de puntos de acceso (Aps) en planes distribuidos en zonas interiores supone una mejora significativa en la cobertura y calidad del servicio de los recursos sin datos.	Independiente: Inteligencia Artificial Generativa	Modelo de Inteligencia Artificial Generativa	Precisión y predicción del modelo de IA Generativa	<ul style="list-style-type: none"> – Tipo de investigación: Diseño Experimental. – Alcance de la investigación: Descriptivo, porque busca describir las características de un fenómeno. – Enfoque de investigación: Cuantitativa.
Problemas Específicos	Objetivos Específicos	Hipótesis Específicas				

Efectividad del modelo de IA Generativa

¿Cómo se puede modelar de manera efectiva la distribución espacial de usuarios y obstáculos en un entorno interior para predecir la cobertura inalámbrica?

Desarrollar un algoritmo que pueda simular con precisión la cobertura de redes inalámbricas en interiores

Los algoritmos de inteligencia artificial generativa, como las GAN, se pueden utilizar para predecir con precisión la ubicación óptima de los puntos de acceso (AP) en un entorno interior.

¿Qué enfoques de inteligencia artificial generativa son más adecuados para generar ubicaciones óptimas de APs en entornos interiores?

Implementar un modelo generativo capaz de proponer automáticamente ubicaciones eficientes para los APs

La combinación de datos de sensores de señales inalámbricos con datos como planos arquitectónicos mejoran la precisión y predicción de la ubicación de AP mediante inteligencia artificial generativa.

Estructura del modelo de IA Generativa

Complejidad de la estructura del modelo de IA Generativa

¿Cómo puedo encontrar una base de datos eficiente y robusta que almacene información detallada y precisa sobre la infraestructura de edificios y características de entornos indoor?

Encontrar una base de datos eficiente y robusta que almacene información detallada sobre la infraestructura de los edificios y características de los entornos indoor.

Una base de datos bien gestionada y enriquecida con datos contextuales permitirá validar las predicciones de los modelos de IA de manera más fiable, comparando las ubicaciones sugeridas con las condiciones reales y mejorando la precisión de futuras predicciones.

Cobertura de Red

Estado de financiamiento de un proyecto

Dependiente:
Predicción de
Ubicaciones de
Puntos de Acceso
(APs) Indoor en
Diferentes Planos

¿Cuáles son las métricas y metodologías de evaluación más adecuadas para medir la eficiencia y efectividad de las predicciones de ubicaciones óptimas de puntos de acceso (APs) generadas por modelos de inteligencia artificial generativa en entornos indoor?

Desarrollar un conjunto de métricas y un marco de evaluación para medir la eficiencia y efectividad de las predicciones generadas por los modelos de inteligencia artificial generativa en la optimización de la cobertura de redes inalámbricas indoor.

La implementación de un marco de evaluación estandarizado permitirá comparar de manera objetiva diferentes enfoques y modelos de IA, facilitando la selección de los más efectivos para optimizar la cobertura de redes inalámbricas en distintos entornos indoor.

Experiencia del usuario

- Metainformación.
- Descripción.
- Comentarios.

D Comparación de metodologías de antecedentes

Autor	Título de la Investigación	Metodología	Grupo
Contreras, Vesga & Vesga	Modelo de optimización para la ubicación de Access Point en redes WLAN	<ul style="list-style-type: none"> – Recolección de información. – Modelado. – Evaluación. – Implementación. 	GG
Alathari	An Optimization for Access Point Placement in Indoor Communication	<ul style="list-style-type: none"> – Recolección de información. – Pre-procesamiento de datos. – Modelado. – Evaluación. – Implementación. 	GE
Ketkhaw & Thipchaksurat	Location Prediction of Rogue Access Point Based on Deep Neural Network Approach	<ul style="list-style-type: none"> – Desarrollo del problema. – Recolección de información. – Pre-procesamiento de datos. – Evaluación. – Implementación. 	GD
Nauata, Hosseini & Chang	House-GAN++: Generative Adversarial Layout Refinement Network towards Intelligent Computational Agent for Professional Architects	<ul style="list-style-type: none"> – Recolección de información. – Pre-procesamiento de datos. – Evaluación. – Implementación. 	GF
Cai & Lin	Precise WiFi Indoor Positioning using Deep Learning Algorithms	<ul style="list-style-type: none"> – Recolección de información. – Pre-procesamiento de datos. – Modelado. – Evaluación. 	GF
Hosseini, Taleai & Zlatanova	NSGA-II based optimal Wi-Fi access point placement for indoor positioning: A BIM-based RSS prediction	<ul style="list-style-type: none"> – Desarrollo del problema. – Recolección de información. – Pre-procesamiento de datos. – Modelado. – Evaluación. 	GD

Lee	3D coverage location modeling of Wi-Fi access point placement in indoor environment	<ul style="list-style-type: none"> – Recolección de información. – Pre-procesamiento de datos. – Modelado. – Evaluación. – Implementación. 	GE
Özerol & Arslan	Generating Mass Housing Plans Through Gans - A Case in Toki, Turkey	<ul style="list-style-type: none"> – Recolección de información. – Modelado. – Evaluación. 	GH
Chang, Cheng & Luo	Building-GAN: Graph-Conditioned Architectural Volumetric Design Generation	<ul style="list-style-type: none"> – Recolección de información. – Pre-procesamiento de datos. – Modelado. – Evaluación. 	GF
Chen, Wu & Tang	Intelligent Home 3D: Automatic 3D-House Design from Linguistic Descriptions Only	<ul style="list-style-type: none"> – Desarrpllo del problema. – Pre-procesamiento de datos. – Modelado. – Evaluación. 	GD
Dou & Zheng	Research on Wireless Network Coverage for Transformation and Upgrading of Exhibition Management with Artificial Intelligence Technology	<ul style="list-style-type: none"> – Recolección de información. – Exploración de datos. – Pre-procesamiento de datos. – Modelado. – Evaluación. 	GE